notebook

March 18, 2025

1 Proyek Analisis Data: Bike Sharing Dataset

- **Nama:** Satria Dirgantara Nuryaman
- **Email:** satriadirgantaranuryaman15@gmail.com
- **ID Dicoding:** MC435D5Y1642

1.1 Deskripsi Dataset

Dataset Bike Sharing berisi data peminjaman sepeda yang digunakan dalam sistem berbagi sepeda di Washington D.C., Amerika Serikat. Data ini dikumpulkan dari sistem Capital Bikeshare dan merupakan bagian dari penelitian Fanaee-T, Hadi (2013). Dataset ini mencatat jumlah peminjaman sepeda yang dilakukan setiap hari (day.csv) dan setiap jam (hour.csv), serta faktor-faktor eksternal seperti cuaca, musim, dan kondisi jalan yang dapat memengaruhi jumlah peminjaman sepeda.

Penjelasan Setiap Kolomnya: - instant: Indeks rekaman (nomor urut data) - dteday: Tanggal - season: Musim (1: Musim Semi, 2: Musim Panas, 3: Musim Gugur, 4: Musim Dingin) - yr: Tahun (0 = 2011, 1 = 2012) - mnth: Bulan (1 sampai 12) - hr: Jam (0 sampai 23) - holiday: Apakah hari tersebut adalah hari libur atau bukan (diambil dari situs http://dchr.dc.gov/page/holiday-schedule) - weekday: Hari dalam seminggu (Senin-Minggu) - workingday: Jika hari tersebut bukan akhir pekan atau hari libur, maka nilainya 1, selain itu 0. - weathersit (Kondisi Cuaca): - 1: Cerah, Berawan Tipis, Sebagian Berawan - 2: Kabut + Berawan, Kabut + Awan Pecah, Kabut + Sedikit Awan, Kabut - 3: Salju Ringan, Hujan Ringan + Petir + Awan Tersebar, Hujan Ringan + Awan Tersebar - 4: Hujan Lebat + Es + Petir + Kabut, Salju + Kabut - temp: Suhu normalisasi dalam Celsius (dibagi dengan 41°C sebagai nilai maksimum) - atemp: Suhu yang dirasakan (feels-like temperature), dinormalisasi (dibagi dengan 50°C sebagai nilai maksimum) - hum: Kelembapan, dinormalisasi (dibagi dengan 100%) - windspeed: Kecepatan angin, dinormalisasi (dibagi dengan 67 m/s sebagai nilai maksimum) - casual: Jumlah pengguna sepeda tanpa registrasi - registered: Jumlah pengguna sepeda terdaftar - cnt: Total jumlah peminjaman sepeda (casual + registered)

1.2 Menentukan Pertanyaan Bisnis

1. Bagaimana perbedaan total peminjaman sepeda antara tahun 2011 dan 2012?
2. Bagaimana kondisi cuaca memengaruhi jumlah peminjaman sepeda?
3. Kapan waktu puncak penggunaan sepeda dalam sehari, dan apakah ada perbedaan pola antara hari kerja dan akhir pekan di tahun 2011 & 2012?
4. Apakah tren peminjaman sepeda mengalami lonjakan atau penurunan signifikan pada bulan-bulan tertentu?
5. Bagaimana pola penggunaan sepeda berbeda antara pelanggan kasual dan pelanggan terdaftar pada hari kerja vs. akhir pekan serta pada berbagai jam dalam sehari?.

1.3 Import Semua Packages/Library yang Digunakan

[11]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import scipy.stats as stats
import statsmodels.api as sm
```

1.4 Data Wrangling

1.4.1 Gathering Data

1. Membuat Data Frame day.csv

[12]:
```
file_path_day = '/content/drive/MyDrive/Colab_Notebooks/
↪Submission_Bike_Sharing_Analysis/Data/day.csv'

day_df = pd.read_csv(file_path_day)
day_df.head()
```

[12]:
```
   instant      dteday  season  yr  mnth  holiday  weekday  workingday  \
0        1  2011-01-01       1   0     1        0        6           0
1        2  2011-01-02       1   0     1        0        0           0
2        3  2011-01-03       1   0     1        0        1           1
3        4  2011-01-04       1   0     1        0        2           1
4        5  2011-01-05       1   0     1        0        3           1

   weathersit      temp     atemp       hum  windspeed  casual  registered  \
0           2  0.344167  0.363625  0.805833   0.160446     331         654
1           2  0.363478  0.353739  0.696087   0.248539     131         670
2           1  0.196364  0.189405  0.437273   0.248309     120        1229
3           1  0.200000  0.212122  0.590435   0.160296     108        1454
4           1  0.226957  0.229270  0.436957   0.186900      82        1518

    cnt
0   985
1   801
2  1349
3  1562
4  1600
```

2. Membuat DataFrmae hour.csv

[13]:
```
file_path_hour = '/content/drive/MyDrive/Colab_Notebooks/
↪Submission_Bike_Sharing_Analysis/Data/hour.csv'

hour_df = pd.read_csv(file_path_hour)
```

```
hour_df.head()
```

[13]:

```
   instant      dteday  season  yr  mnth  hr  holiday  weekday  workingday  \
0        1  2011-01-01       1   0     1   0        0        6           0
1        2  2011-01-01       1   0     1   1        0        6           0
2        3  2011-01-01       1   0     1   2        0        6           0
3        4  2011-01-01       1   0     1   3        0        6           0
4        5  2011-01-01       1   0     1   4        0        6           0

   weathersit  temp   atemp   hum  windspeed  casual  registered  cnt
0           1  0.24  0.2879  0.81        0.0       3          13   16
1           1  0.22  0.2727  0.80        0.0       8          32   40
2           1  0.22  0.2727  0.80        0.0       5          27   32
3           1  0.24  0.2879  0.75        0.0       3          10   13
4           1  0.24  0.2879  0.75        0.0       0           1    1
```

1.4.2 Assessing Data

1.4.3 Menilai Data day_df

---

1. Menggali Informasi dengan .info()

[14]:

```
day_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 731 entries, 0 to 730
Data columns (total 16 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   instant     731 non-null    int64
 1   dteday      731 non-null    object
 2   season      731 non-null    int64
 3   yr          731 non-null    int64
 4   mnth        731 non-null    int64
 5   holiday     731 non-null    int64
 6   weekday     731 non-null    int64
 7   workingday  731 non-null    int64
 8   weathersit  731 non-null    int64
 9   temp        731 non-null    float64
 10  atemp       731 non-null    float64
 11  hum         731 non-null    float64
 12  windspeed   731 non-null    float64
 13  casual      731 non-null    int64
 14  registered  731 non-null    int64
 15  cnt         731 non-null    int64
dtypes: float64(4), int64(11), object(1)
memory usage: 91.5+ KB
```

Insight Dari apa yang aku lihat dan analisis aku menemukan:

- Tidak ada *Missing Value*. Karena total baris di setiap kolom sama sebanyak 731.
- Tipe data nya adalah:
- integer mendominasi dengan 11 kolom.
- float ada 4.

OverAll data ini bagus karena tidak ada missing value sama sekali. Tapi:

- Ada Kesalahan format pada kolom dteday yang seharusnya `datetime` tapi malah `object`
- Setelah aku pikir pikir, season, yr, mnth, holiday, weekday, workingday, dan weathersit kayanya cocok deh dijadikan data category.

---

2. Mencari apakah ada `duplicated`.

[15]:
```
print(f'Jumlah data di day_df yang duplikasi adalah = {day_df.duplicated().
↪sum()}')
```

```
Jumlah data di day_df yang duplikasi adalah = 0
```

Insight

- Dengan tidak adanya *Duplicated* dan juga *Missing Value* data ini bisa di anggap bersih.

---

3. Melihat `Statistik Deskriptif` dari day_df.

[16]:
```
day_df.describe()
```

[16]:

	instant	season	yr	mnth	holiday	weekday	\
count	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	
mean	366.000000	2.496580	0.500684	6.519836	0.028728	2.997264	
std	211.165812	1.110807	0.500342	3.451913	0.167155	2.004787	
min	1.000000	1.000000	0.000000	1.000000	0.000000	0.000000	
25%	183.500000	2.000000	0.000000	4.000000	0.000000	1.000000	
50%	366.000000	3.000000	1.000000	7.000000	0.000000	3.000000	
75%	548.500000	3.000000	1.000000	10.000000	0.000000	5.000000	
max	731.000000	4.000000	1.000000	12.000000	1.000000	6.000000	

	workingday	weathersit	temp	atemp	hum	windspeed	\
count	731.000000	731.000000	731.000000	731.000000	731.000000	731.000000	
mean	0.683995	1.395349	0.495385	0.474354	0.627894	0.190486	
std	0.465233	0.544894	0.183051	0.162961	0.142429	0.077498	
min	0.000000	1.000000	0.059130	0.079070	0.000000	0.022392	
25%	0.000000	1.000000	0.337083	0.337842	0.520000	0.134950	
50%	1.000000	1.000000	0.498333	0.486733	0.626667	0.180975	
75%	1.000000	2.000000	0.655417	0.608602	0.730209	0.233214	
max	1.000000	3.000000	0.861667	0.840896	0.972500	0.507463	

	casual	registered	cnt
count	731.000000	731.000000	731.000000
mean	848.176471	3656.172367	4504.348837
std	686.622488	1560.256377	1937.211452
min	2.000000	20.000000	22.000000
25%	315.500000	2497.000000	3152.000000
50%	713.000000	3662.000000	4548.000000
75%	1096.000000	4776.500000	5956.000000
max	3410.000000	6946.000000	8714.000000

Insight Distribusi Waktu - `season`: - Mean berada pada 2.49, yang berarti kebanyakan data berada di musim ke 2 (summer) dan 3 (musim gugur/fall). - std(Standar Deviasi) menunjukan 1.11 yang menunjukan bahwa sebaran data cukup merata di 4 musim. - `mnth`: - Mean = 6.5 ini menunjukan data hampir merata di semua bulan dengan sedikit lebih banyak di pertengahan tahun.

Holiday VS WorkingDay - `holiday`: - Mean = 0.0287, menunjukkan bahwa hanya sekitar 3% dari hari dalam dataset adalah hari libur. - `Workingday`: - Mean = 0.683, menunjukan 68% dari data adalah hari kerja, yang berarti dataset lebih banyak mencerminkan aktivitas pada hari kerja.

Cuaca - `weathersit`: - Mean = 1.39, menunjukan bahwa mayoritas hari memiliki cuaca cerah atau sebagaian Berawan. - Max = 3, berarti tidak ada data yang mencapai cuaca exstrem. - `temp`: - Mean = 0.49, berarti rata-rata suhu berada di sekitar 50% dari skala maksimumnya. - Min = 0.06, Max = 0.86, menunjukkan variasi suhu yang cukup besar. - `hum`: - Mean = 0.62, artinya rata-rata kelembaban cukup tinggi. - Max = 0.97, menunjukkan ada hari dengan kelembaban hampir 100%. - `windspeed`: - Mean = 0.19, menunjukkan angin rata-rata tidak terlalu kencang. - Max = 0.50, artinya ada hari dengan angin cukup kuat tetapi tidak ekstrem.

Jumlah Penyewaan Sepeda - `casual`: - Mean = 848, tetapi Std = 686, menunjukkan variasi besar dalam jumlah penyewa harian yang tidak terdaftar. - Min = 2, Max = 3410, artinya ada hari dengan sangat sedikit penyewa, tetapi juga hari dengan jumlah sangat tinggi. - `registered`: - Mean = 3656, menunjukkan bahwa mayoritas pengguna adalah penyewa terdaftar. - Max = 6946, jauh lebih tinggi dari pengguna casual. - `cnt`: - Mean = 4504, menunjukkan jumlah rata-rata penyewa sepeda per hari. - Min = 22, Max = 8714, menunjukkan perbedaan besar antara hari tersibuk dan hari paling sepi.

Dari apa yang aku lihat dan pelajari, aku menemukan keanehan dari statistik tersebut.

1. Pada kolom hum, kelembapan minimum nya menyentuh angka 0, yang dimana ini tidak akan mungkin terjadi, karena gurun pun masih punya kelembapan.
2. Pada kolom windspeed, kecepatan angin sampai 34 m/s atau 122 KM/jam kalau kita kali m/s nya dengan 67. Itu menunjukan adanya anomali atau outliers karena itu tidak mungkin kecuali memang ada badai.
3. Pada kolom casual, registered, dan juga cnt, statistik menunjukan min nya menunjukan 2, 20, 22. ini kenapa apakah ini kesalahan input atau memang orang orang nya malas untuk berkegiatan, max nya terlalu ogal ogalan dan melonjak banget potensial outliers.

---

4. Melihat `Inaccurate Value`, dan `amomali`.

- **1. Kolom `hum`**

[17]:
```
day_df['hum'].describe()
```

[17]:
```
count    731.000000
mean       0.627894
std        0.142429
min        0.000000
25%        0.520000
50%        0.626667
75%        0.730209
max        0.972500
Name: hum, dtype: float64
```

[18]:
```
day_df[day_df['hum'] == 0]
```

[18]:
```
    instant      dteday  season  yr  mnth  holiday  weekday  workingday  \
68       69  2011-03-10       1   0     3        0        4           1

    weathersit      temp     atemp  hum  windspeed  casual  registered  cnt
68           3  0.389091  0.385668  0.0   0.261877      46         577  623
```

Insight Aku percaya bahwa ini eror sistem karena mengapa: - Di baris 0 tersebut sedang turun hujan yang lebar. - temp yang normal. - Tidak mungkin kelembapan 0/sangat kering karena di gurun saja masih ada kelembapan.

Mungkin aku akan menggunakan interpolasi linear karena pasti nilai hum tidak akan berfluktuasi dan juga saling terhubung.

- **2. Kolom `windspeed`.**

[19]:
```
day_df['windspeed'].describe()
```

[19]:
```
count    731.000000
mean       0.190486
std        0.077498
min        0.022392
25%        0.134950
50%        0.180975
75%        0.233214
max        0.507463
Name: windspeed, dtype: float64
```

[20]:
```
day_df[day_df['windspeed'] == 0.507463]
```

[20]:
```
    instant      dteday  season  yr  mnth  holiday  weekday  workingday  \
49       50  2011-02-19       1   0     2        0        6           0

    weathersit      temp     atemp       hum  windspeed  casual  registered  \
49           1  0.399167  0.391404  0.187917   0.507463     532        1103

     cnt
49  1635
```

Insight

- Ini merupakan ke anehan jika kita lihat Pada kolom windspeed, kecepatan angin sampai 34 m/s atau 122 KM/jam kalau kita kali m/s nya dengan 67. Itu menunjukan adanya anomali atau outliers karena itu tidak mungkin kecuali memang ada badai. Seperti di tubruk truk toronton. Kita tangani di dta cleaning

---

- **3. Kolom `casual`**

[21]:
```
day_df['casual'].describe()
```

[21]:
```
count     731.000000
mean      848.176471
std       686.622488
min         2.000000
25%       315.500000
50%       713.000000
75%      1096.000000
max      3410.000000
Name: casual, dtype: float64
```

[22]:
```
day_df[day_df['casual'] == 2]
```

[22]:
```
     instant      dteday  season  yr  mnth  holiday  weekday  workingday  \
667      668  2012-10-29       4   1    10        0        1           1

     weathersit  temp   atemp   hum  windspeed  casual  registered  cnt
667           3  0.44  0.4394  0.88     0.3582       2          20   22
```

[23]:
```
day_df[day_df['casual'] == 3410.000000]
```

[23]:
```
     instant      dteday  season  yr  mnth  holiday  weekday  workingday  \
504      505  2012-05-19       2   1     5        0        6           0

     weathersit  temp     atemp      hum  windspeed  casual  registered   cnt
504           1   0.6  0.566908  0.45625   0.083975    3410        4884  8294
```

[24]:
```
day_df[(day_df['mnth'].isin([5, 6, 7, 8]))  &  (day_df['weekday'] == 6)  &␣
↪(day_df['yr'] == 1)]
```

[24]:

	instant	dteday	season	yr	mnth	holiday	weekday	workingday	\
490	491	2012-05-05	2	1	5	0	6	0	
497	498	2012-05-12	2	1	5	0	6	0	
504	505	2012-05-19	2	1	5	0	6	0	
511	512	2012-05-26	2	1	5	0	6	0	
518	519	2012-06-02	2	1	6	0	6	0	
525	526	2012-06-09	2	1	6	0	6	0	
532	533	2012-06-16	2	1	6	0	6	0	
539	540	2012-06-23	3	1	6	0	6	0	
546	547	2012-06-30	3	1	6	0	6	0	
553	554	2012-07-07	3	1	7	0	6	0	
560	561	2012-07-14	3	1	7	0	6	0	
567	568	2012-07-21	3	1	7	0	6	0	
574	575	2012-07-28	3	1	7	0	6	0	
581	582	2012-08-04	3	1	8	0	6	0	
588	589	2012-08-11	3	1	8	0	6	0	
595	596	2012-08-18	3	1	8	0	6	0	
602	603	2012-08-25	3	1	8	0	6	0	

	weathersit	temp	atemp	hum	windspeed	casual	registered	\
490	2	0.621667	0.584608	0.756667	0.152992	2496	4387	
497	1	0.564167	0.544817	0.480417	0.123133	2622	4807	
504	1	0.600000	0.566908	0.456250	0.083975	3410	4884	
511	1	0.692500	0.642696	0.732500	0.198992	2855	3681	
518	1	0.583333	0.566288	0.549167	0.186562	2795	5325	
525	1	0.710833	0.648367	0.437083	0.144287	2708	4790	
532	1	0.631667	0.594708	0.504167	0.166667	2963	4739	
539	1	0.731667	0.652792	0.534583	0.179721	2657	4801	
546	1	0.765000	0.687508	0.601250	0.161071	1455	4232	
553	1	0.861667	0.804913	0.492083	0.163554	1448	3392	
560	2	0.703333	0.666042	0.699167	0.143679	2355	4614	
567	3	0.595833	0.549912	0.865417	0.213300	1264	3195	
574	1	0.755833	0.697604	0.613333	0.157350	2234	4451	
581	1	0.793333	0.751267	0.613333	0.257458	2345	4479	
588	2	0.692500	0.638267	0.732917	0.206479	2247	4052	
595	1	0.678333	0.618071	0.603333	0.177867	2827	5038	
602	2	0.661667	0.618696	0.712917	0.244408	1829	4224	

	cnt
490	6883
497	7429
504	8294
511	6536
518	8120

```
525  7498
532  7702
539  7458
546  5687
553  4840
560  6969
567  4459
574  6685
581  6824
588  6299
595  7865
602  6053
```

Insight Setelah menganalisis lebih dalam dan telah banyak melihat analisis dengan melihat dari bulan, hari dan juga tahun, aku bisa menyimpulkan:

- Aku anggap max pada casual ini merupakan hal yang biasa terjadi, bisa kita lihat saja dengan sabtu sabtu sebelumnya.
- Di dukung dengan hari sabtu dan musim panas.
- Jika aku bisa mengetahui apakah ada events atau tidak nya aku sih bisa 100% yakin nilai tersebut wajar.

Tapi dari sini aku anggap wajar.

- **4. Kolom `registered`**

[25]:
```
day_df['registered'].describe()
```

[25]:
```
count     731.000000
mean     3656.172367
std      1560.256377
min        20.000000
25%      2497.000000
50%      3662.000000
75%      4776.500000
max      6946.000000
Name: registered, dtype: float64
```

[26]:
```
day_df[day_df['registered'] == 6946.000000]
```

[26]:
```
     instant      dteday  season  yr  mnth  holiday  weekday  workingday  \
634      635  2012-09-26       4   1     9        0        3           1

     weathersit   temp     atemp       hum  windspeed  casual  registered  \
634           1  0.635  0.596613  0.630833     0.2444     787        6946

      cnt
```

```
634  7733
```

[27]:
```
day_df[(day_df['mnth'].isin([8, 9, 10,  11]))  &  (day_df['weekday'] == 3)  &␣
↪(day_df['yr'] == 1) & (day_df['season'] == 4) & (day_df['workingday'] == 1) ]
```

[27]:
```
     instant      dteday  season  yr  mnth  holiday  weekday  workingday  \
634      635  2012-09-26       4   1     9        0        3           1
641      642  2012-10-03       4   1    10        0        3           1
648      649  2012-10-10       4   1    10        0        3           1
655      656  2012-10-17       4   1    10        0        3           1
662      663  2012-10-24       4   1    10        0        3           1
669      670  2012-10-31       4   1    10        0        3           1
676      677  2012-11-07       4   1    11        0        3           1
683      684  2012-11-14       4   1    11        0        3           1
690      691  2012-11-21       4   1    11        0        3           1
697      698  2012-11-28       4   1    11        0        3           1

     weathersit      temp     atemp       hum  windspeed  casual  registered  \
634           1  0.635000  0.596613  0.630833   0.244400     787        6946
641           2  0.657500  0.599133  0.793750   0.066546     728        6844
648           1  0.514167  0.503142  0.630833   0.187821     780        6911
655           1  0.455833  0.450108  0.692917   0.101371     979        6482
662           1  0.587500  0.558721  0.636250   0.072779     795        6898
669           2  0.357500  0.361100  0.666667   0.166667     419        5147
676           2  0.295833  0.274621  0.547500   0.304108     326        4709
683           1  0.289167  0.281563  0.552083   0.199625     373        5122
690           1  0.353333  0.364892  0.613750   0.103246     615        4531
697           1  0.296667  0.289762  0.506250   0.210821     198        5062

      cnt
634  7733
641  7572
648  7691
655  7461
662  7693
669  5566
676  5035
683  5495
690  5146
697  5260
```

Insight Jadi setelah aku analisis menggunakan metode yang sama sepreti pada casual/non-member maka aku mengatakan data ini adalah data yang normal, karena:

- Bisa di lihat dari hal yang sama dari rabu rabu pada bulan sebelum dan sesudahnya, nilai nya rata rata hampir sama.
- Di tambah hari itu hari sibuk atau hari kerja.

- Cuaca yang stabil ada cerah ada mendung.
- Suhu yang stabil.

Jadi aku menyimpulkan ini bukan anomali atau outliers, tapi aku masih merasa aneh, kenapa pada index 676, 683, dan 697 saat cuaca berkisar di 12 Celcius dan casual menunjukan nilai yang rendah, tapi kenapa orang orang malah banyak yang berlangganan.

[28]:
```
day_df[(day_df['season'] == 4) & (day_df['temp'] <= 0.3000000)]
```

[28]:

	instant	dteday	season	yr	mnth	holiday	weekday	workingday	\
301	302	2011-10-29	4	0	10	0	6	0	
321	322	2011-11-18	4	0	11	0	5	1	
336	337	2011-12-03	4	0	12	0	6	0	
341	342	2011-12-08	4	0	12	0	4	1	
342	343	2011-12-09	4	0	12	0	5	1	
343	344	2011-12-10	4	0	12	0	6	0	
344	345	2011-12-11	4	0	12	0	0	0	
345	346	2011-12-12	4	0	12	0	1	1	
346	347	2011-12-13	4	0	12	0	2	1	
350	351	2011-12-17	4	0	12	0	6	0	
351	352	2011-12-18	4	0	12	0	0	0	
352	353	2011-12-19	4	0	12	0	1	1	
675	676	2012-11-06	4	1	11	0	2	1	
676	677	2012-11-07	4	1	11	0	3	1	
683	684	2012-11-14	4	1	11	0	3	1	
693	694	2012-11-24	4	1	11	0	6	0	
694	695	2012-11-25	4	1	11	0	0	0	
696	697	2012-11-27	4	1	11	0	2	1	
697	698	2012-11-28	4	1	11	0	3	1	
698	699	2012-11-29	4	1	11	0	4	1	
699	700	2012-11-30	4	1	11	0	5	1	
700	701	2012-12-01	4	1	12	0	6	0	
705	706	2012-12-06	4	1	12	0	4	1	
711	712	2012-12-12	4	1	12	0	3	1	
712	713	2012-12-13	4	1	12	0	4	1	
713	714	2012-12-14	4	1	12	0	5	1	

	weathersit	temp	atemp	hum	windspeed	casual	registered	\
301	3	0.254167	0.227913	0.882500	0.351371	57	570	
321	1	0.274167	0.272721	0.410000	0.168533	245	3147	
336	1	0.299167	0.310604	0.612917	0.095783	706	2908	
341	1	0.265833	0.256938	0.580000	0.240058	150	3172	
342	1	0.290833	0.317542	0.695833	0.082717	261	3359	
343	1	0.275000	0.266412	0.507500	0.233221	502	2688	
344	1	0.220833	0.253154	0.490000	0.066542	377	2366	
345	1	0.238333	0.270196	0.670833	0.063450	143	3167	
346	1	0.282500	0.301138	0.590000	0.140550	155	3368	
350	2	0.258333	0.249371	0.560833	0.243167	275	2464	

351	1	0.238333	0.245579	0.586250	0.169779	220	2211
352	1	0.276667	0.280933	0.637500	0.172896	260	3143
675	1	0.280833	0.281567	0.567083	0.173513	466	5220
676	2	0.295833	0.274621	0.547500	0.304108	326	4709
683	1	0.289167	0.281563	0.552083	0.199625	373	5122
693	1	0.278333	0.248742	0.404583	0.376871	532	1745
694	1	0.245833	0.257583	0.468333	0.150500	309	2115
696	2	0.291667	0.281558	0.786667	0.237562	123	3836
697	1	0.296667	0.289762	0.506250	0.210821	198	5062
698	1	0.280870	0.298422	0.555652	0.115522	243	5080
699	1	0.298333	0.323867	0.649583	0.058471	362	5306
700	2	0.298333	0.316904	0.806667	0.059704	951	4240
705	1	0.255833	0.258204	0.508750	0.174754	340	5035
711	2	0.297500	0.297338	0.538333	0.162937	310	5009
712	1	0.295833	0.294188	0.485833	0.174129	425	5107
713	1	0.281667	0.294192	0.642917	0.131229	429	5182

	cnt
301	627
321	3392
336	3614
341	3322
342	3620
343	3190
344	2743
345	3310
346	3523
350	2739
351	2431
352	3403
675	5686
676	5035
683	5495
693	2277
694	2424
696	3959
697	5260
698	5323
699	5668
700	5191
705	5375
711	5319
712	5532
713	5611

Menurut para riviewer ini aneh gak ya jadi bingung.

- **5. Kolom `cnt`**

[29]:
```
anomali_values = day_df[day_df['cnt'] != day_df['casual'] +␣
↪day_df['registered']]
anomali_values
```

[29]:
```
Empty DataFrame
Columns: [instant, dteday, season, yr, mnth, holiday, weekday, workingday,
weathersit, temp, atemp, hum, windspeed, casual, registered, cnt]
Index: []
```

Insight

- Pada kode ini aku memastikan bahwa total penjumlahan cnt tuh sama dengan casual + registered.

1.4.4 Menilai Data `hour_df`

---

1. Menggali Informasi dengan `.info()`

[30]:
```
hour_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 17379 entries, 0 to 17378
Data columns (total 17 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   instant     17379 non-null  int64
 1   dteday      17379 non-null  object
 2   season      17379 non-null  int64
 3   yr          17379 non-null  int64
 4   mnth        17379 non-null  int64
 5   hr          17379 non-null  int64
 6   holiday     17379 non-null  int64
 7   weekday     17379 non-null  int64
 8   workingday  17379 non-null  int64
 9   weathersit  17379 non-null  int64
 10  temp        17379 non-null  float64
 11  atemp       17379 non-null  float64
 12  hum         17379 non-null  float64
 13  windspeed   17379 non-null  float64
 14  casual      17379 non-null  int64
 15  registered  17379 non-null  int64
 16  cnt         17379 non-null  int64
dtypes: float64(4), int64(12), object(1)
memory usage: 2.3+ MB
```

Insight Disini karena kolom nya sama dengan data day_df maka aku tidak akan menjelaskan nya terlalu details.

- Kolom nya hanya di tambahkan hr.
- Data ini memiliki 17379, waw cukup banyak.
- Tidak ada *Missing Value* yang terjadi disini

Intinya data ini sama hanya berbeda di total baris dan kolom nya saja, permasalahannya juga sama di format yang salah `dteday`.

---

2. Mencari apakah ada `duplicated`.

[31]:
```
print(f'Jumlah data di hour_df yang duplikasi adalah = {hour_df.duplicated().
↪sum()}')
```

```
Jumlah data di hour_df yang duplikasi adalah = 0
```

Insight

- Dengan tidak adanya *Duplicated* dan juga *Missing Value* data ini bisa di anggap bersih.

---

3. Melihat `Statistik Deskriptif` dari hour_df.

[32]:
```
hour_df.describe()
```

[32]:
```
          instant        season            yr          mnth            hr  \
count  17379.0000  17379.000000  17379.000000  17379.000000  17379.000000
mean    8690.0000      2.501640      0.502561      6.537775     11.546752
std     5017.0295      1.106918      0.500008      3.438776      6.914405
min        1.0000      1.000000      0.000000      1.000000      0.000000
25%     4345.5000      2.000000      0.000000      4.000000      6.000000
50%     8690.0000      3.000000      1.000000      7.000000     12.000000
75%    13034.5000      3.000000      1.000000     10.000000     18.000000
max    17379.0000      4.000000      1.000000     12.000000     23.000000

            holiday       weekday    workingday    weathersit          temp  \
count  17379.000000  17379.000000  17379.000000  17379.000000  17379.000000
mean       0.028770      3.003683      0.682721      1.425283      0.496987
std        0.167165      2.005771      0.465431      0.639357      0.192556
min        0.000000      0.000000      0.000000      1.000000      0.020000
25%        0.000000      1.000000      0.000000      1.000000      0.340000
50%        0.000000      3.000000      1.000000      1.000000      0.500000
75%        0.000000      5.000000      1.000000      2.000000      0.660000
max        1.000000      6.000000      1.000000      4.000000      1.000000

              atemp           hum     windspeed        casual    registered  \
count  17379.000000  17379.000000  17379.000000  17379.000000  17379.000000
```

```
mean       0.475775      0.627229      0.190098     35.676218    153.786869
std        0.171850      0.192930      0.122340     49.305030    151.357286
min        0.000000      0.000000      0.000000      0.000000      0.000000
25%        0.333300      0.480000      0.104500      4.000000     34.000000
50%        0.484800      0.630000      0.194000     17.000000    115.000000
75%        0.621200      0.780000      0.253700     48.000000    220.000000
max        1.000000      1.000000      0.850700    367.000000    886.000000

                cnt
count  17379.000000
mean     189.463088
std      181.387599
min        1.000000
25%       40.000000
50%      142.000000
75%      281.000000
max      977.000000
```

Insight

1. Tren Penggunaan Sepeda Berdasarkan Musim

- Rata-rata musim berada di 2.5, yang berarti data cukup merata di semua musim.
- Musim Dingin (season=4) seharusnya memiliki jumlah peminjaman lebih rendah karena cuaca yang lebih ekstrem.
- Musim Panas dan Gugur (season= 2 dan 3) mungkin memiliki peminjaman lebih tinggi karena suhu lebih nyaman untuk bersepeda.

2. Pengaruh Hari Kerja dan Hari Libur

- 68% data adalah hari kerja (workingday = 1), menunjukkan sebagian besar peminjaman terjadi pada weekdays.
- Hari libur (holiday = 1) hanya sekitar 2.8% dari total data, jadi kemungkinan besar peminjaman di hari libur lebih rendah atau hanya menarik bagi non-member.

3. Pengaruh Cuaca terhadap Peminjaman

- Mayoritas data ada di antara cuaca cerah atau hanya berawan dan berkabut saja.
- Kecepatan angin (windspeed) memiliki rata-rata 0.19 (sekitar 12.7 m/s dalam skala asli), yang cukup rendah, sehingga tidak terlalu menghambat peminjaman.
- Kelembaban (hum) cukup tinggi (rata-rata 62.7%), yang bisa mempengaruhi kenyamanan bersepeda.

4. Tren Jam Peminjaman

- Rata-rata jam (hr) = 11.5, menunjukkan kemungkinan puncak peminjaman terjadi menjelang siang.
- Peminjaman bisa lebih rendah di jam malam atau dini hari (jam 0-5) karena aktivitas luar ruangan berkurang.

Dari apa yang aku pelajari aku menemukan keanehan di hour_df ini.

- temp yang menyentuh angka 0.02 atau 0.82 celcius. Ini mungkin masuk akal jika musim sedang winter dan tambahan faktor faktor cuaca lainnya.
- atemp min 0, ini menurut aku kesalahan pengukuran karena tidak mungkin sampai 0 seperti itu.
- hum min 0, seperti yang sudah aku bilang tidak mungkin ada kelembapan yang 0.
- windspeed min = 0 dan max = 0.850700 seperti tidak ada kehidupan dan lanjut di seperti di tabrak mobil toronton tapi dengan angin.
- casual dan registered ini aneh karena = 0, tapi jika memang di jam 12 sampai subuh ngapain juga sepedahan tapi kita tetap analisis.
- cnt seharusnya cnt selaras sama casual dan registered karena kan dia hasil penjumlahan dari kedua kolom tersebut.

---

4. Melihat `Inaccurate Value`, dan `amomali`.

- **1. Kolom `temp`**

[33]:
```
hour_df[hour_df['temp'] == 0.020000        ]
```

[33]:
```
      instant      dteday  season  yr  mnth  hr  holiday  weekday  workingday  \
483       484  2011-01-22       1   0     1   4        0        6           0
484       485  2011-01-22       1   0     1   6        0        6           0
485       486  2011-01-22       1   0     1   7        0        6           0
486       487  2011-01-22       1   0     1   8        0        6           0
504       505  2011-01-23       1   0     1   2        0        0           0
505       506  2011-01-23       1   0     1   3        0        0           0
528       529  2011-01-24       1   0     1   4        0        1           1
529       530  2011-01-24       1   0     1   5        0        1           1
530       531  2011-01-24       1   0     1   6        0        1           1
531       532  2011-01-24       1   0     1   7        0        1           1
8718     8719  2012-01-04       1   1     1   2        0        3           1
8719     8720  2012-01-04       1   1     1   3        0        3           1
8720     8721  2012-01-04       1   1     1   4        0        3           1
8721     8722  2012-01-04       1   1     1   5        0        3           1
8722     8723  2012-01-04       1   1     1   6        0        3           1
8723     8724  2012-01-04       1   1     1   7        0        3           1
8724     8725  2012-01-04       1   1     1   8        0        3           1

      weathersit  temp   atemp   hum  windspeed  casual  registered  cnt
483            2  0.02  0.0152  0.48     0.2985       0           3    3
484            2  0.02  0.0303  0.44     0.2239       0           2    2
485            1  0.02  0.0152  0.44     0.2836       0           8    8
486            1  0.02  0.0000  0.44     0.3284       1          26   27
504            1  0.02  0.0606  0.62     0.1343       3          15   18
505            1  0.02  0.0606  0.62     0.1343       1           4    5
528            1  0.02  0.0606  0.48     0.1343       0           1    1
```

```
529            1  0.02  0.0606  0.48     0.1343       0           5    5
530            1  0.02  0.0758  0.48     0.0896       0          15   15
531            1  0.02  0.1212  0.48     0.0000       5          79   84
8718           1  0.02  0.0152  0.34     0.2836       0           1    1
8719           1  0.02  0.0152  0.34     0.2836       0           1    1
8720           1  0.02  0.0455  0.41     0.1940       0           2    2
8721           1  0.02  0.0455  0.41     0.1940       0          14   14
8722           1  0.02  0.0455  0.41     0.1642       0          59   59
8723           1  0.02  0.0455  0.44     0.1940       1         151  152
8724           1  0.02  0.0606  0.44     0.1343       5         310  315
```

Insight Dari yang telah aku baca pada sumber ini.

- Ternyata di temukan memang pada bulan januari rata rata cuacanya memang berada pada suhu yang rendah malah ada yang sampai minus. Dan rata rata berdasarkan dari jam 2 pagi sampai jam 8 pagi, jadi nilai ini valid menurut aku tidak ada keraguan lagi.

- **2. Kolom `atemp`**

Insight Dari apa yang aku pelajari atemp adalah pengukuran dengan berbasis felling, atau yang harusnya merepresentasikan suhu yang dirasakan oleh kita. Jadi apakah manusia tidak merasakan apapun? aneh bukan?

Jadi aku simpulkan bahwa atemp ini kesalahan pengukuran, karena lihat kolom suhu, kelembapan, dan angin jelas jelas ada loh.

Solusi yang akan aku lakukan dengan menggantikan atemp pada jam yang sama dan musim yang sama saja atau mungkin menggunakan metode interpolasi linear di karenakan data atemp pasti bertahap dari setiap jam dan tidak terlalu berfluktuasi.

- **3. Kolom `hum`**

[34]:
```
hour_df[hour_df['hum'] == 1        ]
```

[34]:
```
       instant      dteday  season  yr  mnth  hr  holiday  weekday  \
26          27  2011-01-02       1   0     1   2        0        0
721        722  2011-02-02       1   0     2  10        0        3
786        787  2011-02-05       1   0     2   5        0        6
787        788  2011-02-05       1   0     2   6        0        6
789        790  2011-02-05       1   0     2   8        0        6
…          …          …     …  ..   …  ..     …        …
16865    16866  2012-12-10       4   1    12  12        0        1
16866    16867  2012-12-10       4   1    12  13        0        1
17025    17026  2012-12-17       4   1    12   4        0        1
17319    17320  2012-12-29       1   1    12  12        0        6
17320    17321  2012-12-29       1   1    12  13        0        6
```

```
       workingday  weathersit  temp   atemp  hum  windspeed  casual  \
26              0           2  0.42  0.4242  1.0     0.2836       1
721             1           2  0.22  0.2727  1.0     0.0000       2
786             0           3  0.20  0.2273  1.0     0.0896       0
787             0           3  0.20  0.2576  1.0     0.0000       0
789             0           3  0.20  0.2273  1.0     0.0896       0
…             …           …   …     …   …         …      …
16865           1           3  0.44  0.4394  1.0     0.2239      23
16866           1           3  0.44  0.4394  1.0     0.2239      30
17025           1           3  0.36  0.3788  1.0     0.0000       2
17319           0           3  0.20  0.2424  1.0     0.0000       5
17320           0           3  0.20  0.2424  1.0     0.0000      13

       registered  cnt
26              8    9
721            59   61
786             9    9
787             4    4
789            10   10
…             …  …
16865         150  173
16866         190  220
17025           3    5
17319          43   48
17320          71   84

[270 rows x 17 columns]
```

Insight

- Menurut aku ini tidak aneh karena memang di dukung oleh suhu yang berawan dan hujan.
- Maka kelembapan segitu masuk akal.

- **5. Kolom `windspeed`**

[35]:
```
hour_df[hour_df['windspeed'] == 0.0        ]
```

[35]:
```
       instant      dteday  season  yr  mnth  hr  holiday  weekday  \
0            1  2011-01-01       1   0     1   0        0        6
1            2  2011-01-01       1   0     1   1        0        6
2            3  2011-01-01       1   0     1   2        0        6
3            4  2011-01-01       1   0     1   3        0        6
4            5  2011-01-01       1   0     1   4        0        6
…        …          …     …  ..   …  ..       …       …
17319    17320  2012-12-29       1   1    12  12        0        6
```

```
17320    17321  2012-12-29       1   1    12  13        0        6
17322    17323  2012-12-29       1   1    12  15        0        6
17330    17331  2012-12-29       1   1    12  23        0        6
17350    17351  2012-12-30       1   1    12  19        0        0

       workingday  weathersit  temp   atemp   hum  windspeed  casual  \
0               0           1  0.24  0.2879  0.81        0.0       3
1               0           1  0.22  0.2727  0.80        0.0       8
2               0           1  0.22  0.2727  0.80        0.0       5
3               0           1  0.24  0.2879  0.75        0.0       3
4               0           1  0.24  0.2879  0.75        0.0       0
…             …           …   …     …   …         …     …
17319           0           3  0.20  0.2424  1.00        0.0       5
17320           0           3  0.20  0.2424  1.00        0.0      13
17322           0           2  0.24  0.2424  0.87        0.0      19
17330           0           2  0.26  0.2424  0.60        0.0       0
17350           0           1  0.34  0.3636  0.61        0.0      16

       registered  cnt
0              13   16
1              32   40
2              27   32
3              10   13
4               1    1
…             …  …
17319          43   48
17320          71   84
17322         110  129
17330          32   32
17350          86  102

[2180 rows x 17 columns]
```

Insight

- Aku setuju sih jika ada jam jam tertentu yang tidak memiliki angin sama sekali tapi 2180 baris ini cukup banyak dan ada kalanya di saat hujan tapi tidak ada angin sekalipun ini aneh sih.

[36]:
```
hour_df[(hour_df['windspeed'] == 0.0) &         (hour_df['weathersit'] == 3)]
```

[36]:
```
       instant      dteday  season  yr  mnth  hr  holiday  weekday  \
142        143  2011-01-07       1   0     1   5        0        5
250        251  2011-01-11       1   0     1  19        0        2
608        609  2011-01-28       1   0     1  14        0        5
692        693  2011-02-01       1   0     2   5        0        2
693        694  2011-02-01       1   0     2   6        0        2
```

```
…        …         …     …  ..   …  ..      …      …
15650    15651  2012-10-19       4   1    10   7        0        5
17025    17026  2012-12-17       4   1    12   4        0        1
17211    17212  2012-12-24       1   1    12  23        0        1
17319    17320  2012-12-29       1   1    12  12        0        6
17320    17321  2012-12-29       1   1    12  13        0        6

       workingday  weathersit  temp   atemp   hum  windspeed  casual  \
142             1           3  0.22  0.2727  0.55        0.0       0
250             1           3  0.16  0.2273  0.93        0.0       0
608             1           3  0.22  0.2727  0.80        0.0       2
692             1           3  0.14  0.2121  0.93        0.0       0
693             1           3  0.14  0.2121  0.93        0.0       0
…           …          …   …     …   …         …     …
15650           1           3  0.54  0.5152  0.94        0.0       5
17025           1           3  0.36  0.3788  1.00        0.0       2
17211           1           3  0.24  0.2879  0.93        0.0       1
17319           0           3  0.20  0.2424  1.00        0.0       5
17320           0           3  0.20  0.2424  1.00        0.0      13

       registered  cnt
142             5    5
250            51   51
608            36   38
692             3    3
693            22   22
…           …  …
15650         149  154
17025           3    5
17211          10   11
17319          43   48
17320          71   84

[117 rows x 17 columns]
```

Insight Aku gak tau kenapa ini bisa nol ada dua kemungkinan:

- Ada Missing Value seebelum proses normalisasi.
- Pengukuran terhalang oleh gedung gedung tinggi di washington.
- Memang kesalahan pengukuran.

Mungkin demi menambahkan wawasan aku, aku bakal gunakan metode interpolasi linear untuk memperbaikinya.

- **6. Kolom `Casual` , `Registered` dan `cnt`**

- **Kolom `casual`.**

[37]:
```
hour_df[hour_df['casual'] == 0]
```

[37]:
```
       instant      dteday  season  yr  mnth  hr  holiday  weekday  \
4            5  2011-01-01       1   0     1   4        0        6
5            6  2011-01-01       1   0     1   5        0        6
29          30  2011-01-02       1   0     1   6        0        0
30          31  2011-01-02       1   0     1   7        0        0
31          32  2011-01-02       1   0     1   8        0        0
…        …          …     …  ..   …  ..      …      …
17338    17339  2012-12-30       1   1    12   7        0        0
17358    17359  2012-12-31       1   1    12   3        0        1
17359    17360  2012-12-31       1   1    12   4        0        1
17360    17361  2012-12-31       1   1    12   5        0        1
17361    17362  2012-12-31       1   1    12   6        0        1

       workingday  weathersit  temp   atemp   hum  windspeed  casual  \
4               0           1  0.24  0.2879  0.75     0.0000       0
5               0           2  0.24  0.2576  0.75     0.0896       0
29              0           3  0.42  0.4242  0.77     0.2985       0
30              0           2  0.40  0.4091  0.76     0.1940       0
31              0           3  0.40  0.4091  0.71     0.2239       0
…           …          …   …     …   …        …      …
17338           0           1  0.24  0.2121  0.56     0.3582       0
17358           1           1  0.16  0.1818  0.59     0.1045       0
17359           1           1  0.14  0.1667  0.69     0.1045       0
17360           1           1  0.16  0.1515  0.64     0.1940       0
17361           1           1  0.16  0.1667  0.64     0.1642       0

       registered  cnt
4               1    1
5               1    1
29              2    2
30              1    1
31              8    8
…           …  …
17338          13   13
17358           1    1
17359           3    3
17360           9    9
17361          40   40

[1581 rows x 17 columns]
```

Insight

- Dengan data sebanyak ini yang mimiliki nilai 0. Maka aku menganggap ini adalah wajar,

karena tidak mungkin di setiap jam selama 2 tahun selalu ada saja peminjam.

- **2. Kolom `Registered`**

[38]:
```
hour_df[hour_df['registered'] == 0]
```

[38]:

	instant	dteday	season	yr	mnth	hr	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual
6	7	2011-01-01	1	0	1	6	0	6	0	1	0.22	0.2727	0.80	0.0000	2
210	211	2011-01-10	1	0	1	1	0	1	1	1	0.12	0.1212	0.50	0.2836	1
598	599	2011-01-28	1	0	1	3	0	5	1	2	0.20	0.2273	0.75	0.1045	1
713	714	2011-02-02	1	0	2	2	0	3	1	3	0.22	0.2273	0.93	0.1343	4
1161	1162	2011-02-21	1	0	2	4	1	1	0	1	0.32	0.3182	0.45	0.1642	1
1365	1366	2011-03-02	1	0	3	4	0	3	1	1	0.20	0.2121	0.75	0.1343	1
1413	1414	2011-03-04	1	0	3	4	0	5	1	2	0.18	0.1818	0.74	0.1940	1
1483	1484	2011-03-07	1	0	3	4	0	1	1	1	0.20	0.1515	0.80	0.5224	1
1505	1506	2011-03-08	1	0	3	2	0	2	1	1	0.24	0.2424	0.52	0.1343	1
1551	1552	2011-03-10	1	0	3	0	0	4	1	3	0.34	0.3182	0.00	0.2537	3
1880	1881	2011-03-24	2	0	3	3	0	4	1	2	0.28	0.2727	1.00	0.1940	1
2023	2024	2011-03-30	2	0	3	4	0	3	1	2	0.32	0.3485	0.57	0.0000	1
2119	2120	2011-04-03	2	0	4	4	0	0	0	1	0.28	0.3030	0.70	0.0896	3
2142	2143	2011-04-04	2	0	4	3	0	1							
3988	3989	2011-06-20	2	0	6	2	0	1							
3989	3990	2011-06-20	2	0	6	3	0	1							
5165	5166	2011-08-08	3	0	8	3	0	1							
5847	5848	2011-09-06	3	0	9	3	0	2							
5989	5990	2011-09-12	3	0	9	2	0	1							
6012	6013	2011-09-13	3	0	9	2	0	2							
6134	6135	2011-09-18	3	0	9	4	0	0							
8626	8627	2011-12-31	1	0	12	5	0	6							
10729	10730	2012-03-28	2	1	3	4	0	3							
16449	16450	2012-11-23	4	1	11	3	0	5							

2142	1	1	0.38	0.3939	0.66	0.2836	1
3988	1	1	0.64	0.5758	0.89	0.0896	2
3989	1	3	0.64	0.5758	0.89	0.0000	1
5165	1	1	0.66	0.5909	0.89	0.0000	1
5847	1	3	0.54	0.5152	0.94	0.2985	1
5989	1	1	0.56	0.5303	0.88	0.0000	2
6012	1	1	0.60	0.5758	0.78	0.0000	2
6134	0	1	0.44	0.4394	0.77	0.2239	1
8626	0	2	0.36	0.3485	0.76	0.2239	1
10729	1	1	0.36	0.3333	0.43	0.2985	1
16449	1	1	0.26	0.3030	0.70	0.0000	1

	registered	cnt
6	0	2
210	0	1
598	0	1
713	0	4
1161	0	1
1365	0	1
1413	0	1
1483	0	1
1505	0	1
1551	0	3
1880	0	1
2023	0	1
2119	0	3
2142	0	1
3988	0	2
3989	0	1
5165	0	1
5847	0	1
5989	0	2
6012	0	2
6134	0	1
8626	0	1
10729	0	1
16449	0	1

Insight Setelah aku analisis dengan seksama aku menemukan bahwa:

- Ini bisa terjadi juga karena berada di rentang jam subuh 1 sampai jam 9.
- Dan sama seperti alasan ku kepada casual selama 2 tahun tidak mungkin selalu ada peminjam di setiap jam.

Jadi kesimpulannya ini angka yang wajar.

- **3. Kolom `cnt`**

[39]:
```
anomali_values_hour = hour_df[hour_df['cnt'] != hour_df['casual']␣
↪+hour_df['registered']]
anomali_values_hour
```

[39]:
```
Empty DataFrame
Columns: [instant, dteday, season, yr, mnth, hr, holiday, weekday, workingday,
weathersit, temp, atemp, hum, windspeed, casual, registered, cnt]
Index: []
```

Insight

- Yang aku lakukan disni sama seperti apa yang aku lakukan kepada `day_df`.

1.4.5 Cleaning Data

1.4.6 Cleaning Data `day_df`

No	Kolom	Permasalahan	Solusi
1	dteday	Format salah, masih berupa objek	Konversi ke datetime
2	Kolom yang di Normalisasi	Mengaganggu analisis	Kembalikan ke bentuk asli
3	hum	Kelembapan minimum 0, yang tidak realistis	Menggunakan interpolasi linear
4	windspeed	Kecepatan angin mencapai 34 m/s atau 122,3 KM/Jam, yang kemungkinan besar merupakan outlier atau anomali	Belum ada solusi
5	-	Mengganti tipe data pada kolom-kolom yang seharusnya kategori	Mengonversinya
6	Semua kolom	Aku berpikir namanya agak aneh dan susah diucapkan	Mengganti namanya
7	-	Jika tidak melakukan binning aku akan kesusahan pada proses EDA	Binning

---

1. Membersihkan `dteday`

[40]:
```
day_df['dteday'] = pd.to_datetime(day_df['dteday'])
```

[41]:
```python
day_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 731 entries, 0 to 730
Data columns (total 16 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   instant     731 non-null    int64
 1   dteday      731 non-null    datetime64[ns]
 2   season      731 non-null    int64
 3   yr          731 non-null    int64
 4   mnth        731 non-null    int64
 5   holiday     731 non-null    int64
 6   weekday     731 non-null    int64
 7   workingday  731 non-null    int64
 8   weathersit  731 non-null    int64
 9   temp        731 non-null    float64
 10  atemp       731 non-null    float64
 11  hum         731 non-null    float64
 12  windspeed   731 non-null    float64
 13  casual      731 non-null    int64
 14  registered  731 non-null    int64
 15  cnt         731 non-null    int64
dtypes: datetime64[ns](1), float64(4), int64(11)
memory usage: 91.5 KB
```

Insight

- Aku melakukan konversi dari data yang salah format nya menjadi benar.

---

2. Kolom yang di `Normalisasi`.

- **Kolom `temp`**

[42]:
```python
# Pada dokumentasi suhu di normalisasi dibagi 41
day_df['temp'] = day_df['temp'] * 41
```

- **Kolom `atemp`**

[43]:
```python
# Pada dokumentasi atemp di normalisasi dengan di bagi 50
day_df['atemp'] = day_df['atemp'] * 50
```

- **Kolom `hum`**

[44]:
```python
# Pada dokumentsai hum di normalisasi dengan di bagi 100
day_df['hum'] = day_df['hum'] * 100
```

- **Kolom `windspeeed`**

[45]:
```
# Pada dokumentasi windspeed di normalisasi dengan di bagi 67
day_df['windspeed'] = day_df['windspeed'] * 67
```

Insight

- Pada kode tersebut aku bertujuan untuk mengganti nilai yang telah di normalisasi menjadi nilai aslinya kembali. Kenapa?
- Ini akan memudahkan aku nantinya di saat proses EDA.
- Menghindari bias karena tidak tau nilai aslinya.

---

3. Membersihkan `hum`

[46]:
```
day_df['hum'] = day_df['hum'].replace(0,  np.nan)
day_df['hum'] = day_df['hum'].interpolate(method='linear')
```

Insight

- Aku menggunakan metode interpolasi linear, mengapa karena jika aku menggunakan median nanti datanya tidak bervariasi dan tidak realistis.
- Interpolasi linear lebih memungkinkan jika data bersifat kontinu atau memiliki urutan yang tidak akan jauh berbeda perubahannya dengan nilai sesudah dan sebelumnya.

Sebelum selsai apakah angka ada yang lebih kecil dari 20%?

[47]:
```
day_df[day_df['hum'] < 20]
```

[47]:
```
    instant     dteday  season  yr  mnth  holiday  weekday  workingday  \
49       50 2011-02-19       1   0     2        0        6           0

    weathersit       temp    atemp      hum  windspeed  casual  registered  \
49           1  16.365847  19.5702  18.7917  34.000021     532        1103

     cnt
49  1635
```

Insight

- Menurut aku ini anomali atau inaccurate value kenapa?
- Casual dan Registered stabil.
- Suhu yang menunjukan 16 Celcius panas dari mana nya coba?

Disini aku memutuskan untuk mengatasinya terlebih dahulu.

[48]:
```
q95_hum_1 = day_df[day_df['season'] == 1]['hum'].quantile(0.95)
day_df.loc[(day_df['season'] == 1) & (day_df['hum'] < 20), 'hum'] = q95_hum_1
```

```
# Memastikan kembali
day_df[day_df['hum'] < 20]
```

[48]:
```
Empty DataFrame
Columns: [instant, dteday, season, yr, mnth, holiday, weekday, workingday,
weathersit, temp, atemp, hum, windspeed, casual, registered, cnt]
Index: []
```

Insight

-

1.5 Jadi kode di atas bertujuan untuk mengisi nilai yang kurang dari 20 di isi menggunakan metode imputation quantile 95.

4. Membersihkkan `windspeed`

[49]:
```
day_df['windspeed'].max()
```

[49]:
```
34.000021
```

Insight

- Inilah alasan aku merubah nya ke nilai asli jadi aku menemukan bahwa nilai maksimum bukan berada pada 122 km/jam lagi tapi di 34 km/jam saja.

Jadi kesimpulannya ini sangat normal.

---

5. Mengganti tipe data yang seharusnya menjadi tipe data `kategorikal` Sebelum menggantinya kita akan mapping dulu

[50]:
```
# 1. Season
day_df['season'] = day_df['season'].map({1: 'Musim Semi', 2: 'Musim Panas', 3:␣
↪'Musim Gugur', 4: 'Musim Dingin'})

# 2. yr
day_df['yr'] = day_df['yr'].map({0: 2011, 1: 2012})

# 3. mnth
day_df['mnth'] = day_df['mnth'].map({
    1: 'Januari',
    2: 'Februari',
    3: 'Maret',
    4: 'April',
    5: 'Mei',
    6: 'Juni',
    7: 'Juli',
```

```
    8: 'Agustus',
    9: 'September',
    10: 'Oktober',
    11: 'November',
    12: 'Desember'
})

# 4. holiday
day_df['holiday'] = day_df['holiday'].map({0: 'Tidak', 1: 'Ya'})

# 5. weekday
day_df['weekday'] = day_df['weekday'].map({
    0: 'Minggu',
    1: 'Senin',
    2: 'Selasa',
    3: 'Rabu',
    4: 'Kamis',
    5: 'Jumat',
    6: 'Sabtu'
})

# 6. workingday
day_df['workingday'] = day_df['workingday'].map({0: 'Tidak', 1: 'Ya'})

# 7. weathersit
day_df['weathersit'] = day_df['weathersit'].map({
    1: 'Cerah/Berawan',
    2: 'Kabut/Berawan',
    3: 'Hujan/Salju Ringan',
    4: 'Hujan Lebat/Salju'
})
```

[51]:
```
kategori_kolom = ['season', 'yr', 'mnth', 'holiday', 'weekday', 'workingday',␣
↪'weathersit']
day_df[kategori_kolom] = day_df[kategori_kolom].astype('category')
```

[52]:
```
day_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 731 entries, 0 to 730
Data columns (total 16 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   instant     731 non-null    int64
 1   dteday      731 non-null    datetime64[ns]
 2   season      731 non-null    category
 3   yr          731 non-null    category
```

```
 4   mnth        731 non-null    category
 5   holiday     731 non-null    category
 6   weekday     731 non-null    category
 7   workingday  731 non-null    category
 8   weathersit  731 non-null    category
 9   temp        731 non-null    float64
 10  atemp       731 non-null    float64
 11  hum         731 non-null    float64
 12  windspeed   731 non-null    float64
 13  casual      731 non-null    int64
 14  registered  731 non-null    int64
 15  cnt         731 non-null    int64
dtypes: category(7), datetime64[ns](1), float64(4), int64(4)
memory usage: 58.0 KB
```

Insight

- Pada kode di atas aku awal awal menggunakan teknik mapping untuk mengkatogorikan nilai numerik kedalam label ini bahasa aku sih gak tau kalau yang sebenarnya hehe.
- Tujuannya untuk memudahkan proses EDA dan fokus untuk mencari sebuah pola.

---

6. Mengganti nama setiap kolom yang susah di rapalkan

[53]:
```
day_df.rename(columns={
    'instant': 'index',
    'dteday': 'Tanggal',
    'season': 'Musim',
    'yr': 'Tahun',
    'mnth': 'Bulan',
    'workingday': 'Kerja',
    'holiday': 'Libur',
    'weekday': 'Hari',
    'weathersit': 'Cuaca',
    'temp': 'Suhu',
    'atemp': 'Suhu_Terasa',
    'hum': 'Kelembapan',
    'windspeed': 'Kecepatan_Angin',
    'casual': 'Non_member',
    'registered': 'Member',
    'cnt': 'Total'
}, inplace=True)
```

[54]:
```
day_df.head()
```

[54]:
```
   index    Tanggal       Musim Tahun    Bulan  Libur    Hari  Kerja  \
0      1 2011-01-01  Musim Semi  2011  Januari  Tidak   Sabtu  Tidak
1      2 2011-01-02  Musim Semi  2011  Januari  Tidak  Minggu  Tidak
```

```
2      3 2011-01-03  Musim Semi  2011  Januari  Tidak   Senin     Ya
3      4 2011-01-04  Musim Semi  2011  Januari  Tidak  Selasa     Ya
4      5 2011-01-05  Musim Semi  2011  Januari  Tidak    Rabu     Ya

           Cuaca       Suhu  Suhu_Terasa  Kelembapan  Kecepatan_Angin  \
0  Kabut/Berawan  14.110847     18.18125     80.5833        10.749882
1  Kabut/Berawan  14.902598     17.68695     69.6087        16.652113
2  Cerah/Berawan   8.050924      9.47025     43.7273        16.636703
3  Cerah/Berawan   8.200000     10.60610     59.0435        10.739832
4  Cerah/Berawan   9.305237     11.46350     43.6957        12.522300

   Non_member  Member  Total
0         331     654    985
1         131     670    801
2         120    1229   1349
3         108    1454   1562
4          82    1518   1600
```

Insight

- Kode tersebut aku temukan di saat dulu aku membaca buku Machine Learning untuk Pemula.
- Kode tersebut mengubah nama dari yang susah menjadi yang aku mengerti, sekaligus saja di jadikan indonesia gak papa kan.
- Tapi kok hari nya nyempil yah aku ubah ah.

[55]:
```
day_df = day_df.reindex(columns=['index', 'Tanggal', 'Musim', 'Tahun', 'Bulan',␣
↪'Hari', 'Libur',
                                 'Kerja', 'Cuaca', 'Suhu', 'Suhu_Terasa',␣
↪'Kelembapan',
                                 'Kecepatan_Angin', 'Non_member', 'Member',␣
↪'Total'])
```

[56]:
```
day_df.head()
```

[56]:
```
   index    Tanggal       Musim Tahun    Bulan    Hari  Libur  Kerja  \
0      1 2011-01-01  Musim Semi  2011  Januari   Sabtu  Tidak  Tidak
1      2 2011-01-02  Musim Semi  2011  Januari  Minggu  Tidak  Tidak
2      3 2011-01-03  Musim Semi  2011  Januari   Senin  Tidak     Ya
3      4 2011-01-04  Musim Semi  2011  Januari  Selasa  Tidak     Ya
4      5 2011-01-05  Musim Semi  2011  Januari    Rabu  Tidak     Ya

           Cuaca       Suhu  Suhu_Terasa  Kelembapan  Kecepatan_Angin  \
0  Kabut/Berawan  14.110847     18.18125     80.5833        10.749882
1  Kabut/Berawan  14.902598     17.68695     69.6087        16.652113
2  Cerah/Berawan   8.050924      9.47025     43.7273        16.636703
3  Cerah/Berawan   8.200000     10.60610     59.0435        10.739832
4  Cerah/Berawan   9.305237     11.46350     43.6957        12.522300
```

```
   Non_member  Member  Total
0         331     654    985
1         131     670    801
2         120    1229   1349
3         108    1454   1562
4          82    1518   1600
```

Insight

- Jadi kode tersebut bertujuan untuk reset index kolom berdasarkan apa yang kita tulis.
- Aku melakukannya agar mudah aku pahami saja.

---

7. Melakukan `Binning`

- **1. Kolom `Suhu_Terasa`.**

[57]:
```
bins_suhu_terasa = [0, 5, 15, 25, 35, float('inf')]
labels_suhu_terasa = ['Sangat Dingin', 'Dingin', 'Nyaman', 'Hangat', 'Panas']
day_df['Kategori_Suhu_Terasa'] = pd.cut(day_df['Suhu_Terasa'],␣
↪bins=bins_suhu_terasa, labels=labels_suhu_terasa, include_lowest=True)
print(f'Jumlah baris setelah melakukan binning suhu terasa adalah␣
↪{len(day_df)}')

# Cek distribusi tiap kategori
day_df['Kategori_Suhu_Terasa'].value_counts().sort_values(ascending=False)
```

```
Jumlah baris setelah melakukan binning suhu terasa adalah 731
```

[57]:
```
Kategori_Suhu_Terasa
Hangat           302
Nyaman           244
Dingin           131
Panas             52
Sangat Dingin      2
Name: count, dtype: int64
```

[58]:
```
day_df.groupby(by='Kategori_Suhu_Terasa', observed=False)['Suhu_Terasa'].
↪describe()
```

[58]:
```
                      count       mean       std       min        25%  \
Kategori_Suhu_Terasa
Sangat Dingin           2.0   4.447718  0.698957   3.95348   4.200599
Dingin                131.0  11.950898  2.313293   5.08290  10.830225
Nyaman                244.0  19.720539  2.796093  15.05625  17.336613
Hangat                302.0  29.909382  2.783315  25.03145  27.360350
Panas                  52.0  36.898661  1.694161  35.10190  35.496513
```

```
                            50%        75%        max
Kategori_Suhu_Terasa
Sangat Dingin          4.447718   4.694836   4.941955
Dingin                12.516950  13.652900  14.962100
Nyaman                19.586250  22.047987  24.936250
Hangat                29.861875  32.413250  34.975400
Panas                 36.458325  37.579175  42.044800
```

[59]:
```
print(f'Apakah ada missing value setelah melakukan binning =␣
↪{day_df["Kategori_Suhu_Terasa"].isna().sum()}')
```

```
Apakah ada missing value setelah melakukan binning = 0
```

- **2. Kolom `Kelembapan`.**

[60]:
```
bins_kelembapan = [0, 40, 60, 75, 85, 100]
labels_kelembapan = ['Kering', 'Nyaman', 'Lembap', 'Sangat Lembap', 'Ekstrem␣
↪Lembap']

day_df['Kategori_Kelembapan'] = pd.cut(day_df['Kelembapan'],␣
↪bins=bins_kelembapan, labels=labels_kelembapan, include_lowest=True)
print(f'Jumlah baris setelah melakukan binning kelembapan adalah {len(day_df)}')

# Cek distribusi tiap kategori
day_df['Kategori_Kelembapan'].value_counts().sort_values(ascending=False)
```

```
Jumlah baris setelah melakukan binning kelembapan adalah 731
```

[60]:
```
Kategori_Kelembapan
Nyaman            292
Lembap            262
Sangat Lembap     104
Ekstrem Lembap     45
Kering             28
Name: count, dtype: int64
```

[61]:
```
day_df.groupby(by='Kategori_Kelembapan', observed=False)['Kelembapan'].
↪describe()
```

[61]:
```
                      count       mean       std      min        25%       50%  \
Kategori_Kelembapan
Kering                 28.0  34.968946  4.223894  25.4167  31.430275  36.02085
Nyaman                292.0  51.444163  5.405278  40.0833  47.767700  51.56250
Lembap                262.0  67.609200  4.220850  60.0417  63.854150  67.75000
Sangat Lembap         104.0  79.570741  3.067244  75.2917  76.645850  79.41665
Ekstrem Lembap         45.0  89.895624  3.079412  85.7500  87.636400  89.52170
```

```
                          75%      max
Kategori_Kelembapan
Kering               38.358225  40.0000
Nyaman               56.184450  60.0000
Lembap               71.215125  74.9583
Sangat Lembap        82.177075  85.0000
Ekstrem Lembap       91.708300  97.2500
```

[62]:
```
print(f'Apakah ada missing value setelah melakukan binning =␣
↪{day_df["Kategori_Kelembapan"].isna().sum()}')
```

```
Apakah ada missing value setelah melakukan binning = 0
```

- **4. Kolom windspeed.**

[63]:
```
bins_angin = [0, 10, 20, 36, ]
labels_angin = ['Tenang', 'Sepoi Sepoi', 'Sedang']

day_df['Kategori_Angin'] = pd.cut(day_df['Kecepatan_Angin'], bins=bins_angin,␣
↪labels=labels_angin, include_lowest=True)
print(f'Jumlah baris setelah melakukan binning kecepatan angin adalah␣
↪{len(day_df)}')

# Cek distribusi tiap kategori
day_df['Kategori_Angin'].value_counts(ascending=False)
```

```
Jumlah baris setelah melakukan binning kecepatan angin adalah 731
```

[63]:
```
Kategori_Angin
Sepoi Sepoi    418
Tenang         242
Sedang          71
Name: count, dtype: int64
```

[64]:
```
day_df.groupby('Kategori_Angin', observed=False)['Kecepatan_Angin'].describe()
```

[64]:
```
                 count       mean       std        min        25%        50%  \
Kategori_Angin
Tenang           242.0   7.490526  1.861746   1.500244   6.177891   7.938093
Sepoi Sepoi      418.0  14.003961  2.635362  10.041357  11.719188  13.812753
Sedang            71.0  23.423665  2.698064  20.125661  21.312566  23.044181

                      75%        max
Kategori_Angin
Tenang           9.000830   9.959014
Sepoi Sepoi     15.781314  19.834479
Sedang          24.583573  34.000021
```

[65]:
```
day_df['Kategori_Angin'].isna().sum()
```

[65]:
```
np.int64(0)
```

Insight

- Setelah aku menggunakan 5 kategori bining ternyata aku menemukan bahwa tidak ada kecepatan angin yang melebihi 36 km/jam jadi aku akan fokus kepada 3 kategori ini saja. Untuk membuktikannya lihat kode di bawah.

[66]:
```
day_df['Kecepatan_Angin'].max()
```

[66]:
```
34.000021
```

[67]:
```
day_df = day_df.reindex(columns=['index', 'Tanggal', 'Musim', 'Tahun', 'Bulan',␣
↪'Hari', 'Libur',
                                 'Kerja', 'Cuaca', 'Suhu', 'Suhu_Terasa',␣
↪'Kategori_Suhu_Terasa', 'Kelembapan',
                                 'Kategori_Kelembapan', 'Kecepatan_Angin',␣
↪'Kategori_Angin',  'Non_member', 'Member', 'Total'])
```

[68]:
```
day_df.head()
```

[68]:
```
   index    Tanggal       Musim Tahun    Bulan    Hari  Libur  Kerja  \
0      1 2011-01-01  Musim Semi  2011  Januari   Sabtu  Tidak  Tidak
1      2 2011-01-02  Musim Semi  2011  Januari  Minggu  Tidak  Tidak
2      3 2011-01-03  Musim Semi  2011  Januari   Senin  Tidak     Ya
3      4 2011-01-04  Musim Semi  2011  Januari  Selasa  Tidak     Ya
4      5 2011-01-05  Musim Semi  2011  Januari    Rabu  Tidak     Ya

           Cuaca       Suhu  Suhu_Terasa Kategori_Suhu_Terasa  Kelembapan  \
0  Kabut/Berawan  14.110847     18.18125               Nyaman     80.5833
1  Kabut/Berawan  14.902598     17.68695               Nyaman     69.6087
2  Cerah/Berawan   8.050924      9.47025               Dingin     43.7273
3  Cerah/Berawan   8.200000     10.60610               Dingin     59.0435
4  Cerah/Berawan   9.305237     11.46350               Dingin     43.6957

  Kategori_Kelembapan  Kecepatan_Angin Kategori_Angin  Non_member  Member  \
0       Sangat Lembap        10.749882    Sepoi Sepoi         331     654
1              Lembap        16.652113    Sepoi Sepoi         131     670
2              Nyaman        16.636703    Sepoi Sepoi         120    1229
3              Nyaman        10.739832    Sepoi Sepoi         108    1454
4              Nyaman        12.522300    Sepoi Sepoi          82    1518

   Total
0    985
1    801
```

```
2    1349
3    1562
4    1600
```

Insigt Pada kesimpulannya aku memlilih kolom kolom di atas untuk dijadikan metode binning, binning tuh cara mengelompokan data yang kontinu dan mengkategotikannya berdasarkan rentang yang sudah di tentukan.

- Kenapa aku memilih kolom Suhu_Terasa Ketimbang Suhu:
- Kalo "Suhu" 25°C tapi lembap, Suhu yang dirasakan manusia bisa terasa 30°C. Orang bakal ngerasa lebih gerah, dan ini bisa ngaruh beda ke keputusan mereka buat nyepeda dibanding kalo cuma liat suhu asli.
- Makanya aku memakai Suhu_Terasa untuk digunakan untuk proses EDA dan visualisasi.
- Suhu_Terasa ini dapat di sebabkan bukan hanya dari faktor suhu asli saja, tapi dari kelembapan dan angin juga.

1.5.1 Cleaning Data `hour_df`

Setelah aku cari cari lagi ternyata banyak jam yang kosong atau dalam 1 hari banyak jam yang loncat misal 1, 2, 3, tiba tiba ke 5. Saya akan atasi.

No	Permasalahan	Solusi
1	Format `dteday` salah (masih objek)	Konversi ke datetime
1	Ada jam yang hilang	belum ada solusi
3	Kolom yang di Normalisasi	Kembalikan ke bentuk asli
4	`atemp` minimum 0, kemungkinan kesalahan pengukuran	Interpolasi linear
5	`windspeed` minimum 0 saat musim hujan dan maksimum terlihat aneh	Interpolasi linear dan belum ada solusi
6	Kolom yang seharusnya kategorikal	Mengubah nya
7	Nama Kolom yang tidak bisa di pahami	Renaming
8	Suhu, Kelembapan dan Angin Susah untuk kita analisis	Binning

---

1. Cleaning `dteday`

[69]:
```
hour_df['dteday'] = pd.to_datetime(hour_df['dteday'])
```

[70]:
```
hour_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 17379 entries, 0 to 17378
Data columns (total 17 columns):
```

```
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   instant     17379 non-null  int64
 1   dteday      17379 non-null  datetime64[ns]
 2   season      17379 non-null  int64
 3   yr          17379 non-null  int64
 4   mnth        17379 non-null  int64
 5   hr          17379 non-null  int64
 6   holiday     17379 non-null  int64
 7   weekday     17379 non-null  int64
 8   workingday  17379 non-null  int64
 9   weathersit  17379 non-null  int64
 10  temp        17379 non-null  float64
 11  atemp       17379 non-null  float64
 12  hum         17379 non-null  float64
 13  windspeed   17379 non-null  float64
 14  casual      17379 non-null  int64
 15  registered  17379 non-null  int64
 16  cnt         17379 non-null  int64
dtypes: datetime64[ns](1), float64(4), int64(12)
memory usage: 2.3 MB
```

Insight

- Ini sama aja seperti apa yang aku lakukan pada day_df.

---

2. Nilai hilang di hr.

[71]:
```
# Membuat kombinasi semua tanggal & jam yang seharusnya ada
full_range = pd.date_range(start=hour_df['dteday'].min(), end=hour_df['dteday'].
 ↪max(), freq='H')

# Cek apakah semua kombinasi ada di dataset
missing_hours = full_range.difference(pd.to_datetime(hour_df['dteday']) + pd.
 ↪to_timedelta(hour_df['hr'], unit='H'))

print(f"Jumlah jam yang hilang: {len(missing_hours)}")
print(missing_hours[:10])
```

```
Jumlah jam yang hilang: 165
DatetimeIndex(['2011-01-02 05:00:00', '2011-01-03 02:00:00',
               '2011-01-03 03:00:00', '2011-01-04 03:00:00',
               '2011-01-05 03:00:00', '2011-01-06 03:00:00',
               '2011-01-07 03:00:00', '2011-01-11 03:00:00',
               '2011-01-11 04:00:00', '2011-01-12 03:00:00'],
              dtype='datetime64[ns]', freq=None)
```

```
<ipython-input-71-0fcfffefbdd1>:2: FutureWarning: 'H' is deprecated and will be
removed in a future version, please use 'h' instead.
  full_range = pd.date_range(start=hour_df['dteday'].min(),
end=hour_df['dteday'].max(), freq='H')
<ipython-input-71-0fcfffefbdd1>:5: FutureWarning: 'H' is deprecated and will be
removed in a future version. Please use 'h' instead of 'H'.
  missing_hours = full_range.difference(pd.to_datetime(hour_df['dteday']) +
pd.to_timedelta(hour_df['hr'], unit='H'))
```

Insight

- Jadi kalau secara ringkas di jelaskan kode tersebut itu bertujuan membantu aku menemukan jam-jam yang tidak ada dalam dataset, supaya aku bisa memutuskan apakah perlu diisi atau tidak.
- Dan kesimpulannya aku ingin mengisinya menggunakan interpolasi linear karena:
- Jam yang hilang sangat banyak 165 totalnya.
- Jam yang hilang tersebar di berbagai tanggal dan paling banyak jika kau lihat pada waktu jam 3 dini hari. Mungkin sistem maintanance who know? anjas kelas.

[72]:
```python
# Menampung jam yang hilang ke dalam sebuah DataFrame
missing_df = pd.DataFrame({'datetime': missing_hours})

# Memisahkan menjadi tanggal dan jam agar sesuai dengan hour_df
missing_df['dteday'] = missing_df['datetime'].dt.date
missing_df['hr'] = missing_df['datetime'].dt.hour

# Konversi dteday ke datetime agar cocok dengan hour_df
missing_df['dteday'] = pd.to_datetime(missing_df['dteday'])

# Kolom yang hilang akan di tandai dengan NaN
for col in hour_df.columns:
    if col not in missing_df.columns:
        missing_df[col] = np.nan  # Isi dengan NaN agar tidak merusak struktur␣
 ↪data

# Penggabungan
hour_df = pd.concat([hour_df, missing_df], ignore_index=True).
 ↪sort_values(by=['dteday', 'hr'])

print(f"Jumlah total baris setelah menambahkan jam yang hilang: {len(hour_df)}")
```

```
Jumlah total baris setelah menambahkan jam yang hilang: 17544
```

Insight

- Dari 165 jam yang hilang aku memutuskan untuk menggunakan interpolasi linear dengan kode yang sedikit membingungkan aku sendiri.

Tapi pada intinya kode ini bisa di jelaskan dengan tujuan nya:

- Tujuan aku membuat missing_df untuk membuat DataFrame yang memuat jam yang hilang itu.
- Terus memastikan format dteday dan hr sesuai dengan hour_df.
- Menambahkan semua kolom yang ada di hour_df ke missing_df menggunakan for statement, yang nantinya kode ini akan diisi dengan NaN agar tidak merusak struktur.
- Menggabungkan missing_df dengan hour_df sehingga dataset memiliki semua jam tanpa celah.

Tapi yang aku bingung mengapa jumlah barisnya bertambah dari yang berasal dari 17379 baris menjadi 17544 baris.

[73]:
```
# crosCek jumlah hari unik dalam dataset
num_days = hour_df['dteday'].nunique()

# Hitung total jam yang seharusnya ada
expected_rows = num_days * 24

print(f"Jumlah hari unik dalam dataset: {num_days}")
print(f"Jumlah baris yang seharusnya ada: {expected_rows}")
print(f"Jumlah baris saat ini: {len(hour_df)}")
```

```
Jumlah hari unik dalam dataset: 731
Jumlah baris yang seharusnya ada: 17544
Jumlah baris saat ini: 17544
```

Insight

- Jumlah baris yang seharusnya ada: 17544 ini menjelaskan bahwa baris memang seharusnya begitu mengapa?
- Setelah aku cari tahu ternyata Dataset Capital Bike Share ini memiliki Tahun Kabisat, berikut Pembuktiannya.

[74]:
```
hour_df['dteday'] = pd.to_datetime(hour_df['dteday'])
hour_df['dteday'].dt.year.value_counts()
```

[74]:
```
dteday
2012    8784
2011    8760
Name: count, dtype: int64
```

Insight Jadi gini aku jelaskan hasil dari apa yang aku maksud:

1. Dataset ini kan mencakup data dari tahun 2011 dan 2012

- Tahun 2011 kan emang harus memiliki 365 hari x 24 jam = 8.760 jam
- Tahun 2012 adalah tahun kabisat, sehingga memiliki 366 hari x 24 jam = 8.784 jam.

2. Mengapa Total jam dalam dataset adalah 17.544?

- Jika dataset hanya mencakup tahun biasa, jumlahnya seharusnya 17.520 jam (2 x 365 x 24)
- Tapi kan karena 2012 adalah tahun kabisat, jumlahnya jadi bertambah 24 jam menjadi 17.544.

Simpelnya:

- 2011 (tahun biasa) = 8.760 jam
- 2012 (tahun kabisat) = 8.784 jam (karena ada 29 Februari)
- Total = 17.544 jam

[75]:
```
# Memastikan kembali
hour_df.isnull().sum()
```

[75]:
```
instant         165
dteday            0
season          165
yr              165
mnth            165
hr                0
holiday         165
weekday         165
workingday      165
weathersit      165
temp            165
atemp           165
hum             165
windspeed       165
casual          165
registered      165
cnt             165
datetime      17379
dtype: int64
```

Insight Walauwe buset buset kalau gitu gausah di tangani dah tapi gak papa ilmu:

- Aku baru menyadari jika baris kita bertabmah karena kita menambahkan jam dengan total 165 baris maka kolom selain dteday dan hr akan memiliki missing value. Karena belum memiliki nilai nya.
- Disini masalah nya aku harus menggunakan apa? karena jika aku sama ratakan menggunakan interpolasi mungkin kolom yang mempunyai data kontinu dan data ordinal akan baik baik saja, tapi berbeda dengan `cnt`, `registered`, dan juga `casual` yang memiliki angka yang sangat berfluktuasi.

Aku akan mengatasi nya nanti aku akan menjelaskan mengapa menggunakan metode tersebut.

[76]:
```
hour_df.head()
```

[76]:
```
   instant     dteday  season   yr  mnth  hr  holiday  weekday  workingday  \
0      1.0 2011-01-01     1.0  0.0   1.0   0      0.0      6.0         0.0
1      2.0 2011-01-01     1.0  0.0   1.0   1      0.0      6.0         0.0
2      3.0 2011-01-01     1.0  0.0   1.0   2      0.0      6.0         0.0
3      4.0 2011-01-01     1.0  0.0   1.0   3      0.0      6.0         0.0
4      5.0 2011-01-01     1.0  0.0   1.0   4      0.0      6.0         0.0
```

```
   weathersit  temp   atemp   hum  windspeed  casual  registered   cnt  \
0         1.0  0.24  0.2879  0.81        0.0     3.0        13.0  16.0
1         1.0  0.22  0.2727  0.80        0.0     8.0        32.0  40.0
2         1.0  0.22  0.2727  0.80        0.0     5.0        27.0  32.0
3         1.0  0.24  0.2879  0.75        0.0     3.0        10.0  13.0
4         1.0  0.24  0.2879  0.75        0.0     0.0         1.0   1.0

  datetime
0      NaT
1      NaT
2      NaT
3      NaT
4      NaT
```

[77]:
```
hour_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 17544 entries, 0 to 17378
Data columns (total 18 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   instant     17379 non-null  float64
 1   dteday      17544 non-null  datetime64[ns]
 2   season      17379 non-null  float64
 3   yr          17379 non-null  float64
 4   mnth        17379 non-null  float64
 5   hr          17544 non-null  int64
 6   holiday     17379 non-null  float64
 7   weekday     17379 non-null  float64
 8   workingday  17379 non-null  float64
 9   weathersit  17379 non-null  float64
 10  temp        17379 non-null  float64
 11  atemp       17379 non-null  float64
 12  hum         17379 non-null  float64
 13  windspeed   17379 non-null  float64
 14  casual      17379 non-null  float64
 15  registered  17379 non-null  float64
 16  cnt         17379 non-null  float64
 17  datetime    165 non-null    datetime64[ns]
dtypes: datetime64[ns](2), float64(15), int64(1)
memory usage: 2.5 MB
```

[78]:
```
hour_df.drop(columns=['datetime'], inplace=True)
```

[79]:
```
hour_df = hour_df.sort_values(['dteday', 'hr'])
hour_df['instant'] = range(1, len(hour_df) + 1)
```

[80]:
```
hour_df['dteday'] = hour_df['dteday'].dt.date
```

[81]:
```
# Mengisi kolom cuaca dengan forward fill
kolom_cuaca = ['temp', 'atemp', 'hum', 'windspeed', 'weathersit']
hour_df[kolom_cuaca] = hour_df[kolom_cuaca].fillna(method='ffill')
```

```
<ipython-input-81-b61f0f6494d4>:3: FutureWarning: DataFrame.fillna with 'method'
is deprecated and will raise in a future version. Use obj.ffill() or obj.bfill()
instead.
  hour_df[kolom_cuaca] = hour_df[kolom_cuaca].fillna(method='ffill')
```

[82]:
```
import holidays  # Library untuk cek hari libur
# Mengatasi kolom kolom kategorikal

# Memastikan dteday dalam format datetime
hour_df['dteday'] = pd.to_datetime(hour_df['dteday'])

# Menghitung ulang kolom tahun bulan dan hari
hour_df['yr'] = hour_df['dteday'].dt.year - 2011  # 0 untuk 2011, 1 untuk 2012
hour_df['mnth'] = hour_df['dteday'].dt.month
hour_df['weekday'] = hour_df['dteday'].dt.weekday

# Menentukan Musim Berdasarkan Bulan
hour_df['season'] = hour_df['mnth'].apply(lambda x: 1 if x in [12, 1, 2] else 2␣
↪if x in [3, 4, 5] else 3 if x in [6, 7, 8] else 4)

# Menentukan holiday
us_holidays = holidays.US()
hour_df['holiday'] = hour_df['dteday'].apply(lambda x: 1 if x in us_holidays␣
↪else 0)

# Menentukan workingday
hour_df['workingday'] = hour_df.apply(lambda row: 0 if row['holiday'] == 1 or␣
↪row['weekday'] in [5, 6] else 1, axis=1)
```

[83]:
```
# Hitung rata-rata per jam dan hari
rata_rata_harian = hour_df.groupby(['hr', 'weekday'])[['casual', 'registered',␣
↪'cnt']].mean().reset_index()

# Fungsi untuk mengisi missing values
def isi_missing(row, avg_df):
    if pd.isna(row['cnt']):
        match = avg_df[(avg_df['hr'] == row['hr']) & (avg_df['weekday'] ==␣
↪row['weekday'])]
        if not match.empty:
            return match[['casual', 'registered', 'cnt']].iloc[0]
    return row[['casual', 'registered', 'cnt']]
```

```
# Terapkan ke data
hour_df[['casual', 'registered', 'cnt']] = hour_df.apply(lambda row:␣
↪isi_missing(row, rata_rata_harian), axis=1)
```

[84]:
```
hour_df.isnull().sum()
```

[84]:
```
instant       0
dteday        0
season        0
yr            0
mnth          0
hr            0
holiday       0
weekday       0
workingday    0
weathersit    0
temp          0
atemp         0
hum           0
windspeed     0
casual        0
registered    0
cnt           0
dtype: int64
```

[85]:
```
kolom_int = ['instant', 'season', 'yr', 'mnth', 'holiday', 'weekday',␣
↪'workingday', 'weathersit', 'casual', 'registered', 'cnt']
hour_df[kolom_int] = hour_df[kolom_int].astype('int64')
```

[86]:
```
print('Total cnt di day_df:', day_df['Total'].sum())
print('Total cnt di hour_df:', hour_df['cnt'].sum())
```

```
Total cnt di day_df: 3292679
Total cnt di hour_df: 3306003
```

[87]:
```
hour_df.head()
```

[87]:
```
   instant     dteday  season  yr  mnth  hr  holiday  weekday  workingday  \
0        1 2011-01-01       1   0     1   0        1        5           0
1        2 2011-01-01       1   0     1   1        1        5           0
2        3 2011-01-01       1   0     1   2        1        5           0
3        4 2011-01-01       1   0     1   3        1        5           0
4        5 2011-01-01       1   0     1   4        1        5           0

   weathersit  temp   atemp   hum  windspeed  casual  registered  cnt
0           1  0.24  0.2879  0.81        0.0       3          13   16
```

1	1	0.22	0.2727	0.80	0.0	8	32	40
2	1	0.22	0.2727	0.80	0.0	5	27	32
3	1	0.24	0.2879	0.75	0.0	3	10	13
4	1	0.24	0.2879	0.75	0.0	0	1	1

Insight Jadi intinya aku mengatasi penambahan baris dan mengisi setiap barisnya menggunakan berbagai metode.

`Instants` - Pada kolom instant kode ini memastikan bahwa hour_df tersusun secara rapih berdasarkan tanggal dan jam, lalu menambahkan indeks unik untuk setiap baris dalam dataset.

`dteday`

- Pada kolom dteday kan itu di bawahnya ada jam tuh, nah makanya aku mengubahnya dengan hanya menampilkan tanggal, bulan, dan tahun saja. Kembali ke setelan pabrik

`temp`, `atemp`, `hum`, `windspeed`, dan `wearhersit`

- Pada kolom ini aku menggunakan metode forward fill, karena yang aku lihat data 165 NaN ini rata rata berada di akhir dan di tengah tengah, jadi aku menggunakan forward fill untuk menentukan angka dari angka sebelumnya.

`yr`, `mnth`, `weekday`, `holiday`, `workingday`, `season`.

- Pada kolom ini intinya aku melakukan:
- penghitung ulang yr, mnth, dan weekday untuk memastikan kategori waktu benar dan relavan.
- Karena musim kan sangat di tentukan oleh bulan maka aku melakukan klasifikasi season berdasarkan bulan.
- Menandai holiday berdasarkan kalender libur nasional AS. Aku menggunakan library holiday nih.
- Dan terakhir menentukan workingday untuk memisahkan hari kerja dan akhir pekan/libur.

`casual`, `registered`, `cnt`.

- Pada kolom kode di atas itu memiliki tujuan untuk:
- Mempertahankan pola peminjaman sepeda yang alami berdasarkan jam dan hari.
- Lebih akurat dibanding sekadar mengganti NaN dengan median atau rata-rata global.
- Mengatasi NaN tanpa mengubah distribusi data secara signifikan.

Dan Walaupun hasilnya ada sedikit perbedaan antara Total Penjumlahan dari day dan hour nya tapi gak papa lah ya pusing akunya hehehe.

---

3. Mengembalikan kolom yang di `normalisasi`.

- **Kolom`temp`**

[88]:
```
# Sama 41
hour_df['temp'] = hour_df['temp'] * 41
```

- **Kolom `atemp`**

[89]:
```
# Sama 50
hour_df['atemp'] = hour_df['atemp'] * 50
```

- **Kolom hum**

[90]:
```
# Sama 100
hour_df['hum'] = hour_df['hum'] * 100
```

- **Kolom windspeed**

[91]:
```
# Sama 67
hour_df['windspeed'] = hour_df['windspeed'] * 67
```

Insight

- Sama seperti apa yang aku lakukan dengan day_df.

---

4. Cleaning atemp

[92]:
```
hour_df[hour_df['atemp'] == 0]
```

[92]:
```
     instant     dteday  season  yr  mnth  hr  holiday  weekday  workingday  \
480      506 2011-01-22       1   0     1   1        0        5           0
486      513 2011-01-22       1   0     1   8        0        5           0

     weathersit  temp  atemp   hum  windspeed  casual  registered  cnt
480           2  1.64    0.0  41.0    26.0027       3           9   12
486           1  0.82    0.0  44.0    22.0028       1          26   27
```

Insight

- Seperti yang aku bilang bahwa, tidak ada atemp yang nilai nya 0, jika ada itu aneh sekali karena setiap manusia pasti merasakan suhu.

Karena jika di hapus sayang, karena akan mempengaruhi hasil maka disini saya akan menggunakan interpolasi linear seperti biasa jika ke data atau nilai yang berurut.

[93]:
```
hour_df['atemp'] = hour_df['atemp'].replace(0, np.nan)
hour_df['atemp'] = hour_df['atemp'].interpolate(method='linear')
```

[94]:
```
# Melihat kembali
hour_df[hour_df['atemp'] == 0]
```

[94]:
```
Empty DataFrame
Columns: [instant, dteday, season, yr, mnth, hr, holiday, weekday, workingday,
weathersit, temp, atemp, hum, windspeed, casual, registered, cnt]
Index: []
```

Insight Mengapa menggunakan interpolasi linear kembali? - Karena interpolasi linear ini sangat cocok dengan data yang berurut arau kontinu. - jika menggunakan median variasi nilai dari atemp itu akan kurang. - Makanya itu aku menggunakan interpolasi linear saja dengan asumsi tidak ada nilai yang signifikan. dari atemp ini

---

5. Membersihkan kolom `windspeed`

- **Kecepatan Angin dengan Nilai `Minimum`.**

[95]:
```
hour_df[hour_df['windspeed'] == 0.0]
```

[95]:
```
       instant     dteday  season  yr  mnth  hr  holiday  weekday  workingday  \
0            1 2011-01-01       1   0     1   0        1        5           0
1            2 2011-01-01       1   0     1   1        1        5           0
2            3 2011-01-01       1   0     1   2        1        5           0
3            4 2011-01-01       1   0     1   3        1        5           0
4            5 2011-01-01       1   0     1   4        1        5           0
…          …          …     …  ..   …  ..      …      …         …
17319    17485 2012-12-29       1   1    12  12        0        5           0
17320    17486 2012-12-29       1   1    12  13        0        5           0
17322    17488 2012-12-29       1   1    12  15        0        5           0
17330    17496 2012-12-29       1   1    12  23        0        5           0
17350    17516 2012-12-30       1   1    12  19        0        6           0

       weathersit   temp   atemp    hum  windspeed  casual  registered  cnt
0               1   9.84  14.395   81.0        0.0       3          13   16
1               1   9.02  13.635   80.0        0.0       8          32   40
2               1   9.02  13.635   80.0        0.0       5          27   32
3               1   9.84  14.395   75.0        0.0       3          10   13
4               1   9.84  14.395   75.0        0.0       0           1    1
…             …     …      …      …         …      …         …   …
17319           3   8.20  12.120  100.0        0.0       5          43   48
17320           3   8.20  12.120  100.0        0.0      13          71   84
17322           2   9.84  12.120   87.0        0.0      19         110  129
17330           2  10.66  12.120   60.0        0.0       0          32   32
17350           1  13.94  18.180   61.0        0.0      16          86  102

[2189 rows x 17 columns]
```

Insight Dari apa yang aku sudah katakan 2180 ini tuh sangat aneh mengapa bisa banyak seperti ini. Tapi ada kemungkinan: Ada kemungkinan nilai 0.0 pada kolom windspeed di hour_df merupakan hasil dari:

1. Kesalahan pengukuran alat atau sensor.
2. Missing value sebelum proses normalisasi.

3. Lokasi pengukuran yang terlindung dari angin (misal, terhalang gedung).
4. Memang tidak ada angin pada saat pengukuran.

Jadi untuk menghindari kesalahan dan pengukuran yang tidak pasti, aku memutuskan untuk memfilter terlebih dahulu seperti ini.

1. Aku tetap menggunakan windspeed yang 0.0
2. Tapi aku tambahkan yang hanya di saat weathersit nya 3 atau lagi hujan.

Karena logika nya masa di saat hujan gak ada angin?

[96]:
```
hour_df[(hour_df['windspeed'] == 0.0) & (hour_df['weathersit'] == 3)]
```

[96]:
```
       instant     dteday  season  yr  mnth  hr  holiday  weekday  workingday  \
142        150 2011-01-07       1   0     1   5        0        4           1
250        260 2011-01-11       1   0     1  19        0        1           1
608        663 2011-01-28       1   0     1  14        0        4           1
692        750 2011-02-01       1   0     2   5        0        1           1
693        751 2011-02-01       1   0     2   6        0        1           1
…          …         …     …  ..   …  ..       …        …           …
15650    15776 2012-10-19       4   1    10   7        0        4           1
17025    17189 2012-12-17       1   1    12   4        0        0           1
17211    17376 2012-12-24       1   1    12  23        0        0           1
17319    17485 2012-12-29       1   1    12  12        0        5           0
17320    17486 2012-12-29       1   1    12  13        0        5           0

       weathersit   temp   atemp    hum  windspeed  casual  registered  cnt
142             3   9.02  13.635   55.0        0.0       0           5    5
250             3   6.56  11.365   93.0        0.0       0          51   51
608             3   9.02  13.635   80.0        0.0       2          36   38
692             3   5.74  10.605   93.0        0.0       0           3    3
693             3   5.74  10.605   93.0        0.0       0          22   22
…           …    …      …      …        …       …          …  …
15650           3  22.14  25.760   94.0        0.0       5         149  154
17025           3  14.76  18.940  100.0        0.0       2           3    5
17211           3   9.84  14.395   93.0        0.0       1          10   11
17319           3   8.20  12.120  100.0        0.0       5          43   48
17320           3   8.20  12.120  100.0        0.0      13          71   84

[117 rows x 17 columns]
```

Insight Aku dengan kebingungan menganggap saja bahwa windspeed 0.0 di saat weathersit 3 (hujan ringan) adalah anomali atau outliers. Karena alasannya:

1. Hujan selalu mendatangkan angin, atau ada suatu waktu hujan itu di bawa angin, jadi meskipun hujan ringan, tapi menurut aku gak ada mungkin jika sampai benar benar 0 yang artinya tidak adanya angin
2. Di lihat dari mean dan median nya windspeed di saat hujan, aku bisa menyimpulkan bahwa saat hujan pun mean dan median malah tidak ada yang 0.0, yang menunjukan bahwa ini

tidak mewakili nilai yang sebenarnya di saat hujan.

Jadi aku akan menggunakan interpolasi kembali.

[97]:
```
hour_df.loc[(hour_df['windspeed'] == 0.0) & (hour_df['weathersit'] == 3),␣
↪'windspeed'] = np.nan
hour_df['windspeed'] = hour_df['windspeed'].interpolate(method='linear')
```

[98]:
```
hour_df[(hour_df['windspeed'] == 0.0) & (hour_df['weathersit'] == 3)]
```

[98]:

	instant	dteday	season	yr	mnth	hr	holiday	weekday	workingday	\
692	750	2011-02-01	1	0	2	5	0	1	1	
693	751	2011-02-01	1	0	2	6	0	1	1	
694	752	2011-02-01	1	0	2	7	0	1	1	
695	753	2011-02-01	1	0	2	8	0	1	1	
5885	5994	2011-09-07	4	0	9	17	0	2	1	
5886	5995	2011-09-07	4	0	9	18	0	2	1	
6254	6365	2011-09-23	4	0	9	4	0	4	1	
6510	6621	2011-10-03	4	0	10	20	0	0	1	
15259	15385	2012-10-03	4	1	10	0	0	2	1	
15283	15409	2012-10-04	4	1	10	0	0	3	1	
17025	17189	2012-12-17	1	1	12	4	0	0	1	

	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
692	3	5.74	10.605	93.0	0.0	0	3	3
693	3	5.74	10.605	93.0	0.0	0	22	22
694	3	6.56	11.365	93.0	0.0	0	52	52
695	3	6.56	11.365	93.0	0.0	3	132	135
5885	3	26.24	28.790	89.0	0.0	21	264	285
5886	3	26.24	28.790	89.0	0.0	18	219	237
6254	3	24.60	25.000	100.0	0.0	6	7	13
6510	3	16.40	20.455	82.0	0.0	13	191	204
15259	3	25.42	27.275	94.0	0.0	5	47	52
15283	3	26.24	28.790	89.0	0.0	11	65	76
17025	3	14.76	18.940	100.0	0.0	2	3	5

Insight

- Ya berhasil deh. Setelah aku menangani nya dengan memfilternya, tapi bisa kita lihat masih banyak yang 0 dan aku tidak tau kenapa.
- Semoga riviewer membaca ini dan menjelaskanya.

- **Kecepatan Angin dengan Nilai `Maksimum`.**

[99]:
```
hour_df[hour_df['windspeed'] == 56.996900000000004]
```

[99]:

```
      instant     dteday  season  yr  mnth  hr  holiday  weekday  workingday  \
4315     4410 2011-07-03       3   0     7  17        0        6           0
4316     4411 2011-07-03       3   0     7  18        0        6           0

      weathersit  temp  atemp   hum  windspeed  casual  registered  cnt
4315           3  32.8  37.12  49.0    56.9969     181         177  358
4316           3  32.8  37.12  49.0    56.9969      74         107  181
```

Insight Setelah aku melihat langsung dari `website` weatherspark dapat aku simpulkan:

- Nilai ini tidak anomali, website tersebut menunjukan bahwa angin di tanggal 3 Juli 2011 di temukan bahwa kecepatan angin sampai kepada angka `60 KPH` (96 Km/Jam) dan hembusan nya mencapai `80 KPH` atau 128 Km/Jam .
- Tapi mungkin berbeda aku juga gak tau kenapa tapi menunjukan bahwa data dari website tersebut bisa menjawab kebingungan yang melanda.

Jadi dengan adanya data tersebut dapat aku simpulkan memang ini nyata langung di lihat dari website resminya.

---

6. Kolom yang seharusnya `kategorikal`.

[100]:

```
# Mapping dulu
# 1. Season
hour_df['season'] = hour_df['season'].map({1: 'Musim Semi', 2: 'Musim Panas', 3:
 ↪ 'Musim Gugur', 4: 'Musim Dingin'})

# 2. yr
hour_df['yr'] = hour_df['yr'].map({0: 2011, 1: 2012})

# 3. mnth
hour_df['mnth'] = hour_df['mnth'].map({
    1: 'Januari',
    2: 'Februari',
    3: 'Maret',
    4: 'April',
    5: 'Mei',
    6: 'Juni',
    7: 'Juli',
    8: 'Agustus',
    9: 'September',
    10: 'Oktober',
    11: 'November',
    12: 'Desember'
})

# 4. holiday
hour_df['holiday'] = hour_df['holiday'].map({0: 'Tidak', 1: 'Ya'})
```

```python
# 5. weekday
hour_df['weekday'] = hour_df['weekday'].map({
    0: 'Minggu',
    1: 'Senin',
    2: 'Selasa',
    3: 'Rabu',
    4: 'Kamis',
    5: 'Jumat',
    6: 'Sabtu'
})

# 6. workingday
hour_df['workingday'] = hour_df['workingday'].map({0: 'Tidak', 1: 'Ya'})

# 7. weathersit
hour_df['weathersit'] = hour_df['weathersit'].map({
    1: 'Cerah/Berawan',
    2: 'Kabut/Berawan',
    3: 'Hujan/Salju Ringan',
    4: 'Hujan Lebat/Salju'
})
```

[101]:
```python
kategori_kolom = ['season', 'yr', 'mnth', 'holiday', 'weekday', 'workingday',␣
↪'weathersit']
hour_df[kategori_kolom] = hour_df[kategori_kolom].astype('category')
```

[102]:
```python
hour_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 17544 entries, 0 to 17378
Data columns (total 17 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   instant     17544 non-null  int64
 1   dteday      17544 non-null  datetime64[ns]
 2   season      17544 non-null  category
 3   yr          17544 non-null  category
 4   mnth        17544 non-null  category
 5   hr          17544 non-null  int64
 6   holiday     17544 non-null  category
 7   weekday     17544 non-null  category
 8   workingday  17544 non-null  category
 9   weathersit  17544 non-null  category
 10  temp        17544 non-null  float64
 11  atemp       17544 non-null  float64
 12  hum         17544 non-null  float64
```

```
 13  windspeed   17544 non-null  float64
 14  casual      17544 non-null  int64
 15  registered  17544 non-null  int64
 16  cnt         17544 non-null  int64
dtypes: category(7), datetime64[ns](1), float64(4), int64(5)
memory usage: 1.6 MB
```

Insight Sama seperti apa yang aku lakukan pada day_df

7. Renaming Kolom

[103]:
```
hour_df.rename(columns={
    'instant': 'index',
    'dteday': 'Tanggal',
    'season': 'Musim',
    'yr': 'Tahun',
    'mnth': 'Bulan',
    'hr': 'Jam',
    'workingday': 'Kerja',
    'holiday': 'Libur',
    'weekday': 'Hari',
    'weathersit': 'Cuaca',
    'temp': 'Suhu',
    'atemp': 'Suhu_Terasa',
    'hum': 'Kelembapan',
    'windspeed': 'Kecepatan_Angin',
    'casual': 'Non_member',
    'registered': 'Member',
    'cnt': 'Total'
}, inplace=True)

print(hour_df.columns)
```

```
Index(['index', 'Tanggal', 'Musim', 'Tahun', 'Bulan', 'Jam', 'Libur', 'Hari',
       'Kerja', 'Cuaca', 'Suhu', 'Suhu_Terasa', 'Kelembapan',
       'Kecepatan_Angin', 'Non_member', 'Member', 'Total'],
      dtype='object')
```

[104]:
```
hour_df.head()
```

[104]:
```
   index    Tanggal       Musim Tahun    Bulan  Jam Libur   Hari  Kerja  \
0      1 2011-01-01  Musim Semi  2011  Januari    0    Ya  Jumat  Tidak
1      2 2011-01-01  Musim Semi  2011  Januari    1    Ya  Jumat  Tidak
2      3 2011-01-01  Musim Semi  2011  Januari    2    Ya  Jumat  Tidak
3      4 2011-01-01  Musim Semi  2011  Januari    3    Ya  Jumat  Tidak
4      5 2011-01-01  Musim Semi  2011  Januari    4    Ya  Jumat  Tidak

            Cuaca  Suhu  Suhu_Terasa  Kelembapan  Kecepatan_Angin  Non_member  \
```

```
0  Cerah/Berawan  9.84       14.395        81.0              0.0           3
1  Cerah/Berawan  9.02       13.635        80.0              0.0           8
2  Cerah/Berawan  9.02       13.635        80.0              0.0           5
3  Cerah/Berawan  9.84       14.395        75.0              0.0           3
4  Cerah/Berawan  9.84       14.395        75.0              0.0           0

   Member  Total
0      13     16
1      32     40
2      27     32
3      10     13
4       1      1
```

Insight

- Sama seperti apa yang aku lakukan kepada yang day_df.

---

8. Melakukan Binning

- **1. Kolom Suhu_Terasa.**

[105]:
```
bins_suhu_terasa_hour = [0, 5, 15, 25, 35, float('inf')]
labels_suhu_terasa_hour = ['Sangat Dingin', 'Dingin', 'Nyaman', 'Hangat',␣
↪'Panas']
hour_df['Kategori_Suhu_Terasa'] = pd.cut(hour_df['Suhu_Terasa'],␣
↪bins=bins_suhu_terasa_hour, labels=labels_suhu_terasa_hour,␣
↪include_lowest=True)
print(f'Jumlah baris setelah melakukan binning suhu terasa adalah␣
↪{len(hour_df)}')

# Cek distribusi tiap kategori
hour_df['Kategori_Suhu_Terasa'].value_counts().sort_values(ascending=False)
```

```
Jumlah baris setelah melakukan binning suhu terasa adalah 17544
```

[105]:
```
Kategori_Suhu_Terasa
Hangat           6599
Nyaman           6310
Dingin           3216
Panas            1337
Sangat Dingin      82
Name: count, dtype: int64
```

[106]:
```
hour_df.groupby(by='Kategori_Suhu_Terasa', observed=False)['Suhu'].describe()
```

[106]:

Kategori_Suhu_Terasa	count	mean	std	min	25%	50%	75%	max
Sangat Dingin	82.0	2.730000	1.497413	0.82	1.64	2.46	4.10	5.74
Dingin	3216.0	9.537600	2.774812	0.82	8.20	9.84	10.66	35.26
Nyaman	6310.0	16.728910	2.867335	10.66	13.94	16.40	18.86	24.60
Hangat	6599.0	26.488150	2.712591	22.14	24.60	26.24	28.70	33.62
Panas	1337.0	33.621227	2.153449	29.52	31.98	33.62	35.26	41.00

[107]:
```
print(f'Jumlah Missing Value sesudah melakukan binning =␣
↪{hour_df["Kategori_Suhu_Terasa"].isna().sum()}')
```

```
Jumlah Missing Value sesudah melakukan binning = 0
```

- **2. Kolom Kelembapan**

[108]:
```
bins_kelembapan_hour = [0, 40, 60, 75, 85, 100]
labels_kelembapan_hour = ['Kering', 'Nyaman', 'Lembap', 'Sangat Lembap',␣
↪'Ekstrem Lembap']

hour_df['Kategori_Kelembapan'] = pd.cut(hour_df['Kelembapan'],␣
↪bins=bins_kelembapan_hour, labels=labels_kelembapan_hour,␣
↪include_lowest=True)
print(f'Jumlah baris setelah melakukan binning kelembapan adalah␣
↪{len(hour_df)}')

# Cek distribusi tiap kategori
hour_df['Kategori_Kelembapan'].value_counts().sort_values(ascending=False)
```

```
Jumlah baris setelah melakukan binning kelembapan adalah 17544
```

[108]:
```
Kategori_Kelembapan
Nyaman            5522
Lembap            4237
Ekstrem Lembap    2738
Sangat Lembap     2565
Kering            2482
Name: count, dtype: int64
```

[109]:
```
hour_df.groupby(by='Kategori_Kelembapan', observed=False)['Kelembapan'].
↪describe()
```

[109]:

```
                       count       mean       std   min   25%   50%   75%  \
Kategori_Kelembapan
Kering                2482.0  32.658743  6.498751   0.0  29.0  34.0  37.0
Nyaman                5522.0  50.602680  5.692671  41.0  46.0  51.0  55.0
Lembap                4237.0  67.931791  4.337870  61.0  65.0  68.0  72.0
Sangat Lembap         2565.0  80.194542  2.594691  76.0  78.0  81.0  83.0
Ekstrem Lembap        2738.0  90.949233  4.102627  86.0  88.0  89.0  94.0

                        max
Kategori_Kelembapan
Kering                 40.0
Nyaman                 60.0
Lembap                 75.0
Sangat Lembap          85.0
Ekstrem Lembap        100.0
```

[110]:

```
print(f'Jumlah Missing Value sesudah melakukan binning =␣
↪{hour_df["Kategori_Kelembapan"].isna().sum()}')
```

```
Jumlah Missing Value sesudah melakukan binning = 0
```

- **3. Kolom `Kecepatan_Angin`.**

[111]:

```
bins_angin_hour = [0, 10, 20, 36, hour_df['Kecepatan_Angin'].max()]
labels_angin_hour = ['Tenang', 'Sepoi Sepoi', 'Sedang', 'Kencang']

hour_df['Kategori_Angin'] = pd.cut(hour_df['Kecepatan_Angin'],␣
↪bins=bins_angin_hour, labels=labels_angin_hour, include_lowest=True)
print(f'Jumlah baris setelah melakukan binning kecepatan angin adalah␣
↪{len(hour_df)}')

# Cek distribusi tiap kategori
hour_df['Kategori_Angin'].value_counts().sort_values(ascending=False)
```

```
Jumlah baris setelah melakukan binning kecepatan angin adalah 17544
```

[111]:

```
Kategori_Angin
Sepoi Sepoi    8081
Tenang         6973
Sedang         2329
Kencang         161
Name: count, dtype: int64
```

[112]:

```
hour_df.groupby(by='Kategori_Angin', observed=False)['Kecepatan_Angin'].
↪describe()
```

[112]:

```
                  count       mean       std        min       25%       50%  \
Kategori_Angin
```

```
Tenang          6973.0   5.201402  3.558666   0.000000   0.0000   6.0032
Sepoi Sepoi     8081.0  15.088674  3.076930  10.333633  12.9980  15.0013
Sedang          2329.0  26.056064  3.691255  22.002800  22.0028  26.0027
Kencang          161.0  41.955608  5.785278  36.997400  39.0007  39.0007

                    75%       max
Kategori_Angin
Tenang           8.9981   9.99975
Sepoi Sepoi     16.9979  19.99950
Sedang          27.9993  35.00080
Kencang         43.0006  56.99690
```

[113]:
```
print(f'Jumlah Missing Value sesudah melakukan binning =␣
↪{hour_df["Kategori_Angin"].isna().sum()}')
```

```
Jumlah Missing Value sesudah melakukan binning = 0
```

- **4. Kolom Jam.**

[114]:
```
bins_jam = [0, 5, 11, 15, 18, 23]
labels_jam = ['Dini Hari', 'Pagi', 'Siang', 'Sore', 'Malam']

hour_df['Kategori_Jam'] = pd.cut(hour_df['Jam'], bins=bins_jam,␣
↪labels=labels_jam, include_lowest=True)

print(f'Jumlah baris setelah melakukan binning jam adalah {len(hour_df)}')

# Cek distribusi tiap kategori
hour_df['Kategori_Jam'].value_counts().sort_values(ascending=False)
```

```
Jumlah baris setelah melakukan binning jam adalah 17544
```

[114]:
```
Kategori_Jam
Dini Hari    4386
Pagi         4386
Malam        3655
Siang        2924
Sore         2193
Name: count, dtype: int64
```

[115]:
```
hour_df.groupby(by='Kategori_Jam', observed=False)['Jam'].describe()
```

[115]:
```
               count  mean       std   min    25%   50%    75%   max
Kategori_Jam
Dini Hari     4386.0   2.5  1.708020   0.0   1.00   2.5   4.00   5.0
Pagi          4386.0   8.5  1.708020   6.0   7.00   8.5  10.00  11.0
Siang         2924.0  13.5  1.118225  12.0  12.75  13.5  14.25  15.0
Sore          2193.0  17.0  0.816683  16.0  16.00  17.0  18.00  18.0
```

```
Malam         3655.0  21.0  1.414407  19.0  20.00  21.0  22.00  23.0
```

[116]:
```python
hour_df['Kategori_Jam'].isna().sum()
```

[116]:
```
np.int64(0)
```

[117]:
```python
hour_df = hour_df.reindex(columns=['index', 'Tanggal', 'Musim', 'Tahun',␣
↪'Bulan', 'Hari', 'Jam', 'Kategori_Jam', 'Libur',
                                   'Kerja', 'Cuaca', 'Suhu', 'Suhu_Terasa',␣
↪'Kategori_Suhu_Terasa', 'Kelembapan',
                                   'Kategori_Kelembapan', 'Kecepatan_Angin',␣
↪'Kategori_Angin',  'Non_member', 'Member', 'Total'])
```

[118]:
```python
hour_df.head()
```

[118]:
```
   index    Tanggal       Musim Tahun    Bulan   Hari  Jam Kategori_Jam Libur  \
0      1 2011-01-01  Musim Semi  2011  Januari  Jumat    0    Dini Hari    Ya
1      2 2011-01-01  Musim Semi  2011  Januari  Jumat    1    Dini Hari    Ya
2      3 2011-01-01  Musim Semi  2011  Januari  Jumat    2    Dini Hari    Ya
3      4 2011-01-01  Musim Semi  2011  Januari  Jumat    3    Dini Hari    Ya
4      5 2011-01-01  Musim Semi  2011  Januari  Jumat    4    Dini Hari    Ya

   Kerja  …  Suhu  Suhu_Terasa  Kategori_Suhu_Terasa Kelembapan  \
0  Tidak  …  9.84       14.395                Dingin       81.0
1  Tidak  …  9.02       13.635                Dingin       80.0
2  Tidak  …  9.02       13.635                Dingin       80.0
3  Tidak  …  9.84       14.395                Dingin       75.0
4  Tidak  …  9.84       14.395                Dingin       75.0

   Kategori_Kelembapan Kecepatan_Angin  Kategori_Angin Non_member  Member  \
0        Sangat Lembap             0.0          Tenang          3      13
1        Sangat Lembap             0.0          Tenang          8      32
2        Sangat Lembap             0.0          Tenang          5      27
3               Lembap             0.0          Tenang          3      10
4               Lembap             0.0          Tenang          0       1

   Total
0     16
1     40
2     32
3     13
4      1

[5 rows x 21 columns]
```

Insight

- Sama Seperti apa yang telah aku lakukan terhadap day_df.
-

1.6 Tapi ada sedikit penambahan di jam nya.

1.7 Exploratory Data Analysis (EDA)

Roadmap Eksplorasi Data (EDA) `day_df`

No	Aspek EDA	Detail Analisis
1	**Distribusi Data**	- Cek distribusi jumlah peminjaman sepeda (`Total`). - Lihat distribusi berdasarkan `Musim`, `Bulan`, dan `Hari`.
2	**Korelasi Antar Variabel**	- Hitung korelasi antara `Suhu`, `Kelembapan`, `Kecepatan Angin`, dan `Cuaca` dengan `Total`. - Cek apakah suhu tinggi meningkatkan peminjaman atau curah hujan menurunkannya.
3	**Pola Harian & Mingguan**	- Bandingkan pola **hari kerja vs akhir pekan** untuk tahun 2011 & 2012.
4	**Perbandingan Tahun 2011 vs 2012**	- Bandingkan total peminjaman **antar tahun** untuk melihat peningkatan atau penurunan.

---

1. Distribusi Data `day_df`

- **Melihat Distribusi jumlah peminjaman sepeda (`Total`)**

[119]:
```
day_df['Total'].describe()
```

[119]:
```
count     731.000000
mean     4504.348837
std      1937.211452
min        22.000000
25%      3152.000000
50%      4548.000000
```

```
75%      5956.000000
max      8714.000000
Name: Total, dtype: float64
```

Insight Dari yang aku lihat aku bisa mendapatkan.

- Pada `2 Tahun` data ini dikumpulkan ditemukan bahwa, rata rata Peminjaman sepeda Perhari ada di angka 4.504 Peminjaman, dan ini adalah angka yang cukup stabil, karena bisa kita lihat kebutuhan transportasi umum di `washington DC`secara real memang banyak.
- `Standar deviasi` berada di angka 1.937 Peminjaman. Ini menunjukan bahwa penyewaan dalam `2 Tahun` ini berfluktuasi, dan setelah saya cek di cleaning data ini memang normal, karena saat lonjakan tersebut `rata rata` ada di `musim panas` dan `musim gurgur`, dengan `cuaca`, `suhu`, `kelembapan` dan, `kecepatan angin` yang relatif sangat baik, serta banyak lonjakan tersebut ada di hari `sabtu` dan `minggu`.
- Ada hari dimana peminjaman perhari nya ini hanya berjumlah `minimum` 22 Peminjaman dan `maksimum` 8.714 Peminjaman, tapi bisa di konfirmasi setelah aku `eksplorasi` kembali karena menurut aku ini sedikit aneh.
- Mayoritas Peminjam harian berada di antara 3.152 - 5.956 Peminjaman. Bisa di lihat di Q1 (25%) dan Q3(75%), dan ini juga menunjukan bahwa data ini distribusi nya ke kanan atau right-skewed.

- **Melihat distribusi berdasarkan, `Musim`, `Bulan`, dan `Hari` berdasarkan `Total` pada`day.csv`.**

`Berdasarkan Musim`

[120]:
```
day_df.groupby(by='Musim', observed=False).agg({
    'Total' : ['mean', 'min', 'median', 'max', 'std']})
```

[120]:

	Total				
	mean	min	median	max	std
Musim					
Musim Dingin	4728.162921	22	4634.5	8555	1699.615261
Musim Gugur	5644.303191	1115	5353.5	8714	1459.800381
Musim Panas	4992.331522	795	4941.5	8362	1695.977235
Musim Semi	2604.132597	431	2209.0	7836	1399.942119

Insight Dapat aku simpulkan bahwa:

- Sebelum aku melanjutkan ekplorasi ini aku merasa aneh mengapa musim dingin sangat tinggi sedangkan musim semi sangat rendah. apakah ada kesalahan dari musim atau tanggalnya, karena ini sangat aneh

[121]:
```
day_df[day_df['Total'] == 8555]
```

[121]:

```
     index    Tanggal         Musim Tahun      Bulan   Hari  Libur  Kerja  \
637    638 2012-09-29  Musim Dingin  2012  September  Sabtu  Tidak  Tidak

             Cuaca     Suhu  Suhu_Terasa Kategori_Suhu_Terasa  Kelembapan  \
637  Cerah/Berawan  22.2425      26.5148               Hangat     54.2917

    Kategori_Kelembapan  Kecepatan_Angin Kategori_Angin  Non_member  Member  \
637              Nyaman        15.249468    Sepoi Sepoi        2589    5966

     Total
637   8555
```

Insight Setelah aku analisis lebih dalam aku menemukan bahwa faktanya:

- Pada umumnya menurut sumber internet, 29 September 2012 seharusnya musim gugur, tapi mengapa di catat sebagai musim dingin.
- Faktor utama lonjakan ini adalah cuaca cerah, suhu nyaman (22°C), kelembapan 54%, dan angin ringan (15 km/jam) yang mirip dengan rata rata di Musim Panas dan Musim Semi.

Waduh kenapa aku baru menyadari nya disini.

[122]:

```
day_df[day_df['Bulan'] == 'September'][['Tanggal', 'Musim', 'Total']]
```

[122]:

```
        Tanggal         Musim  Total
243 2011-09-01   Musim Gugur   5115
244 2011-09-02   Musim Gugur   4727
245 2011-09-03   Musim Gugur   4484
246 2011-09-04   Musim Gugur   4940
247 2011-09-05   Musim Gugur   3351
248 2011-09-06   Musim Gugur   2710
249 2011-09-07   Musim Gugur   1996
250 2011-09-08   Musim Gugur   1842
251 2011-09-09   Musim Gugur   3544
252 2011-09-10   Musim Gugur   5345
253 2011-09-11   Musim Gugur   5046
254 2011-09-12   Musim Gugur   4713
255 2011-09-13   Musim Gugur   4763
256 2011-09-14   Musim Gugur   4785
257 2011-09-15   Musim Gugur   3659
258 2011-09-16   Musim Gugur   4760
259 2011-09-17   Musim Gugur   4511
260 2011-09-18   Musim Gugur   4274
261 2011-09-19   Musim Gugur   4539
262 2011-09-20   Musim Gugur   3641
263 2011-09-21   Musim Gugur   4352
264 2011-09-22   Musim Gugur   4795
265 2011-09-23  Musim Dingin   2395
266 2011-09-24  Musim Dingin   5423
```

```
267 2011-09-25  Musim Dingin   5010
268 2011-09-26  Musim Dingin   4630
269 2011-09-27  Musim Dingin   4120
270 2011-09-28  Musim Dingin   3907
271 2011-09-29  Musim Dingin   4839
272 2011-09-30  Musim Dingin   5202
609 2012-09-01   Musim Gugur   6140
610 2012-09-02   Musim Gugur   5810
611 2012-09-03   Musim Gugur   6034
612 2012-09-04   Musim Gugur   6864
613 2012-09-05   Musim Gugur   7112
614 2012-09-06   Musim Gugur   6203
615 2012-09-07   Musim Gugur   7504
616 2012-09-08   Musim Gugur   5976
617 2012-09-09   Musim Gugur   8227
618 2012-09-10   Musim Gugur   7525
619 2012-09-11   Musim Gugur   7767
620 2012-09-12   Musim Gugur   7870
621 2012-09-13   Musim Gugur   7804
622 2012-09-14   Musim Gugur   8009
623 2012-09-15   Musim Gugur   8714
624 2012-09-16   Musim Gugur   7333
625 2012-09-17   Musim Gugur   6869
626 2012-09-18   Musim Gugur   4073
627 2012-09-19   Musim Gugur   7591
628 2012-09-20   Musim Gugur   7720
629 2012-09-21   Musim Gugur   8167
630 2012-09-22   Musim Gugur   8395
631 2012-09-23  Musim Dingin   7907
632 2012-09-24  Musim Dingin   7436
633 2012-09-25  Musim Dingin   7538
634 2012-09-26  Musim Dingin   7733
635 2012-09-27  Musim Dingin   7393
636 2012-09-28  Musim Dingin   7415
637 2012-09-29  Musim Dingin   8555
638 2012-09-30  Musim Dingin   6889
```

Insight

- Aku ingin meminta maaf terlebih dahulu kepada tim riviewer karena baru menyadarinya.

Jadi kesimpulannya masalah yang terlihat:

- Pada awal 2011-09-01 menunjukan bahwa musim di awali oleh musim gugur.
- Tapi tiba tiba pada tanggal 2011-09-23 malah sudah musim dingin.
- Dan ini terjadi di 2011 maupun 2012. Ini harus aku hantam sih.
- Penyewaan sepeda pada tanggal 29 September 2012 sangat tinggi 8.555 penyewaan, hampir mendekati rekor 8.714 pada 15 September 2012 yang dimana ini menunjukan ada keanehan.

1.8 Cleaning Data Dadakan.

[123]:
```
# Memperbaiki musim yang salah dengan mencocokkan bulan
day_df.loc[day_df['Bulan'].isin(['September', 'Oktober', 'November']), 'Musim']␣
↪= 'Musim Gugur'
day_df.loc[day_df['Bulan'].isin(['Desember', 'Januari', 'Februari']), 'Musim']␣
↪= 'Musim Dingin'
day_df.loc[day_df['Bulan'].isin(['Maret', 'April', 'Mei']), 'Musim'] = 'Musim␣
↪Semi'
day_df.loc[day_df['Bulan'].isin(['Juni', 'Juli', 'Agustus']), 'Musim'] = 'Musim␣
↪Panas'

# Cekcok
day_df[['Tanggal', 'Bulan', 'Musim']].head(30)
```

[123]:

	Tanggal	Bulan	Musim
0	2011-01-01	Januari	Musim Dingin
1	2011-01-02	Januari	Musim Dingin
2	2011-01-03	Januari	Musim Dingin
3	2011-01-04	Januari	Musim Dingin
4	2011-01-05	Januari	Musim Dingin
5	2011-01-06	Januari	Musim Dingin
6	2011-01-07	Januari	Musim Dingin
7	2011-01-08	Januari	Musim Dingin
8	2011-01-09	Januari	Musim Dingin
9	2011-01-10	Januari	Musim Dingin
10	2011-01-11	Januari	Musim Dingin
11	2011-01-12	Januari	Musim Dingin
12	2011-01-13	Januari	Musim Dingin
13	2011-01-14	Januari	Musim Dingin
14	2011-01-15	Januari	Musim Dingin
15	2011-01-16	Januari	Musim Dingin
16	2011-01-17	Januari	Musim Dingin
17	2011-01-18	Januari	Musim Dingin
18	2011-01-19	Januari	Musim Dingin
19	2011-01-20	Januari	Musim Dingin
20	2011-01-21	Januari	Musim Dingin
21	2011-01-22	Januari	Musim Dingin
22	2011-01-23	Januari	Musim Dingin
23	2011-01-24	Januari	Musim Dingin
24	2011-01-25	Januari	Musim Dingin
25	2011-01-26	Januari	Musim Dingin
26	2011-01-27	Januari	Musim Dingin
27	2011-01-28	Januari	Musim Dingin
28	2011-01-29	Januari	Musim Dingin
29	2011-01-30	Januari	Musim Dingin

Done sudah bagus sekali.

`Berdasarkan Musim setelah di perbaiki.`

[124]:
```
day_df.groupby(by='Musim', observed=False).agg({
    'Total' : ['mean', 'min', 'median', 'max', 'sum' , 'std']
}).sort_values(by=('Total', 'sum'), ascending=False).sort_values(by=('Total', ␣
 ↪'sum'), ascending=False)
```

[124]:

	Total					
	mean	min	median	max	sum	std
Musim						
Musim Panas	5665.673913	1115	5324.0	8173	1042484	1337.403092
Musim Gugur	5072.384615	22	4889.5	8714	923174	1824.916947
Musim Semi	4509.239130	605	4572.0	8362	829700	1802.070633
Musim Dingin	2747.629834	431	2493.0	6606	497321	1393.789627

Insight Setelah fakta kesalahan di atasi aku bisa melihat dengan jelas dan menemukan: - `Musim panas` ini adalah musim terThebest untuk orang-orang bersepeda. Dari jumlah keseluruhan, Musim TheBest ini paling tinggi dengan 1.042.484 peminjam, dan menunjukkan bahwa rata-rata peminjaman sepeda ada di angka 5.665 peminjam, minimum 22 peminjam, maksimum ada di 8.362 peminjam dan standar deviasi yang cukup tinggi di angka 1.695 peminjam.

`- Ini menunjukkan bahwa musim panas adalah musim di mana orang-orang bisa bersepeda dengan beba`

- `Musim gugur` berada di podium kedua, dengan nilai keseluruhan ada di 923.174 peminjam. Rata-rata 5.072 peminjam yang menyewa sepeda, median 4.889 peminjam yang menunjukkan sebagian besar hari memiliki peminjaman yang tinggi, dan titik puncak menyentuh angka 8.714 peminjam yang menunjukkan bahwa peminjaman tertinggi dari setiap musim, std yang berada pada angka 1.824 yang menunjukkan ada fluktuasi tinggi, mungkin ada event atau acara lain.
- `Musim semi` sekarang lebih tinggi dengan musim dingin nih, sudah good. Musim semi ada di podium ke 3 dengan nilai keseluruhan berada pada angka 829.700 peminjam, rata rata 4509, peminjam, median 4572 peminjam dan maksimum di angka 8362 peminjam.
- Perngkat terakhir ada `Musim Dingin`.

Dari semua yang terlihat dari rata-rata, nilai tertinggi itu berada pada 8.000+ dan jumlah keseluruhan nilai nya ada di 900.000+, aku mendapatkan sumber untuk memperkuat angka-angka tersebut.

`Wikipedia` dan `Capital Bike Share` menyatakan

- `Capital Bike Share` mulai beroperasi pada September 2010 dan mengalami ekspansi signifikan pada musim gugur 2011, termasuk rencana menambah `32 stasiun` dan memperluas `18 stasiun` lainnya pada akhir tahun, serta menambah `50 stasiun` lagi pada 2012.
- Selain itu, ada acara sepeda seperti `DC Tweed Ride`, yang diadakan pada 13 November 2011 dan juga pada 2012, menarik ratusan peserta dengan tema vintage, tetapi tidak secara khusus

melibatkan `Capital Bike Share`. Ini menunjukkan adanya minat pada acara sepeda, tetapi fokusnya tidak terletak pada program berbagi sepeda tersebut.

`Berdasarkan Bulan`

[125]:
```
day_df.groupby(by='Bulan', observed=False).agg({
    'Total' : ['mean', 'min', 'median', 'max', 'sum', 'std']
}).sort_values(by=('Total', 'sum'), ascending=False).sort_values(by=('Total', ␣
 ↪'sum'), ascending=False)
```

[125]:

	Total					
	mean	min	median	max	sum	std
Bulan						
Agustus	5664.419355	1115	5229.5	7865	351194	1494.516146
Juni	5772.366667	3767	5308.5	8120	346342	1240.400031
September	5766.516667	1842	5384.0	8714	345991	1810.130649
Juli	5563.677419	3285	5446.5	8173	344948	1273.751871
Mei	5349.774194	2633	4890.5	8294	331686	1298.711561
Oktober	5199.225806	22	5013.0	8156	322352	1988.392517
April	4484.900000	795	4293.5	7460	269094	1776.160778
November	4247.183333	1495	4081.0	6852	254831	1285.712709
Maret	3692.258065	605	3216.5	8362	228920	1899.301812
Desember	3403.806452	441	3444.0	6606	211036	1549.639353
Februari	2655.298246	1005	2402.0	5062	151352	1145.313307
Januari	2176.338710	431	1939.0	4521	134933	1161.674370

Insight Dari bulan ini aku akan menggunakan rata-rata (mean) agar adil tanpa terpengaruhi oleh event, kenapa tidak median karena nilai-nilai pada bulan tidak terlalu mempunyai selisih yang jauh antara mean dan median:

- `Bulan` yang memiliki `peminjaman tertinggi` adalah `Juni` (5772 peminjam), `September` (5766 peminjam), `Agustus` (5664 peminjam), dan `Juli` (5563 peminjam), dan ini valid menurut aku karena ini adalah bulan dengan musim ter-the-best yaitu Musim Panas dan Musim Gugur.
- `Bulan` yang memiliki `peminjaman terendah` adalah `Januari` (2.176 peminjam) dan `Februari` (2.655 peminjam). Karena apa? Ya karena ini Musim Dingin.

Jika berdasarkan `Max`: - Tertinggi dipegang oleh `September` (8714 peminjam) dan `Maret` (8362 peminjam). - Terendah dipegang oleh `Januari` (4521 peminjam) dan `Februari` (5062 peminjam).

Berdasarkan `Min`: - Dipegang oleh `Oktober` dengan nilai 22 peminjam, dan dikala ada sumber dari Wikipedia mengatakan bahwa ada badai yang bernama `Hurricane Sandy` yang mengakibatkan tidak adanya orang yang beraktivitas, tapi orang ini superhero kali ya.

Berdasarkan `sum`: - Bulan yang memiliki jumlah peminjaman paling banyak adalah `Agustus` mencapai angka 351.194 peminjam, `Juni` mencapai (346.342 peminjam), dan `September` mencapai angka (345.991 peminjam) dan ini valid karena rata rata nya pun memang seperti itu mereka top tier. - Bulan yang memeiliki jumlah peminjaman yang paling sedikit adalah sama juga mereka masuk

ke `Musim Dingin` yaitu `Januari`(134.933 peminjam) dan `Februari` (151.352 peminjam) dan ini di buktikan di meannya.

Berdasarkan Hari

[126]:
```
day_df.groupby(by='Hari', observed=False).agg({
    'Total' : ['mean', 'min', 'median', 'max','sum', 'std']
    }).sort_values(by=('Total', 'sum'), ascending=False)
```

[126]:

	Total					
	mean	min	median	max	sum	std
Hari						
Jumat	4690.288462	1167	4601.5	8362	487790	1874.624870
Kamis	4667.259615	431	4721.0	7804	485395	1939.433317
Sabtu	4550.542857	627	4521.0	8714	477807	2196.693009
Rabu	4548.538462	441	4642.5	8173	473048	2038.095884
Selasa	4510.663462	683	4576.5	7767	469109	1826.911642
Senin	4338.123810	22	4359.0	7525	455503	1793.074013
Minggu	4228.828571	605	4334.0	8227	444027	1872.496629

Insight Ada banyak keanehan disini aku akan cek terlebih dahulu dengan dibwah ini.

[127]:
```
day_df[(day_df['Hari'].isin(['Senin', 'Kamis', 'Rabu', 'Jumat', 'Rabu'])) &␣
 ↪(day_df['Total'].isin([22, 431, 441, 8362, 8173]))].sort_values(by='Total')
```

[127]:

	index	Tanggal	Musim	Tahun	Bulan	Hari	Libur	Kerja	\
667	668	2012-10-29	Musim Gugur	2012	Oktober	Senin	Tidak	Ya	
26	27	2011-01-27	Musim Dingin	2011	Januari	Kamis	Tidak	Ya	
725	726	2012-12-26	Musim Dingin	2012	Desember	Rabu	Tidak	Ya	
571	572	2012-07-25	Musim Panas	2012	Juli	Rabu	Tidak	Ya	
447	448	2012-03-23	Musim Semi	2012	Maret	Jumat	Tidak	Ya	

	Cuaca	Suhu	Suhu_Terasa	Kategori_Suhu_Terasa	\
667	Hujan/Salju Ringan	18.040000	21.97000	Nyaman	
26	Cerah/Berawan	7.995000	10.98500	Dingin	
725	Hujan/Salju Ringan	9.976653	11.01665	Dingin	
571	Cerah/Berawan	29.690847	32.70270	Hangat	
447	Kabut/Berawan	24.668347	28.50335	Hangat	

	Kelembapan	Kategori_Kelembapan	Kecepatan_Angin	Kategori_Angin	\
667	88.0000	Ekstrem Lembap	23.999400	Sedang	
26	68.7500	Lembap	7.627079	Tenang	
725	82.3333	Sangat Lembap	21.208582	Sedang	
571	45.0000	Nyaman	11.041600	Sepoi Sepoi	
447	69.4167	Lembap	7.792100	Tenang	

	Non_member	Member	Total
667	2	20	22
26	15	416	431
725	9	432	441
571	1383	6790	8173
447	2469	5893	8362

Insight Aku menganalisis berdasarkan mean nya dulu lalu nanti aku tuliskan berdasarkan jumlah keseluruhan atau sum:

1. **`Min` dan `Max`**

Nilai Terendah di duduki oleh hari: - Hari `Senin` dengan angka 22 peminjam, dan ternyata ada alasannya, jika di perhatikan dia adalah hari yang dimana badai pada 29 Oktober 2012 terjadi yaitu Badai Hurricane Sandy. - Hari `Kamis` dengan angka 431 peminjam, dan ternyata sama setelah aku cari tau kenapa aku menemukan sumber dari Wikipedia pada hari `Kamis` tersebut di tanggal 2011 Januari 2011 di katakan adanya badai salju yang disebut `Commut Armaggedon` dari 25-27 Januari 2011. - Hari `Rabu` dengan angka 441 peminjam, jika ini kemungkinannya adalah disebabkan oleh cuaca buruk dan periode pasca-libur Natal.

Nilai Tertinggi di duduki oleh:

- Hari `Sabtu` dengan angka mencapai 8.714 peminjam, dan ini 100% Valid karena memang lagi `Musim Gugur` yang merupakan musim terThebest.
- Hari `Jumat` dengan angka mencpai 8.362 peminjam, ada beberapa alasan:
- Banyak orang menggunakan sepeda untuk perjalanan kerja karena pada hari jumat memang kan `Hari Kerja`.
- Ini adalah akhir Minggu kerja.
- Orang orang mungkin lebih sering menggunakan sepeda untuk kegiatan rekreasi atau berbelanja sebelum akhir pekan.
- Di dukung Musim Semi yang suhu dan angin sepoi sepoi yang enakeun.
- Hari `Minggu` mencapai 8.227 peminjam. Fix Valid no debat!.
- Hari `Rabu` mencapai 8.173 peminjam, ada beberapa alasan:
  - `Cuaca` yang mendukung kemungkinan besar menjadi faktor utama.
  - `Suhu` sekitar 26°C yang hangat.
  - `Kecepatan angin` sepoi sepoi uy sekitar 9,9 km/jam, semuanya.
  - Dan hari kerja, mungkin orang orang menjadikan sepeda sebagai alat transportasinya.

2. **`sum` dan `mean` Nilai Terendah dididuki oleh:**

- Ada di hari `Minggu` dengan `sum` dan `mean` berada pada (444.027 peminjam) dan (4228 peminjam), ada beberapa faktor yang bisa menyebabkannya:
- Orang lebih memilih bersantai setelah hari sabtu mereka beraktivitas keluar untuk membeli kebutuhan sehari hari mereka. Dan pada hari minggu mungkin di barat merupakan waktunya family time bagi orang yang sudah memiliki keluarga dan beristirahat.
- Di hari `Senin` dengan sum dan mean mencapai (455.503 peminjam) dan (4338 peminjam), karena mungkin hari senin ada kejadian Hurricane Sandy tadi.

Nilai Tertinggi di duduki oleh: - Pada hari `Jumat` dengan sum dan mean berada pada (487.790 peminjam) dan (4690 peminjam) dengan std menunjukan angka yang cukup besar (1874 peminjam)

ini menunjukan adanya variasi data atau fluktuitas data yang lumayan besar dan signifikan. - Pada hari `Kamis` dari yang awalnya bagai salju kini hari kamis bangkit ke posisi ke 2 Tertinggi dengan sum dan mean berada pada (485.395 peminjam) dan (4667 peminjam) di ikuti oleh std yang berfluktuasi melebihi hari Jum'at berada pada (1939 peminjam). - Pada hari `Ssbtu` dari yang memiliki max paling tinggi tapi sum dan mean nya cetek kali. std nya sih sudah bisa menunjukan kenapa Hari Sabtu ini berada di posisi ke 3 di salip oleh Jumat dan Kamis.

---

2. Korelasi Antar Variable `day_df`.

- **Menghitung korelasi antara `Suhu`, `Kelembapan`, `Kecepatan_Angin`, `Cuaca` dan `Musim` dengan `Total`.**

Standarisasi ANOVA

```
1. P-Value (PR(>F))
•   Jika < 0.05 → Perbedaan antar kelompok signifikan.
•   Jika sangat kecil (misal 1.40e-59) → Efek musim sangat kuat terhadap penyewaan.
2. F-Value
•   Semakin besar → Variasi antar musim lebih besar dibanding variasi dalam satu musim.
•   Jika F > 10, berarti ada perbedaan yang cukup signifikan antar musim.
•   Jika F   1, berarti musim tidak terlalu berpengaruh.
```

`Berdasrakan Tipe Data Kategorikal`

`1. Cuaca`

[128]:
```
from statsmodels.formula.api import ols

# ANOVA dengan kategori cuaca
model = ols('Total ~ C(Cuaca)', data=day_df).fit()
anova_Cuaca= sm.stats.anova_lm(model, typ=2)

anova_Cuaca
```

[128]:

	sum_sq	df	F	PR(>F)
C(Cuaca)	2.716446e+08	2.0	40.066045	3.106317e-17
Residual	2.467891e+09	728.0	NaN	NaN

Insight Jadi Saya menggunakan pendekatan `ANOVA` karena ingin langsung menganalisis variabel kategorikal tanpa perlu mengonversinya ke numerik. - Berdasarkan hasil uji `ANOVA`, diperoleh p-value = 3.10e-17, yang jauh lebih kecil dari 0.05. - Hal ini menunjukkan bahwa kondisi cuaca memiliki pengaruh signifikan terhadap total penyewaan sepeda. - Dengan kata lain, jumlah penyewaan sepeda berbeda secara signifikan berdasarkan kategori cuaca.

[129]:
```
from statsmodels.stats.multicomp import pairwise_tukeyhsd

# Uji Tukey HSD untuk Cuaca
tukey_Cuaca = pairwise_tukeyhsd(endog=day_df['Total'], groups=day_df['Cuaca'],␣
↪alpha=0.05)
print(tukey_Cuaca.summary())
```

```
                Multiple Comparison of Means - Tukey HSD, FWER=0.05
================================================================================
===
      group1              group2        meandiff  p-adj   lower      upper
reject
--------------------------------------------------------------------------------
---
     Cerah/Berawan Hujan/Salju Ringan -3073.5005   0.0 -4038.2458 -2108.7551
True
     Cerah/Berawan      Kabut/Berawan  -840.9238   0.0 -1181.6303  -500.2174
True
Hujan/Salju Ringan      Kabut/Berawan  2232.5766   0.0  1249.6991  3215.4542
True
--------------------------------------------------------------------------------
---
```

Insight Nah, setelah aku cek hasil Tukey HSD buat cuaca, aku bisa bilang kalau cuaca ini beneran ngaruh banget ke jumlah penyewaan sepeda. Karena: - p-value semua 0.0, alias signifikan banget, berarti perbedaan tiap kondisi cuaca emang bukan kebetulan doang. - Cerah/Berawan dibanding Hujan/Salju Ringan, bedanya gede banget -3073.5, jelas banget kalau hujan bikin orang males nyewa sepeda. Tapi kalau ada yang lagi sad dan depresi bisa di pertimbangkan haha. - Cerah/Berawan vs Kabut/Berawan, bedanya -840.92, masih signifikan, tapi gak separah pas hujan. - Yang agak menarik, Hujan/Salju Ringan vs Kabut/Berawan justru selisihnya +2232.57, ini nunjukin kalau meskipun kabut ada, orang masih lebih mau nyewa sepeda dibanding saat hujan.

Angka angka ini di dukung sama Distribusi Data Cuaca terhadap Total yang sudah aku lakukan sebelumnya.

2. Musim

[130]:
```
from statsmodels.formula.api import ols

# ANOVA dengan kategori musim
model_musim = ols('Total ~ C(Musim)', data=day_df).fit()
anova_musim = sm.stats.anova_lm(model_musim, typ=2)

anova_musim
```

[130]:

	sum_sq	df	F	PR(>F)
C(Musim)	8.654629e+08	3.0	111.911631	1.401257e-59
Residual	1.874072e+09	727.0	NaN	NaN

Insight Berdasarkan Uji ANOVA yang sama aku lakukan terhadap Cuaca juga aku menyimpulkan:

- Musim ini sangat berpengaruh terhadap Total karena:
- `p-value` = 1.40e-59, yang jauh lebih kecil dari 0.05.
- nilai `sum_sq` untuk musim 865M jauh lebih besar dibandingkan cuaca 271M, yang berarti musim memiliki dampak lebih besar dibandingkan cuaca terhadap total penyewaan sepeda.

Dan semuanya ini di dukung setelah kita mengeksplorasi Distribusi Data berdasarkan Musim.

[131]:
```
from statsmodels.stats.multicomp import pairwise_tukeyhsd

# Uji Tukey HSD untuk musim
tukey_musim = pairwise_tukeyhsd(endog=day_df['Total'], groups=day_df['Musim'],␣
↪alpha=0.05)
print(tukey_musim.summary())
```

```
        Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====================================================================
   group1       group2    meandiff  p-adj    lower      upper   reject
---------------------------------------------------------------------
Musim Dingin Musim Gugur  2324.7548    0.0  1890.7658 2758.7437   True
Musim Dingin Musim Panas  2918.0441    0.0  2485.2328 3350.8554   True
Musim Dingin  Musim Semi  1761.6093    0.0   1328.798 2194.4206   True
 Musim Gugur Musim Panas   593.2893 0.0024   161.0778 1025.5007   True
 Musim Gugur  Musim Semi  -563.1455 0.0046  -995.3569  -130.934   True
 Musim Panas  Musim Semi -1156.4348    0.0 -1587.4637 -725.4059   True
---------------------------------------------------------------------
```

Insight Dari apa yang aku lihat dari hasil Uji Tukey HSD, bisa disimpulkan kalau musim tuh emang ngaruh banget ke jumlah penyewaan sepeda. Bukan cuma sekadar beda, tapi bedanya signifikan!

- Musim panas itu paling rame, beda jauh banget sama musim dingin, selisihnya sampai +2918 penyewaan. Udah jelas sih, siapa juga yang mau sepedaan di tengah dingin beku? Mhehehe.
- Musim gugur juga lebih rame dibanding musim semi, walaupun selisihnya tidak terlalu jauh (-563 penyewaan).
- Yang menarik, setiap musim tuh punya pola penyewaan yang beda, dan semua perbedaannya signifikan (bukan kebetulan doang ada bukti pada Distribusi Data!).

Jadi ya, aku bisa dibilang musim punya dampak yang lebih besar dibanding cuaca, karena perbedaannya beneran kerasa di angka.

3. Kategori `Suhu Terasa`

[132]:
```
from statsmodels.formula.api import ols

# ANOVA dengan kategori musim
model_Kategori_Suhu = ols('Total ~ C(Kategori_Suhu_Terasa)', data=day_df).fit()
anova_musim_Kategori_Suhu = sm.stats.anova_lm(model_Kategori_Suhu, typ=2)
```

```
anova_musim_Kategori_Suhu
```

[132]:

	sum_sq	df	F	PR(>F)
C(Kategori_Suhu_Terasa)	1.148479e+09	4.0	131.012857	3.314132e-84
Residual	1.591057e+09	726.0	NaN	NaN

Insight Pada kesimppulannya aku mendapatkan:

- Nilai F menunjukan 131.01 yang artinya kalau perbedaannya kecil, nilai F-nya bakal mendekati 1. Ini jauh di atas 1, jadi suhu terasa memang berpengaruh banget terhadap jumlah peminjaman sepeda. -Nilai PR atau p-value berada pada 3.31 tidak ada keraguan lagi dan pertanyaan apakah ini kebetulan karena sudah terjawab disini. Dengan p-value sekecil ini maka bisa aku katakan Suhu Terasa ini sangat penting dalam faktor penentu Total Peminjaman Sepeda.

[133]:
```
from statsmodels.stats.multicomp import pairwise_tukeyhsd

# Uji Tukey HSD untuk musim
tukey_musim = pairwise_tukeyhsd(endog=day_df['Total'],␣
 ↪groups=day_df['Kategori_Suhu_Terasa'], alpha=0.05)
print(tukey_musim.summary())
```

```
        Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====================================================================
group1     group2     meandiff  p-adj    lower      upper    reject
---------------------------------------------------------------------
Dingin        Hangat  3336.2464    0.0  2912.7201  3759.7727   True
Dingin        Nyaman  1669.8941    0.0  1231.4032  2108.3851   True
Dingin         Panas   2992.089    0.0  2328.5541  3655.6238   True
Dingin Sangat Dingin -1376.0649 0.6884 -4260.4332  1508.3034  False
Hangat        Nyaman -1666.3522    0.0 -2014.8287 -1317.8758   True
Hangat         Panas  -344.1574 0.5312  -951.9733   263.6584  False
Hangat Sangat Dingin -4712.3113 0.0001 -7584.3736 -1840.2489   True
Nyaman         Panas  1322.1948    0.0   703.8584  1940.5312   True
Nyaman Sangat Dingin  -3045.959 0.0316 -5920.2662  -171.6518   True
 Panas Sangat Dingin -4368.1538 0.0005 -7285.2836 -1451.0241   True
---------------------------------------------------------------------
```

Insight **Perbedaan Signifikan ($p < 0.05$, reject = True)**

- Dingin vs Hangat : Hangat jauh lebih banyak peminjaman sepeda (+3336).
- Dingin vs Nyaman : Nyaman lebih banyak peminjaman dibanding Dingin (+1669).
- Dingin vs Panas : Panas lebih banyak peminjaman dibanding Dingin (+2992).
- Hangat vs Nyaman : Nyaman lebih sedikit peminjaman dibanding Hangat (-1666).
- Hangat vs Sangat Dingin : Sangat Dingin jauh lebih sedikit dibanding Hangat (-4712).
- Nyaman vs Panas : Panas lebih banyak dibanding Nyaman (+1322).
- Nyaman vs Sangat Dingin : Sangat Dingin jauh lebih sedikit dibanding Nyaman (-3045).

- Panas vs Sangat Dingin : Sangat Dingin jauh lebih sedikit dibanding Panas (-4368).

Berdasrakan Tipe Data Numerical

[134]:
```
correlation_matrix = day_df[['Total', 'Suhu', 'Kelembapan', 'Kecepatan_Angin']].
↪corr()
correlation_matrix
```

[134]:

	Total	Suhu	Kelembapan	Kecepatan_Angin
Total	1.000000	0.627494	-0.125936	-0.234545
Suhu	0.627494	1.000000	0.121952	-0.157944
Kelembapan	-0.125936	0.121952	1.000000	-0.220750
Kecepatan_Angin	-0.234545	-0.157944	-0.220750	1.000000

Insight Dari apa yang aku lihat dan pelajari dari correlation_matrix ini dapat aku katakan: - Suhu punya korelasi positif cukup kuat (0.63) dengan total penyewaan sepeda. Ini artinya, semakin tinggi suhu, semakin banyak orang yang menyewa sepeda. Tentunya masuk akal dong, karena cuaca hangat lebih nyaman buat bersepeda. - Kelembapan memiliki korelasi negatif sangat lemah (-0.12) terhadap total penyewaan. Yang artinya, kelembapan bukan faktor yang terlalu berpengaruh, jadi walaupun lembab, orang masih tetap menyewa sepeda. - Kecepatan angin punya korelasi negatif moderat (-0.23) dengan total penyewaan. Ini berarti, semakin kencang anginnya, semakin sedikit orang yang sewa sepeda. Bisa jadi karena angin kencang bikin bersepeda lebih berat dan kurang nyaman, apalagi bersepeda pas ada tornado.

Dari sini dapat aku simpulkan, Suhu jadi faktor utama yang paling berdampak pada jumlah penyewaan sepeda dibandingkan faktor lainnya. Tapi, kita masih bisa gali lebih dalam buat lihat apakah ada hubungan yang lebih kompleks antara variabel ini?

- **Cek apakah `suhu tinggi` meningkatkan penyewaan atau `curah hujan` menurunkannya.**

[135]:
```
day_df.groupby(by=['Cuaca', 'Kategori_Suhu_Terasa'], observed=False).agg({
    'Total' : ['count', 'mean', 'std', 'min', 'median', 'max', 'sum']
}).sort_values(by=('Total', 'sum'), ascending=False)
```

[135]:

		Total			\
		count	mean	std	
Cuaca	Kategori_Suhu_Terasa				
Cerah/Berawan	Hangat	194	6043.525773	1352.061068	
	Nyaman	142	4481.978873	1518.749306	
Kabut/Berawan	Hangat	101	5219.851485	1442.923757	
	Nyaman	93	3599.913978	1392.640046	
Cerah/Berawan	Panas	45	5305.577778	1241.694343	
	Dingin	80	2604.362500	1369.582984	
Kabut/Berawan	Dingin	46	2072.304348	1015.623265	
	Panas	7	5647.857143	1696.765298	

Hujan/Salju Ringan	Hangat	7	2926.571429	1146.238174
	Nyaman	9	1328.333333	932.078725
	Dingin	5	1085.600000	789.746035
Cerah/Berawan	Sangat Dingin	2	983.500000	3.535534
Hujan/Salju Ringan	Sangat Dingin	0	NaN	NaN
Kabut/Berawan	Sangat Dingin	0	NaN	NaN
Hujan/Salju Ringan	Panas	0	NaN	NaN

		min	median	max	sum
Cuaca	Kategori_Suhu_Terasa				
Cerah/Berawan	Hangat	2927.0	6038.5	8714.0	1172444
	Nyaman	1317.0	4330.5	8090.0	636441
Kabut/Berawan	Hangat	1115.0	4795.0	8362.0	527205
	Nyaman	605.0	3623.0	6392.0	334792
Cerah/Berawan	Panas	3285.0	4845.0	7592.0	238751
	Dingin	431.0	2287.5	7148.0	208349
Kabut/Berawan	Dingin	683.0	1878.0	5319.0	95326
	Panas	3784.0	6140.0	7534.0	39535
Hujan/Salju Ringan	Hangat	1842.0	2424.0	4639.0	20486
	Nyaman	22.0	1027.0	2765.0	11955
	Dingin	441.0	627.0	2169.0	5428
Cerah/Berawan	Sangat Dingin	981.0	983.5	986.0	1967
Hujan/Salju Ringan	Sangat Dingin	NaN	NaN	NaN	0
Kabut/Berawan	Sangat Dingin	NaN	NaN	NaN	0
Hujan/Salju Ringan	Panas	NaN	NaN	NaN	0

Insight Sebenarnya ini sudah terjawab pada ANOVA dan Korelasi yang sudah aku lakukan jadi intinya.

- Korelasi anatara `Suhu` dan `Total Peminjaman` ada pada angka 0.63 ini menunjukan bahwa Semakin Tinggi Suhu, Semakin Tinggi juga Total Peminjamanya, mau suhu sedang relatif panas atau sejuk asalkan suhu tidak melewati batas Suhu masih lebih berpengaruh kepada Total Peminjaman.
- Nah, di data kita gak ada variabel 'curah hujan' secara langsung, tapi ada Cuaca, yang sudah kita uji dengan ANOVA sebelumnya. Hasilnya menunjukkan bahwa Hujan/Salju Ringan signifikan menurunkan penyewaan dibandingkan cuaca lain. Makanya kenapa aku mengubah nya menjadi kategorikal dan memappingnya.
- Dan setelah kita melihat tabel di atas ini betul bukan menunjukan bahwa hujan/salju menurunkan peminjaman sepeda

Jadi kesimpulannya. - Suhu tinggi memang meningkatkan penyewaan (terbukti dari korelasi yang positif kuat) dan (terbukti pada tabel di atas di dominasi oleh hangat dan nyaman). - Curah hujan menurunkan penyewaan (terlihat dari hasil ANOVA pada kategori cuaca) dan (terlihat pada tabel bahwa ketika hujan langsung menurun).

---

3. Pola Hari Kerja vs Hari Libur.

- **Membandingkan jumlah penyewaan pada hari kerja (`Kerja`) vs `Akhir Pekan`**

[136]:
```
# Langsung buat list tanpa nambahin kolom baru
weekend_rentals = day_df[day_df['Hari'].isin(['Sabtu', 'Minggu'])]['Total']
weekday_rentals = day_df[day_df['Hari'].isin(['Senin', 'Selasa', 'Rabu',␣
↪'Kamis', 'Jumat'])]['Total']

# Uji t-test
t_stat, p_value = stats.ttest_ind(weekend_rentals, weekday_rentals,␣
↪equal_var=False)

print(f'T-Test Statistik: {t_stat:.4f}')
print(f'p-value: {p_value:.4f}')
```

```
T-Test Statistik: -0.9837
p-value: 0.3259
```

Insight Oke, dari uji `T-Test` yang aku lakukan tadi, hasilnya: - `T-Test Statistik` berada pada angka -0.9837, Ini menunjukkan seberapa besar perbedaan rata-rata antara penyewaan di Hari Kerja vs Akhir Pekan. - `p-value` berada di angka 0.3259, Nah, karena ini lebih dari 0.05, artinya perbedaan ini gak signifikan secara statistik.

Jadi Kesimpulannya gini:

- Tidak ada perbedaan signifikan antara penyewaan di `Hari Kerja` vs `Akhir Pekan`. Artinya, jumlah penyewaan sepeda di weekday dan weekend sebenarnya hampir mirip, gak ada lonjakan besar yang bisa dianggap signifikan.
- Orang orang tetap banyak nyewa sepeda, baik di hari kerja maupun akhir pekan. Karena menurut Wikipedia yang link nya telah aku cantummkan di sini, Sepeda ini merupakan kebutuhan trasnsportasi harian yang diminati sangat tinggi oleh masyarakat disana.
- Hasil ini sesuai sama pola mobilitas kota. Kalau di kota besar apalagi seperti `Washington DC` dengan transportasi umum yang padat, sepeda bisa jadi solusi buat harian.
- Jadi, gak heran kalau penggunaannya tetap stabil, gak cuma naik drastis pas akhir pekan aja.

Jadi, kesimpulannya, penyewaan sepeda di `Hari Kerja` vs `Akhir Pekan` gak beda jauh secara signifikan, dan kemungkinan sepeda dipakai buat keperluan harian, bukan sekadar rekreasi weekend doang.

---

4. Perbandingan Tahun 2011 vs 2012

- **Membandingkan total peminjaman antar tahun untuk melihat peningkatan atau penurunan.**

[137]:
```
day_df.groupby(by='Tahun', observed=False).agg({
    'Total' : ['count', 'mean', 'std', 'min',  'median', 'max', 'sum']
}).sort_values(by=('Total', 'sum'), ascending=False)
```

[137]:

	Total						
	count	mean	std	min	median	max	sum
Tahun							
2012	366	5599.934426	1788.667868	22	5927.0	8714	2049576
2011	365	3405.761644	1378.753666	431	3740.0	6043	1243103

Insight Dari yang aku lihat dari perbandingan antara tahun 2011 dan tahun 2012 ini adalah:

- `Mean`: Rata rata peminjaman harian, meningkat signifikan dari 3405 Peminjam pada 2011 menjadi 5599 Peminjam pada 2012.
- `Std`: Deviasi standar juga meningkat, menunjukkan variabilitas harian yang lebih besar pada 2012 (1788 Peminjam vs 1378 Peminjam).
- `Min`: Minimum peminjaman harian turun drastis dari 431 Peminjaman pada 2011 menjadi 22 Peminjaman pada 2012, yang mungkin menunjukkan hari dengan penggunaan sangat rendah, Kita akan eksplorasi perihal ini karena takut nya ada inkonsistensi atau inaccurate value.
- `Median`: Median naik dari 3740 Peminjaman ke 5927 Peminjaman, menunjukkan distribusi yang lebih tinggi secara keseluruhan pada 2012.
- `Max`: Maksimum peminjaman harian juga meningkat, dari 6043 Peminjaman pada tahun 2011 ke 8714 Peminjaman pada tahun 2012, menunjukkan hari dengan penggunaan puncak yang lebih tinggi.
- `Sum`: Total peminjaman tahunan melonjak meleduaks dari 1,243,103 Peminjaman pada 2011 menjadi 2,049,576 Peminjaman pada 2012, menunjukkan peningkatan penggunaan sebesar sekitar 64.9%.

Mengapa Peminjaman Naik Gila Gilaan pada 2012?

Dari eksplorasi yang aku temukan dari `sumber sumber internet`aku semakin yakin angka ini adalah angka valid. Penjelasnnya:

1. **Pertama di pengaruhi oleh Perluasan Sistem Capital Bike Share**

`Wikipedia` menyatakan bahwa: - Capital Bike Share mulai beroperasi pada September 2010 dan mengalami ekspansi signifikan pada musim gugur 2011.
- Ada penambahan 32 stasiun dan perluasan 18 stasiun lagi di akhir 2011.s - Tahun 2012 makin gila, nambah 50 stasiun lagi.

2. **Di pengaruhi oleh kondisi cuaca.**

- Dari yang aku baca pada artikel `The Washington Post` disitu dinyatakan bahwa:
- Tahun 2012 adalah tahun terhangat yang tercatat di Washington, D.C., dengan Maret yang sangat hangat dan musim panas yang masuk dalam tiga terhangat dalam sejarah.
- Ini membuktikan cuaca juga mendorong banget orang orang bersepeda dan mendorong rezeki Capital Bike Share.

3. **Sistem seperti Peminjaman Sepeda relatif baru mungkin ya disana.**

- Ini asumsiku saja bahwa transportasi umum di Washington DC itu mungkin padat dan adanya Sistem Peminjaman Sepeda ini melirik minat masyarakat apalagi pekerja, dan mungkin di dukung oleh pemerintahan juga agar mengurangi kemacetan.

1.9 Exploratory Data Analysis (EDA).

1.9.1 Roadmap Analisis `hour_df` untuk Mendukung `day_df`

No	Fokus Analisis	Tujuan
1	**Perbandingan 2011 vs 2012**	Mengecek apakah peningkatan penyewaan di 2012 terjadi merata di semua jam atau hanya pada jam tertentu.
2	**Pengaruh Cuaca terhadap Peminjaman**	Memastikan apakah cuaca buruk lebih berpengaruh di jam tertentu.
3	**Pola Waktu Puncak & Weekend vs Weekday**	Mengonfirmasi jam-jam sibuk dan perbedaan pola peminjaman di hari kerja vs akhir pekan.
4	**Pengaruh Suhu dan Kelembapan**	Menggali lebih dalam apakah suhu tinggi lebih meningkatkan peminjaman di jam tertentu.
5	**Pola Pengguna Member vs Non-Member**	Memahami kapan pengguna casual lebih aktif dibandingkan member.

---

1. Perbandingan`2011` vs `2012` pada `Jam`.

- **Mengecek apakah peningkatan peminjaman di `2012` terjadi merata di semua `jam` atau hanya `pada jam` tertentu.**.

[138]:
```
# bins_jam = [0, 5, 11, 15, 18, 23]
```

```
hour_df.groupby(by=['Tahun', 'Kategori_Jam'], observed=False).agg({
    'Total' : ['count', 'mean', 'std', 'min', 'median', 'max', 'sum']
}).sort_values(by=('Total', 'sum'), ascending=False)
```

[138]:

		Total						
		count	mean	std	min	median	max	sum
Tahun	Kategori_Jam							
2012	Pagi	2196	261.010018	185.588748	1	215.0	839	573178
	Sore	1098	496.728597	221.443209	13	487.5	977	545408
	Siang	1464	311.142760	152.455870	10	276.0	776	455513
	Malam	1830	227.862842	145.421408	9	198.5	743	416989
2011	Pagi	2190	155.085388	116.560356	1	126.0	564	339637
	Sore	1095	302.305936	156.168271	11	287.0	638	331025
	Siang	1460	187.929452	108.873255	3	170.0	651	274377
	Malam	1825	143.643836	97.879963	2	123.0	465	262150
2012	Dini Hari	2196	29.413024	34.393677	1	16.0	283	64591
2011	Dini Hari	2190	19.696347	24.019322	1	10.0	177	43135

Insight Jadi karena aku bingung untuk `hour_df` ini, aku memutuskan nya untuk menjadikan `hour_df` ini sebagai support untuk memperkuat jawaban jawaban yang berada pada `day_df`. Jadi aku menemukan bahwa:

- Pada `day_df` dinyatakan bahwa `Tahun 2012` itu merupakan puncak `tertinggi` dari `rata rata`, dan jumlah keseluruhan dari peminjaman perhari. Dan disini ternyata di buktikan dengan `rata rata` dan `total peminjaman` per jam nya:
- Bisa kita lihat di `Tahun 2012` peminjaman per `jam` mencapai rentang `227- 496 peminjaman` dengan `Total Penjumlahan` mencapai rentang `416.989 - 573.178 peminjaman`.
- Bandingkan dengan `Tahun 2011` yang benar benar tidak bisa mengejar angka pada `Tahun 2012`, karena sudah aku katakan bahwa peningkatan di `Tahun 2012` itu sudah ada buktinya.

Maka kesimpulannya yang di katakan pada `day_df` yang mengatakan bahwa `Tahun 2012` itu adalah tahun tertinggi dengan faktor faktor yang mempengaruhinya, ternyata bisa aku katakan bahwa itu sangat sangat benar.

---

2. Pengaruh `Cuaca` terhadap `Peminjaman`

- **Memastikan apakah cuaca buruk lebih berpengaruh di jam tertentu**.

[139]:
```
perbandingan = hour_df.groupby(by=['Cuaca', 'Kategori_Jam'], observed=False).
 ↪agg({
    'Total' : ['count', 'mean', 'std', 'min', 'median', 'max', 'sum']
}).sort_values(by=('Total', 'sum'), ascending=False)
perbandingan
```

[139]:

		Total					\
		count	mean	std	min	median	
Cuaca	Kategori_Jam						
Cerah/Berawan	Sore	1517	431.224786	211.209668	24.0	417.0	
	Pagi	2657	217.945427	166.424407	1.0	179.0	
	Siang	1865	277.391957	148.796723	37.0	244.0	
	Malam	2543	201.757766	134.854992	6.0	174.0	
Kabut/Berawan	Pagi	1367	211.032187	163.387848	1.0	169.0	
	Siang	810	222.170370	121.231783	3.0	205.5	
	Sore	455	370.986813	199.450633	38.0	344.0	
	Malam	791	165.992415	114.890140	9.0	139.0	
Cerah/Berawan	Dini Hari	2873	26.061260	31.337353	1.0	14.0	
Hujan/Salju Ringan	Sore	219	243.223744	192.490915	11.0	181.0	
	Pagi	362	125.008287	115.881674	1.0	93.5	
	Malam	321	108.314642	98.313548	2.0	77.0	
	Siang	249	130.907631	121.786482	7.0	82.0	
Kabut/Berawan	Dini Hari	1140	24.141228	29.170208	1.0	13.0	
Hujan/Salju Ringan	Dini Hari	372	14.268817	18.523615	1.0	7.0	
Hujan Lebat/Salju	Sore	2	100.000000	90.509668	36.0	100.0	
	Dini Hari	1	23.000000	NaN	23.0	23.0	
	Malam	0	NaN	NaN	NaN	NaN	
	Pagi	0	NaN	NaN	NaN	NaN	
	Siang	0	NaN	NaN	NaN	NaN	

		max	sum
Cuaca	Kategori_Jam		
Cerah/Berawan	Sore	977.0	654168
	Pagi	839.0	579081
	Siang	776.0	517336
	Malam	743.0	513070
Kabut/Berawan	Pagi	817.0	288481
	Siang	711.0	179958
	Sore	957.0	168799
	Malam	610.0	131300
Cerah/Berawan	Dini Hari	249.0	74874
Hujan/Salju Ringan	Sore	891.0	53266
	Pagi	646.0	45253
	Malam	614.0	34769
	Siang	626.0	32596
Kabut/Berawan	Dini Hari	283.0	27521
Hujan/Salju Ringan	Dini Hari	117.0	5308
Hujan Lebat/Salju	Sore	164.0	200
	Dini Hari	23.0	23
	Malam	NaN	0
	Pagi	NaN	0
	Siang	NaN	0

Insight Pada `day_df` dinyatakan bahwa curah hujan sangat mempengaruhi `Total Peminjaman` dan di `hour df ini aku menemukan bahwa`:

- Ini terbukti bisa kita lihat dari angka `pagi` sampai `malam` dengan angka rentang berada pada `362 - 321 Peminjaman perjam` menunjukan penurunan yang sangat signifikan terurama pada `pagi` dan `sore hari` yang sangat turun menukik tajam di bandingkan dengan saat cerah dan berkabut saja.

Dari sini dapat aku simpulkan bahwa apa yang di katakan oleh `day_df` dinyatakan valid bahwa cuaca dan curah hujan sangat mempengaruhi `Total Peminjaman`.

3. Pola `Waktu` Puncak &`Weekend` vs `Weekday`

- **Mengonfirmasi jam-jam sibuk**.

[140]:
```
hour_df.groupby(by='Jam').agg({
    'Total' : ['mean', 'min', 'median', 'max', 'sum', 'std']
}).sort_values(by=('Total', 'mean'), ascending=False)
```

[140]:

	Total					
	mean	min	median	max	sum	std
Jam						
17	461.507524	15	475.0	976	337362	232.502039
18	425.497948	23	419.0	977	311039	224.255428
8	359.566347	5	387.0	839	262843	234.673389
16	311.945280	11	304.0	783	228032	148.584351
19	311.530780	11	311.0	743	227729	160.754812
13	253.515732	11	223.0	760	185320	147.930919
12	253.080711	3	228.0	776	185002	144.830682
15	251.090287	7	226.0	750	183547	144.460167
14	240.794802	12	212.0	750	176021	147.099813
20	226.030096	11	224.0	567	165228	119.442778
9	219.381669	14	217.0	426	160368	93.453589
7	212.477428	1	215.0	596	155321	161.104214
11	207.842681	10	180.0	663	151933	127.211510
10	173.441860	8	147.0	539	126786	101.971311
21	172.324213	6	174.0	584	125969	89.609856
22	131.339261	9	129.0	502	96009	69.798456
23	87.830369	2	80.0	256	64204	50.759613
6	76.010944	1	76.0	213	55564	54.988840
0	53.820793	2	40.0	283	39343	42.226356
1	33.273598	1	20.0	168	24323	33.464831
2	22.770178	1	11.0	132	16645	26.469869
5	19.768810	1	18.0	66	14451	13.143566
3	11.429549	1	6.0	79	8355	13.033840
4	6.305062	1	6.0	28	4609	4.062014

Insight

- `Evening Rush` (Jam 16 - Jam 18) masih menjadi jam yang paling sibuk, bisa kita lihat:
- `Jam 17`, merupakan jam yang paling tinggi dan paling sibuk, dengan faktor `mean` (461 Peminjaman), `median` (475 Peminjaman), sum (337.362 Peminjaman). Maka bisa kita lihat bahwa memang jam paling sibuk pantas di pegang oleh `Jam 17`.
- `Jam 18`, bisa kita lihat `mean` (425 Peminjam), `median` (419 Peminjam), dan `sum` (311.039 Peminjam).
- `Jam 16`, Awal dari kenaikan `Evening Rush`, dengan `mean` (312 Peminjam), `median` (304 Peminjam), dan `sum` (228.082 Peminjam)

Maka dengan nilai nilai pada Jam `Evening Rush` dapat aku katakan bahwa `Evening Rush` merupakan jam yang paling sibuk dan berpengaruh besar terhadap `Total Peminjaman`.

- `Morning Rush` (Jam 7 - Jam 9) Jam ramai tapi tidak sampai sesibuk `Sore`:
  - `Jam 8`: Merupakan penopang penting untuk `Morning Rush`, dengan `mean` di angka 359 peminjaman, `median` berada pada 387 peminjaman, dan `sum` mencapai 262.843 peminjaman, ini statistik yang mengalahkan `Evening Rush` pada `Jam 16`.
  - `Jam 9`: Berada di tier ke 2 di `Morning Rush` dengan `mean` mencapai angka 311 Peminjam, `median` di 311 peminjam juga, dan `sum` berada di angka 227.729 Peminjam.
  - `Jam 7`: Awal lonjakan pada `Morning Rush`, dengan `mean` berada di angka 212 Peminjam, `median` di 215 Peminjam dan `sum` mencapai 155.321 Peminjam.
- `Jam Sepi` (Jam 24 - Jam 5) sangat sepi:
- Bisa kita lihat terdapat penurunan di jam jam sepi contohnya lihat saja setelah jam menyentuh jam 23 maka jam sepi mulai muncul dan penurunan pun tidak bisa di bendung karena ini logis, mana ada manusia yang bersepeda pada jam segitu.

Jadi kesimpulannya menurut aku ini masuk akal dengan lonjakan pada `Tahun 2012` dengan di awali oleh The King `Evening Rush` yang menunjukan bahwa dia yang paling mempengaruhi `Total Peminjaman` di karenakan beberapa faktor, jam pulang kerja, jam pulang sekolah dan masih banyak lagi. Begitu pula dengan `Morning Rush` faktornya jam berangkat kerja, dan jam berangkat sekolah atau kuliah.

- **Perbedaan pola peminjaman di `hari kerja` vs `akhir pekan`**

[141]:
```
hour_df.groupby(by=['Hari', 'Jam'], observed=False).agg({
    'Total' : ['mean', 'sum']
}).sort_values(by=('Total', 'mean'), ascending=False)
```

[141]:

		Total	
		mean	sum
Hari	Jam		
Senin	17	544.278846	56605
Rabu	17	527.346154	54844
Senin	18	517.567308	53827
Selasa	17	513.144231	53367
Minggu	17	502.390476	52751
…		…	…

```
       3      5.104762    536
Rabu   3      5.067308    527
Selasa 4      4.894231    509
       3      4.846154    504
Senin  3      4.134615    430

[168 rows x 2 columns]
```

Insight Di katakan bahwa `weekend` dan `weekday` di `day_df` hampir setara dan merata tapi ternyata di `hour_df` ini bisa kita lihat lebih jelas:

- Bahwa `Morning Rush` dan `Evening Rush` sangat mendominasi pada `weekday`, seperti yang sudah aku bilang faktornya adalah jam jam dimana orang yang berangkat dan pulang dari bekerja, bersekolah, dan juga rekreasi.
- Di `weekend`, `Morning Rush` dan juga `Evening Rush` terlihat lebih merata pada sepanjang jam, mungkin ini di dukung oleh orang orang yang meminjam sepeda ini hanya menggunakan sepeda nya untuk liburan saja dan rekreasi.

Maka bisa di katakan bahwa apa yang di katakan pada `day_df` ternyata salah dan weekday dan weekend ini memiliki perbandingan yang cukup signifikan

---

4. Pengaruh `Suhu` dan `Kelembapan`

- **Menggali lebih dalam apakah `suhu tinggi` lebih meningkatkan peminjaman di jam tertentu**

[142]:
```
hour_df.groupby(by=['Kategori_Suhu_Terasa', 'Kategori_Jam'], observed=False).
 ↪agg({
    'Total' : ['mean', 'sum']
})
```

[142]:

		Total	
		mean	sum
Kategori_Suhu_Terasa	Kategori_Jam		
Sangat Dingin	Dini Hari	8.725000	349
	Pagi	59.800000	1495
	Siang	140.000000	140
	Sore	138.000000	414
	Malam	42.000000	546
Dingin	Dini Hari	13.688716	14072
	Pagi	132.732143	133794
	Siang	117.933333	38918
	Sore	161.848000	40462
	Malam	76.280000	45768
Nyaman	Dini Hari	23.507831	39023

```
                    Pagi          206.009709  318285
                    Siang         215.442346  216735
                    Sore          317.316845  237353
                    Malam         150.399704  203190
Hangat              Dini Hari      32.371284   51179
                    Pagi          256.831949  401942
                    Siang         304.768271  341950
                    Sore          506.663972  438771
                    Malam         246.337884  360885
Panas               Dini Hari      40.298701    3103
                    Pagi          235.798354   57299
                    Siang         284.187097  132147
                    Sore          489.058282  159433
                    Malam         304.203540   68750
```

Insight Pada `day_df` aku menyatakan bahawa suhu yang mulai meninggi dapat mempengaruhi `Total Peminjaman` dan ternyata di `hour_df` terjawab semuanya:

- Transisi dari `Nyaman` ke `Hangat` sangat benar benar melonjak signifikan, bisa di lihat dari rentang dini hari sampai malam dari keduanya. Saling terus meningkat apalagi pas di soer hari selalu melonjak.
- Di saat `Suhu Panas` mengakibatkan sedikit penurunan walaupun penurunan tersebut tidak terlalu berarti.
- `Dingin` dan `Sangat Dingin` merupakan mimpi buruk dari `Total Penjumlahan`

Jadi bisa aku simpulkan bahwa `Cuaca` yang semakin tinggi atau rentang `15 Celcius` sampai `35 Celcius` sangat berpengaruh dan berperan besar terhadap `Total Peminjaman Sepeda`.

5. Perbedaan Pola Non_member dan Member

- **Analisis jumlah peminjaman antara `Registered` (Member) dan `Casual` (Non-Member) berdasarkan jam.**

[143]:
```
hour_df.groupby('Jam', observed=False)[['Non_member', 'Member']].agg(['mean',␣
↪'max', 'min', 'median', 'sum']).sort_index()
```

[143]:

	Non_member					Member				
	mean	max	min	median	sum	mean	max	min	median	sum
Jam										
0	10.142271	68	0	7.0	7414	43.673051	234	0	32.0	31925
1	6.489740	49	0	4.0	4744	26.782490	139	0	15.0	19578
2	4.753762	44	0	2.0	3475	18.001368	104	0	8.0	13159
3	2.614227	26	0	1.0	1911	8.778386	61	0	5.0	6417
4	1.222982	13	0	1.0	894	5.065663	22	0	5.0	3703
5	1.403557	16	0	1.0	1026	18.352941	64	0	17.0	13416
6	4.155951	19	0	3.0	3038	71.852257	203	0	73.0	52524
7	11.057456	40	0	10.0	8083	201.417237	572	1	205.0	147236

8	21.679891	69	0	21.0	15848	337.886457	808	4	361.0	246995
9	30.853625	142	0	26.0	22554	188.523940	399	6	182.0	137811
10	46.396717	209	0	34.0	33916	127.039672	351	8	115.0	92866
11	59.418605	268	0	44.0	43435	148.419973	446	5	136.0	108495
12	68.184679	362	0	49.0	49843	184.893297	526	3	180.0	135157
13	72.238030	355	0	50.0	52806	181.276334	491	9	175.0	132513
14	75.492476	361	0	53.0	55185	165.300958	502	12	154.0	120835
15	74.833105	357	0	54.0	54703	176.255814	456	4	170.0	128843
16	73.718194	367	0	55.0	53888	238.227086	481	8	241.0	174144
17	74.251710	347	0	63.0	54278	387.254446	885	14	373.0	283083
18	61.131327	266	0	55.0	44687	364.363885	886	20	349.0	266350
19	48.778386	230	0	40.0	35657	262.749658	662	11	255.0	192070
20	36.238030	237	0	29.0	26490	189.790698	461	8	187.0	138737
21	28.257182	222	0	23.0	20656	144.062927	362	6	145.0	105310
22	22.257182	175	0	18.0	16270	109.080711	327	5	106.0	79738
23	15.201094	71	0	12.0	11112	72.629275	220	2	66.0	53092

Insight Perbedaan yang bisa aku lihat dari `Non-member` VS `Member` adalah:

1. `Non_member`

- Berdasakan apa yang aku lihat, puncak peminjaman tertinggi `Non_member` berada pada `Jam 14 - Jam 17` dengan rata rata (`mean`) nya bearada pada 75 peminjaman per jam. Jumlah peminjaman (`sum`) berada pada rentang 165 sampai 387 Peminjaman per Jam.
- Setelah `Jam 18` peminjaman mulai menurun drastis.
- Hal ini menunjukkan bahwa `Non-Member` lebih banyak menggunakan sepeda di siang hingga sore hari, mungkin hanya untuk liburan dan rekreasi karena penat nya dunia mheheh.

2. `Member`

- Nah untuk `Member` peminjaman tertinggi terjadi di `Jam 8` (337 Peminjam), `Jam 17` (387 Peminjam), dan `Jam 18` berada pada (364 peminjam), Dengan reantang `sum` berada pada 349 - 373 Peminjam Per Jam.
- Coba perhatikan rata rata peminjaman yang sangat tinggi berada di Pagi Hari dengan rentang `Jam 7 - Jam 9`, dan Sore Hari `Jam 16 - Jam 19`.
- Ini menunjukkan bahwa Member lebih banyak menggunakan sepeda untuk Perjalanan kerja (commuting) dan perjalanan sekolah sampai pulang nya.

Jadi pada kesimpulannya adalah: - Non-Member lebih banyak meminjam sepeda di siang dan sore hari, kemungkinan besar untuk tujuan rekreasi. - Member lebih banyak meminjam sepeda di jam kerja (Jam `7 - Jam 9` & Jam `16 - Jam 19`), menunjukkan pola penggunaan untuk commuting. - Jam `8` dan `17` adalah jam tersibuk untuk peminjaman sepeda oleh Member. - Setelah `Jam 20`, peminjaman sepeda menurun drastis untuk kedua kelompok.

- **Cek apakah ada perbedaan kebiasaan antara kedua kelompok ini, misalnya penggunaan lebih tinggi di `hari kerja` atau `akhir pekan`**

[144]:
```
hour_df.groupby('Hari', observed=False)[['Non_member', 'Member']].agg(
    ['mean', 'max', 'min', 'median', 'sum']
    ).sort_values(by=[('Non_member', 'mean')], ascending=False)
```

[144]:

	Non_member					Member				
	mean	max	min	median	sum	mean	max	min	median	sum
Hari										
Jumat	61.176984	367	0	25.0	154166	128.878175	491	0	101.0	324773
Sabtu	55.800397	317	0	24.0	140617	120.592857	526	0	88.0	303894
Kamis	31.348958	264	0	17.0	78247	164.101362	757	0	135.5	409597
Minggu	28.362302	272	0	15.0	71473	154.149206	857	0	112.0	388456
Rabu	24.743590	154	0	14.0	61760	170.657452	885	0	129.0	425961
Senin	23.300080	178	0	13.0	58157	165.933894	871	0	120.0	414171
Selasa	23.034054	237	0	12.0	57493	167.125401	886	0	121.0	417145

Insight

1. **`Non-Member`**

- Peminjaman tertinggi terjadi pada Jumat (61 peminjaman/jam) dan Sabtu (55 peminjaman/jam).
- Peminjaman menurun drastis pada hari kerja lainnya (Senin-Kamis & Minggu) dengan rata-rata hanya 23-31 peminjaman/jam.

Kesimpulan nya Non-Member lebih sering menggunakan sepeda di akhir pekan dan menjelang akhir pekan (Jumat-Sabtu), kemungkinan besar untuk rekreasi atau jalan-jalan santai seperti yang sudah aku jelaskan di atas.

2. **`Member`**

- Peminjaman tertinggi terjadi di hari kerja (Rabu: 170, Selasa: 167, Senin: 165, Kamis: 164).
- Peminjaman menurun pada Sabtu (120) dan Minggu (154).

Kesimpulannya Member lebih banyak menggunakan sepeda di hari kerja, kemungkinan besar untuk perjalanan kerja (commuting) atau sekolah seperti yang aku jelaskan di atas juga.

1.10 Visualisasi Data

1.10.1 Menjawab Pertanyaan Bisnis

No	Pertanyaan Bisnis
1	Bagaimana perbedaan total peminjaman sepeda antara tahun 2011 dan 2012?
2	Bagaimana kondisi cuaca memengaruhi jumlah peminjaman sepeda?

No	Pertanyaan Bisnis
3	Kapan waktu puncak penggunaan sepeda dalam sehari, dan apakah ada perbedaan pola antara hari kerja dan akhir pekan di tahun 2011 & 2012?
4	Apakah tren peminjaman sepeda mengalami lonjakan atau penurunan signifikan pada bulan-bulan tertentu?
5	Bagaimana pola penggunaan sepeda berbeda antara pelanggan kasual dan pelanggan terdaftar pada hari kerja vs. akhir pekan serta pada berbagai jam dalam sehari?

---

1. Bagaimana perbedaan total peminjaman sepeda antara tahun 2011 dan 2012?

[145]:
```
perbandingan_tahun = day_df.groupby(by='Tahun', observed=False)['Total'].sum().
 ↪reset_index()

plt.figure(figsize=(10, 8))
sns.barplot(
    x = 'Tahun',
    y = 'Total',
    hue = 'Tahun',
    data = perbandingan_tahun,
    palette=['#1f77b4', '#ff7f0e']
)

plt.title('Perbandingan Total Peminjaman Sepeda (2011 vs 2012)', pad=20,␣
 ↪fontsize=14)
plt.xlabel(None)
plt.ylabel('Jumlah Peminjaman')
plt.xticks(ticks=[0, 1], labels=['2011', '2012'], fontsize=12)
plt.show()
```

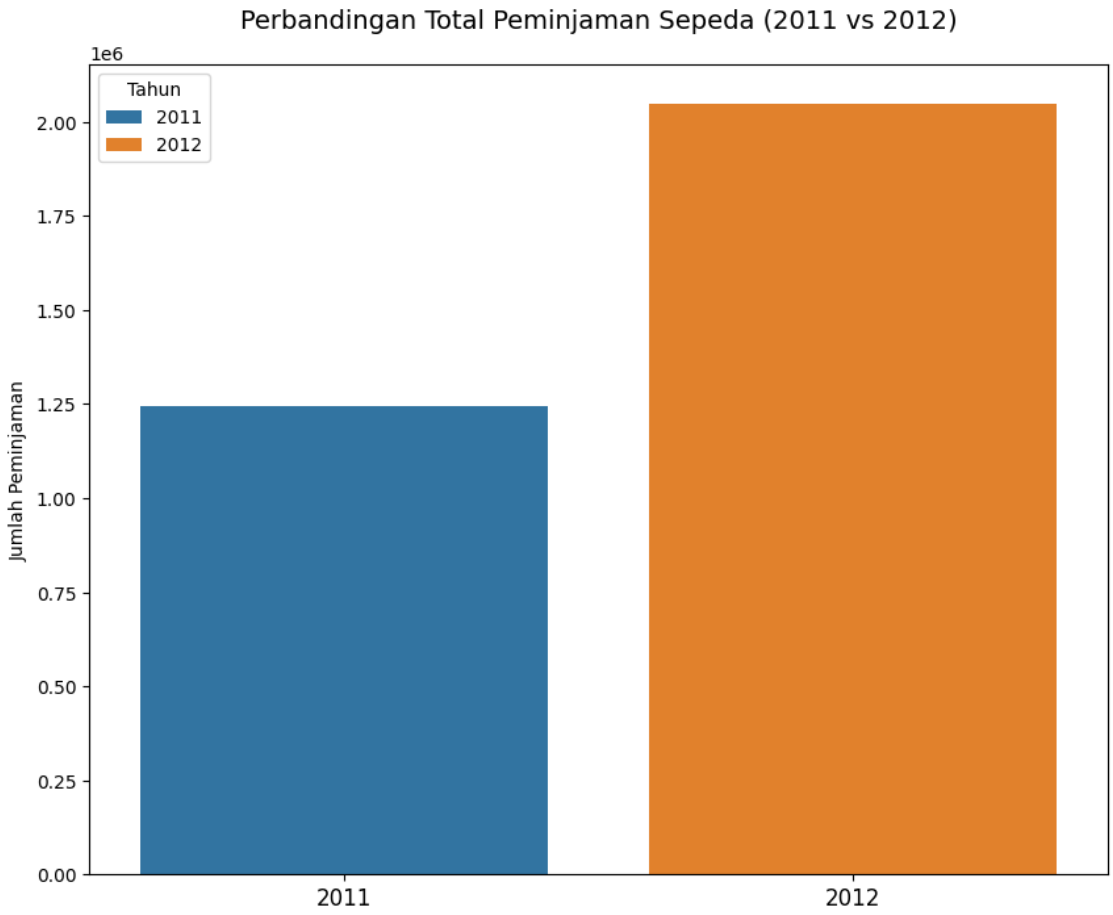

Insight Saya sudah mengatakan di proses EDA bahwa data dan eksplorasi menunjukan, `Tahun 2012` adalah Tahun yang paling tinggi jumlah peminjamannya, dan perkataan tersebut bisa di perkuat oleh `Line Chart` di atas. Ternyata memang eksplorasi kita tepat untuk mengatakan `Tahun 2012` ini merupakan tahun terbaik. Mengapa:

- Dari `Line Chart` di atas juga sudah terjawab di lihat dari lonjakan signifikan dari april sampai ke juni. Tapi faktor yang mempengaruhi banget bahwa `Tahun 2012` ini sangat menggila adalah:

1. Sukses nya `Ekspansi` besar besaran yang di lakukan oleh `Capital Bike Share` dengan penambahan `32 stasiun` dan memperluas `18 statiun` sisanya pada akhir tahun. Dan lebih gilanya di `Tahun 2012` ini di tambah menjadi `50 stasiun`. Ini membuktikan bahwa strategi yang di ambil oleh `Capital Bike Share` mampu menjadikan `Tahun 2012` menjadi tahun yang paling banyak `Total Peminjamnya`. Capital Bike Share Sytem
2. Seperti yang sudah aku katakan pada proses EDA, faktor `Cuaca` pun sangat berjasa dan berpengaruh besar untuk `Tahun 2012` ini. Menurut The Washington Post menyatakan bahwa, `Tahun 2012` adalah tahun terhangat yang tercatat di Washington, D.C., dengan Maret yang sangat hangat dan musim panas yang masuk dalam tiga terhangat dalam sejarah.

Meskipun ada bencana alam yang terjadi di `Tahun 2012` ini seperti `Huriccane Sandy` tapi tetap bisa di katakan bahwa `Tahun 2012` adalah tahun terbaik dengan `Total Peminjaman Sepeda` Terbanyak, dan itu valid 100%.

- **Pendukung Kuat untuk menjawab mengapa bisa `Tahun 2012` menjadi tahun yang paling banyak diminati**.

1. Dominasi `Tahun 2012` di jam sibuk.

[146]:
```
by_hour_df = hour_df.groupby(['Tahun', 'Jam'], observed=False)['Total'].sum().
 ↪reset_index()

plt.figure(figsize=(8, 6))
sns.barplot(
    x='Jam',
    y='Total',
    hue='Tahun',
    data=by_hour_df,
    palette=['#1f77b4', '#ff7f0e']
)

plt.title('Perbandingan Peminjaman Sepeda per Jam (2011 vs 2012)', pad=20,␣
 ↪fontsize=16)
plt.xlabel('Jam', fontsize=12)
plt.ylabel('Jumlah Peminjaman', fontsize=14)
plt.xticks(fontsize=12)
plt.legend(title='Tahun')
plt.grid(axis='y', linestyle='--', alpha=0.7)

plt.show()
```

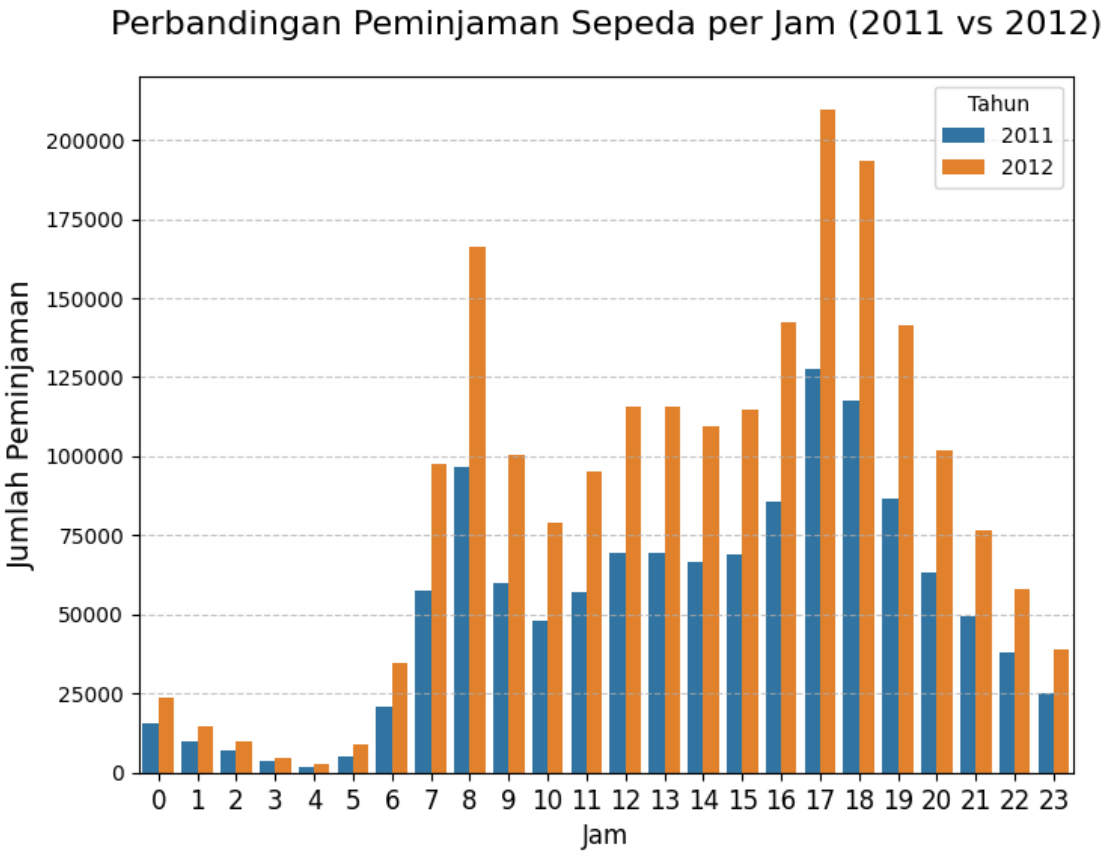

Insight Walaupun kedua tahun memiliki lonjakan yang signifikan dan pola serupa tapi, `Tahun 2012` selalu berada di paling tinggi.

- `Morning Rush` dan `Evening Rush` sangat mempengaruhi sekali peminjaman sepeda ini di kedua tahun, tapi lonjakan pada `Tahun 2012` di saat `Evening Rush` itu sangat gila banget sampai sampai menyentuh 2.000.000 peminjaman loh.

Tapi dengan visualisasi data ini aku baru menemukan hal menarik:

- Pola pemakaian `pagi` dan `sore` di kedua tahun ini mirip sekali, yang artinya sepeda memang sudah jadi pilihan utama buat mobilitas sehari-hari, bukan cuma buat iseng atau rekreasi doang.
- Lonjakan di `Evening Rush` jauh lebih tajam dibanding `Morning Rush`, bisa jadi karena lebih banyak orang pulang kerja naik sepeda daripada berangkat kerja. Mungkin pulang sekolah juga berpengaruh deh kayanya.

Jadi kesimpulannya di lihat dari manapun `Tahun 2012` ini tahun yang terbaik dari strategi matang yang telah `Capital Bike Share` ciptakan.

Masih banyak sih yang aku perlihatkan tapi mungkin segini saja sudah cukup untuk menjelaskan.

---

2. Bagaimana kondisi cuaca memengaruhi jumlah peminjaman sepeda?

[147]:
```
# Grouping
Impact_Cuaca = day_df.groupby(by=['Tahun', 'Cuaca'], observed=False)['Total'].
 ↪sum().reset_index()


plt.figure(figsize=(8,5))
sns.barplot(x='Cuaca', y='Total',hue='Tahun', data=day_df, palette='coolwarm')

plt.title("Pengaruh Kondisi Cuaca terhadap Jumlah Peminjaman Sepeda")
plt.xlabel("Kondisi Cuaca")
plt.ylabel("Jumlah Peminjaman Sepeda")

plt.show()
print(Impact_Cuaca)
```

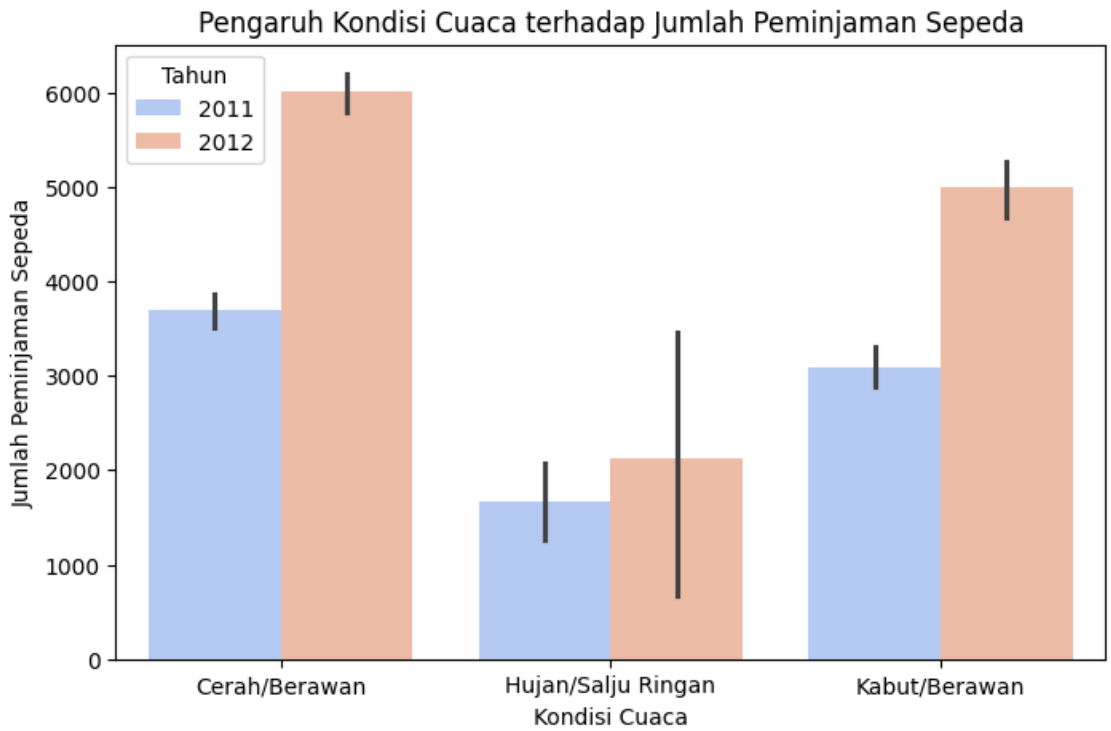


```
   Tahun               Cuaca    Total
0   2011        Cerah/Berawan   835067
1   2011   Hujan/Salju Ringan    25112
2   2011        Kabut/Berawan   382924
3   2012        Cerah/Berawan  1422885
4   2012   Hujan/Salju Ringan    12757
5   2012        Kabut/Berawan   613934
```

Insight Dari grafik di atas bisa kita ketahui bahwa:

- Pada `Tahun 2011` dan `2012`, kondisi `Cuaca` dapat mempengaruhi `Jumlah Peminjaman` sepeda secara signifikan. Hal ini terlihat pada tiap tahunnya yang memperlihatkan bahwa dalam kondisi `Cuaca` yang `Cerah/Berawan`, angka Peminjaman sepeda cenderung meningkat.
- Sedangkan pada kondisi `Cuaca Hujan` angka peminjaman sepedanya relatif menurun dari kondisi `Cuaca` lainnya. Dalam grafik tersebut juga diketahui bahwa pe,imja,am dari tiap tahun dan masing-masing kondisi `Cuaca` terus meningkat.

Tapi mari kita lihat `Tahun 2012` selalu menjadi yang terdepan. Bukan hanya karena `Cuaca` seperti biasanya, tapi `Cuaca` pada `Tahun 2012` ini spesial loh brow, sampai sampai masuk `sejarah` haha.

Untuk memastikan benar tidak nya data ini aku akan memastikan nya dengan membawa variable pendukung lain.

- **Melihat peran `Suhu Terasa` kepada `Total Peminjaman` untuk membuktikan `Cuaca Cerah/Berawan` itu valid**.

[148]:
```
atemp_impact = hour_df.groupby(by='Kategori_Suhu_Terasa',␣
↪observed=False)['Total'].sum().sort_values(ascending=False).reset_index()

plt.figure(figsize=(12, 6))

scatter = sns.scatterplot(
    x='Suhu_Terasa',
    y='Total',
    hue='Kategori_Suhu_Terasa',
    palette='coolwarm',
    data=day_df,
    alpha=0.8,
    edgecolor='black',
    s=100
)

plt.title('Pengaruh Kategori Suhu Terasa terhadap Peminjaman Sepeda Per Jam',␣
↪fontsize=14, fontweight='bold')
plt.xlabel('Suhu Terasa (°C)', fontsize=12)
plt.ylabel('Jumlah Peminjaman Sepeda', fontsize=12)
plt.legend(title='Kategori Suhu Terasa', bbox_to_anchor=(1,1))
plt.show()
print(atemp_impact)
```

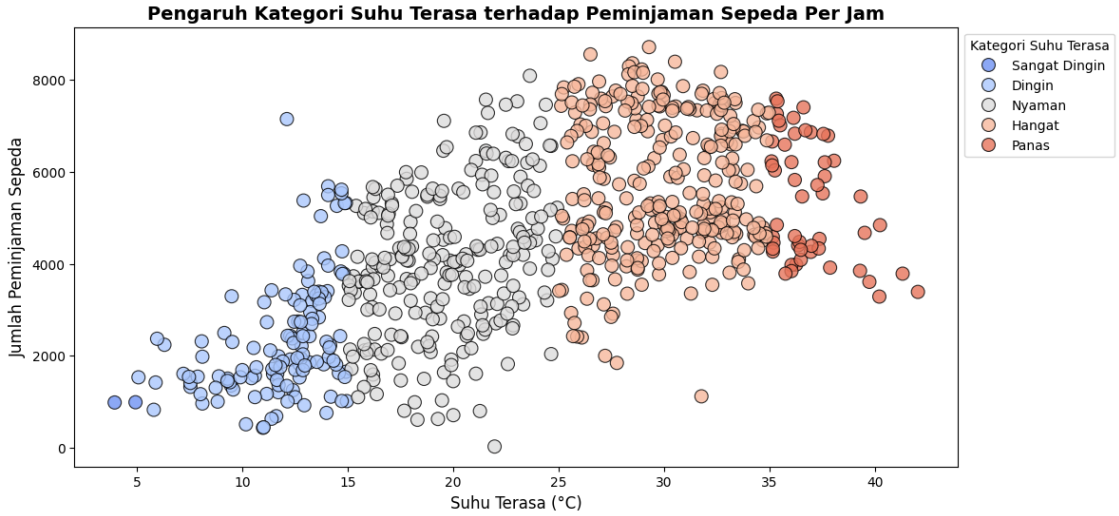


```
  Kategori_Suhu_Terasa    Total
0               Hangat  1594727
1               Nyaman  1014586
2                Panas   420732
3               Dingin   273014
4        Sangat Dingin     2944
```

Insight Aku menggunakan `hour_df` untuk mendukung apa yang telah di katakan, bahwa `Cuaca Cerah/Berawan` memeiliki kontribusi tertinggi untuk `Total Peminjaman` dan mengapa aku menggunakan `Suhu_Terasa` karena, `Suhu_Terasa` merepresentasikan `Suhu Asli` dan `Kelembapan`.

Dan setelah itu aku menemukan sebuah kesimpulan:

- `Hangat` dan `Nyaman` merupakan keniakan yang sangat stabil dan signifikan bisa di lihat dari `scatterplot` di atas lonjakan `Jumlah Peminjaman` di saat `Suhu_Terasa` mencapai 15 Celcius sampai 35 Celcius.

Dan pada kesimpulannya bahwa `Cuaca Cerah/Berawan` dapat di katakan merupakan sebuah fakta dan bukti nyata bahwa dialah yang paling berkontribusi untuk `Total Peminjaman Capital Bike Share`.

---

3. Kapan waktu puncak penggunaan sepeda dalam sehari, dan apakah ada perbedaan pola antara hari kerja dan akhir pekan di tahun 2011 & 2012?

`Berdasarkan Hari`

[149]:
```
# Penempatan hari
urutan_hari = ['Senin', 'Selasa', 'Rabu', 'Kamis', 'Jumat', 'Sabtu', 'Minggu']
```

```
# Menyiapkan data 2012 dan 2011 dengan berdasarkan urutan_hari
data_2011 = hour_df[hour_df['Tahun'] == 2011].groupby('Hari',␣
↪observed=False)['Total'].sum().reindex(urutan_hari)
data_2012 = hour_df[hour_df['Tahun'] == 2012].groupby('Hari',␣
↪observed=False)['Total'].sum().reindex(urutan_hari)


# Plot
fig, axes = plt.subplots(1, 2, figsize=(12, 6), sharex=True)

sns.barplot(x=data_2011.values, y=data_2011.index, ax=axes[0], hue=data_2011.
↪index, palette='coolwarm')
axes[0].set_title('Total Peminjaman per Hari - 2011')
axes[0].set_xlabel('Total Peminjaman')
axes[0].set_ylabel('Hari')

sns.barplot(x=data_2012.values, y=data_2012.index, ax=axes[1], hue=data_2012.
↪index, palette='coolwarm')
axes[1].set_title('Total Peminjaman per Hari - 2012')
axes[1].set_xlabel('Total Peminjaman')
axes[1].set_ylabel('')

plt.tight_layout()
plt.show()
```

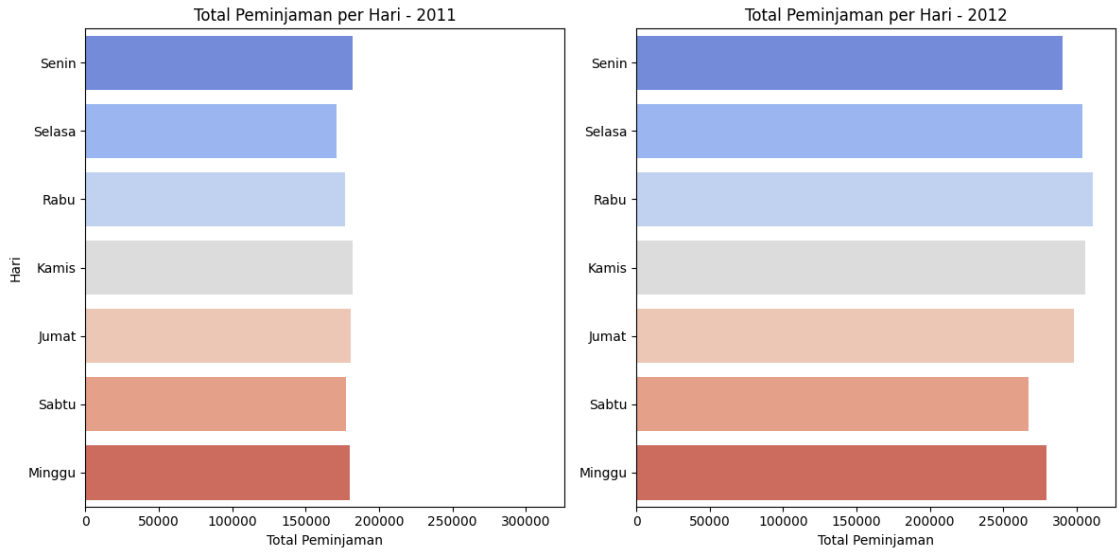

Insight Untuk waktu puncak penggunaan sepeda dalam sehari di pegang oleh:

- Hari Rabu pada `Tahun 2012` dengan Peminjaman perharinya sampai di 300.000+ peminjam.

Dan untuk pola antara hari kerja dan akhir pekan bisa kita lihat di kedua tahun:

2011

- Di `Tahun 2011` Peminjaman sepeda seimbang baik itu di hari kerja dan hari libur. Walaupun hari libur lebih signifikan dari biasanya.

2012

- Jika di `Tahun 2012` Hari kerja lebih mendomiasi di banding kan dengan hari libur. Ini menunjukan bahwa di `Tahun 2012` ini transportasi sepeda sudah di terima dan digunakan sebagai alat transportasi.

Untuk pola aku menemukannya sedikit:

- Pada `Tahun 2011` rata rata semua `Hari` sangat seimbang walaupun dominasi di pegang oleh `Akhir Pekan`.
- Ini menunjukan bahwa pada `Tahun 2011` orang yang kerja dan bersekolah belum tertarik dengan transportasi sepeda ini. Mungkin orang orang pada tahun itu bersepeda hanya karena gabut dan pengen melepas penat aja di hari libur.
- Nah berbeda dengan The King `Tahun 2012`, bisa kita lihat di barplot `Hari Kerja` mendominasi banget di banding kan dengan `Akhir Pekan`.
- Ini menunjukan strategi yang sudah aku bilang tepat dan sukses, dan pada akhirnya orang orang di tahun ini menyadari bahwa memakai sepeda itu bisa mengefisiensikan waktu karena tidak ada kemacetan di jalanan `Washington DC`, sehingga pemikiran ini merambah kepada semua kalangan, mau bapak bapak yang pergi dan pulang kantor, mau anak sekolahan yang berangkat dan pulang sekolah, mau orang yang berlibur doang menggunakan sepeda menikmati pemandangn. Dapat aku katakan `Capital Bike Share` mulai di terima di `Washington DC`.

---

4. Apakah tren peminjaman sepeda mengalami lonjakan atau penurunan signifikan pada bulan-bulan tertentu?

`Berdasarkan Bulan`

[150]:
```
# Mengelompokkan total peminjaman per bulan untuk masing-masing tahun
monthly_2011 = day_df[day_df['Tahun'] == 2011].groupby('Bulan',␣
↪observed=False)['Total'].sum()
monthly_2012 = day_df[day_df['Tahun'] == 2012].groupby('Bulan',␣
↪observed=False)['Total'].sum()

# Membuat plot untuk perbandingan
plt.figure(figsize=(10, 5))
sns.lineplot(x=monthly_2011.index, y=monthly_2011.values, marker='o',␣
↪label="2011")
sns.lineplot(x=monthly_2012.index, y=monthly_2012.values, marker='o',␣
↪label="2012")

# Penampilan
```

```
plt.title('Tren Peminjaman Sepeda per Bulan (2011 vs 2012)')
plt.xlabel('Bulan')
plt.ylabel('Total Peminjaman')
plt.xticks(ticks=range(1, 13), labels=['Jan', 'Feb', 'Mar', 'Apr', 'Mei',␣
↪'Jun', 'Jul', 'Agu', 'Sep', 'Okt', 'Nov', 'Des'])
plt.legend()
plt.grid(True)
plt.show()
```

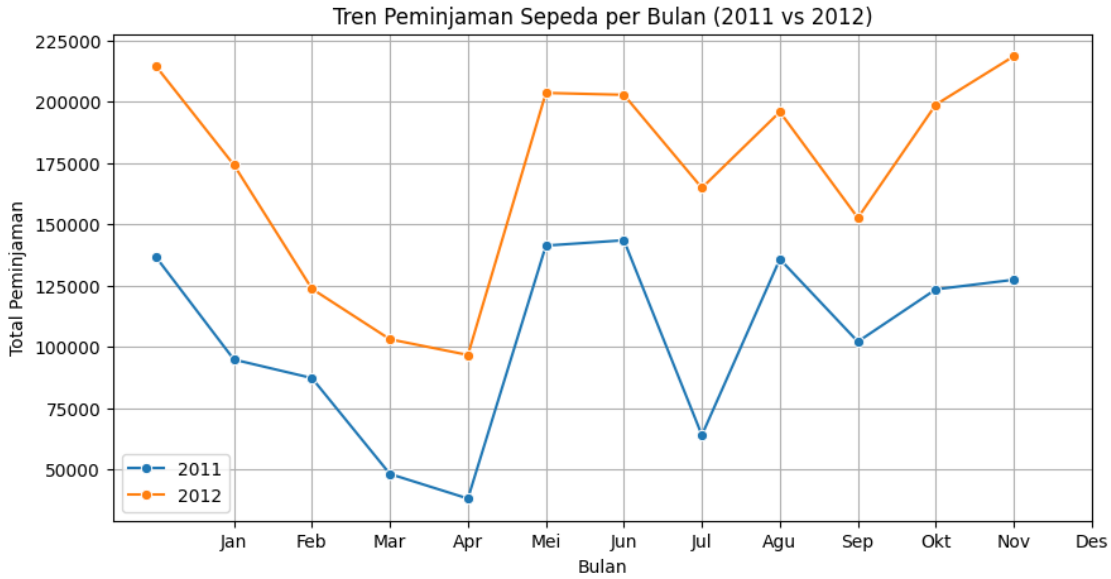

Insight Sebenarnya pola lonjakan dan penurunannya sama percis tapi yang membedakannya adalah `Tahun 2012` memiliki peminjaman lebih tinggi di bandingkan dengan `Tahun 2011`:

- Pada `Januari` - `Maret` terlihat penurunan yang sangat signifikan di keduanya, di karenakan `Musim Dingin` telah tiba yang mengakibatkan minat untuk meminjam sepeda terurung di karenakan di luar Cuaca dingin.
- Tapi Seteleh beresnya `Musim Dingin` pada bulan `April` sampai bulan `Juni` lonjakan yang sangat signifikan muncul, mungkin orang orang sangat excited karena bisa beraktivitas di luar ruangan secara normal kembali seteleh lama `Musim Dingin`.
- `Bulan Juli` mengalami penurunan tapi tidak secara signifikan, dan setelahnya meningkat kembali seperti biasanya.

Jadi pada keseimpulannya penurunan signifikan terjadi pada bulan `Januari` sampai bulan `Maret` tapi di balikkan oleh lonjakan yang sangat signifikan pada bulan `April` hingga bulan `Juni`.

Kita akan melihat deh Musim apa yang paling berkontribusi atau berjasa atas total penjumlahan ini.

`Berdasarkan Musim`

[151]:
```
season_total = day_df.groupby('Musim', observed=False)['Total'].sum()
warna_musim = ['#AEC6CF', '#77DD77', '#FFB347', '#FF6961']


plt.figure(figsize=(8, 5))
sns.barplot(x=season_total.index, y=season_total.values, hue=season_total.
 ↪index, palette=warna_musim)

plt.title('Total Peminjaman Sepeda Berdasarkan Musim (Gabungan 2011 & 2012)')
plt.xlabel('Musim')
plt.ylabel('Total Peminjaman')
plt.show()
```

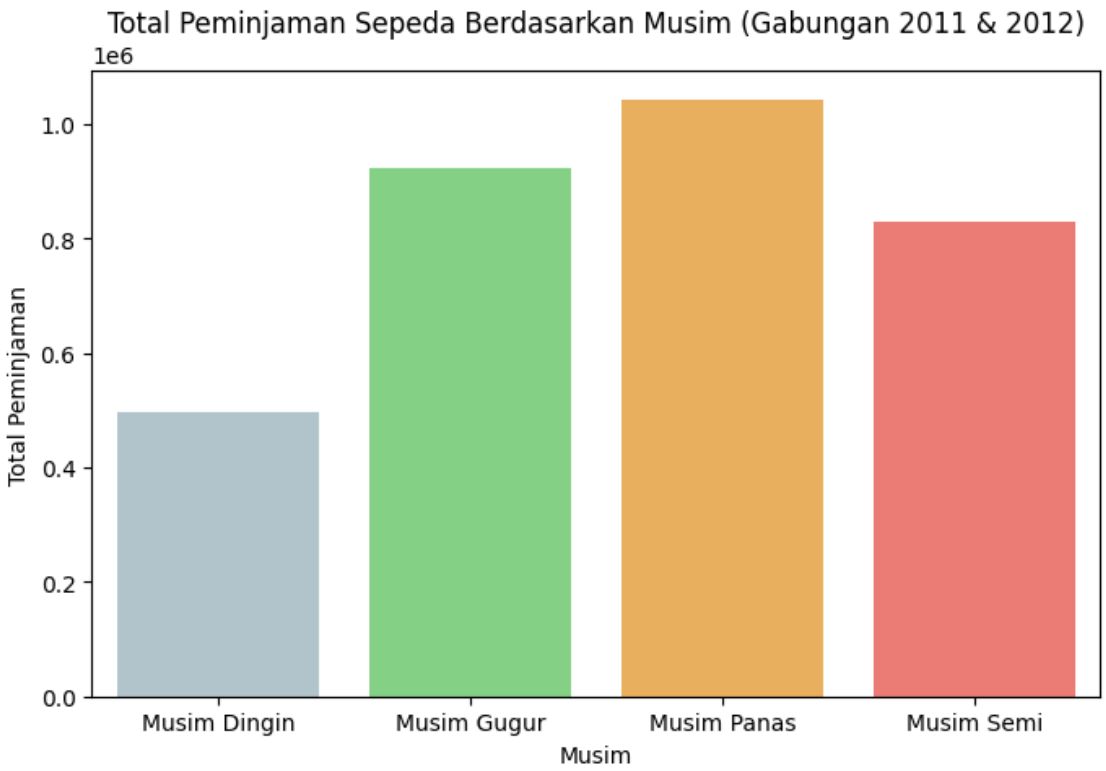

Insight Karena kedua tahun sama percis polanya maka aku akan menggabungkan nya untuk `Musim`, dan kita menemukan hal yang menarik bukan:

- Pada Bulan `Januari` sampai `Maret` di katakan bahwa penurunan signifikan terjadi pada bulan ini, dan ternyata benar karena dia berada di `Musim Dingin`, Tapi kalau aku tidak menyadari kesalahan `Musim` ini pasti di anggap `Musim Fall` sih.
- Dan benar juga kan Lonjakan pada Bulan `April` sampai `Juni` kenapa bisa tinggi, ya karena `Musim Gugur` dan `Musim Panas` lah bro, disukai pisan sama orang orang yang bersepeda.

---

5. Bagaimana pola penggunaan sepeda berbeda antara pelanggan kasual dan pelanggan terdaftar pada hari kerja vs. akhir pekan serta pada berbagai jam dalam sehari?

[152]:
```
# Kelompokkan data langsung tanpa buat kolom baru
kategori_totals = day_df.groupby(
    day_df['Hari'].apply(lambda x: 'Libur' if x in ['Sabtu', 'Minggu'] else␣
 ↪'Kerja')
)[['Member', 'Non_member']].sum().reset_index()

# Buat plot
plt.figure(figsize=(8, 5))
sns.barplot(
    data=kategori_totals,
    x='Hari',
    y='Member',
    label='Member',
    color='skyblue'
)
sns.barplot(
    data=kategori_totals,
    x='Hari',
    y='Non_member',
    label='Non-Member',
    color='lightcoral'
)

# Tambahkan judul dan label
plt.title('Perbandingan Peminjaman Sepeda oleh Member vs Non-Member\nPada Hari␣
 ↪Kerja dan Akhir Pekan')
plt.xlabel('Kategori Hari')
plt.ylabel('Total Peminjaman')
plt.legend()

# Tampilkan plot
plt.show()
```

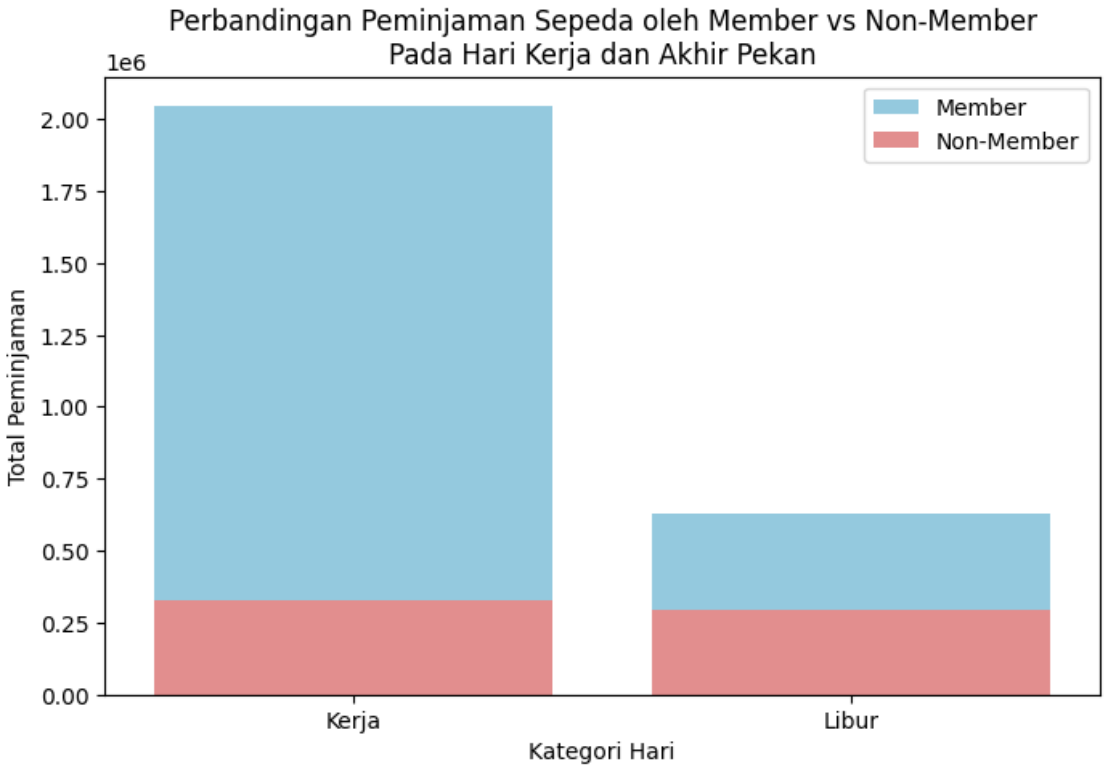

Insight Perbedaan yang bisa kita simpulkan dan kita ambil antara `Non_member` dan `Member` adalah:

- `Member`: Cenderung memanfaatkan fasilitasnya karena sudah langganan, terbukti dengan mereka lebih aktif pada `Hari Kerja`, jadi pada kesimpulannya `Member` menggunakan sepeda nya untuk aktivitas aktivitas rutin seperti berangkat kerja, berangkat sekolah, dan pulang ke rumah.
- Berbeda dengan `Non_member`: Peminjaman sepeda nya lebih merata baik di `Hari Kerja` Maupun di `Hari Libur`, meskipun Non_Member ini jumlah nya kecil tapi mereka konsisten di keduanya. Sepertinya mereka adalah orang orang yang berliburan deh, wisatawan mungkin yang hanya memakai sepeda untuk liburan dan coba coba aja.

Jadi kesimpulannya `Member` menggunakan sepeda nya lebih ke arah Funsgsionalitasnya, berbeda dengan `Non-member` mereka menggunakan sepedanya ke arah untuk santai dan rekreasi.

Untuk membuktikannya aku akan melakukan dan menjelaskan di RFM analysis ya.

1.11 Advance Analysis

RFM Analysis

[153]:
```
Non_member_df = hour_df[hour_df['Non_member'] > 0].copy()
Member_df = hour_df[hour_df['Member'] > 0].copy()
```

Berdasarkan Hari

[154]:
```
# RFM berdasarkan Hari untuk pelanggan Non_member
rfm_Non_member_day = Non_member_df.groupby('Hari', observed=False).agg({
    'Tanggal': lambda x: (Non_member_df['Tanggal'].max() - x.max()).days,  #␣
 ↪Recency
    'index': 'count',  # Frequency: jumlah transaksi
    'Non_member': 'sum'  # Monetary: total sepeda yang dipinjam
}).reset_index()

# Renaming Non_member
rfm_Non_member_day = rfm_Non_member_day.rename(columns={'index': 'Frequency'})

# RFM berdasarkan Hari untuk Member
rfm_Member_day = Member_df.groupby('Hari', observed=False).agg({
    'Tanggal': lambda x: (Member_df['Tanggal'].max() - x.max()).days,  # Recency
    'index': 'count',  # Frequency
    'Member': 'sum'  # Monetary
}).reset_index()

# Renameing Member
rfm_Member_day = rfm_Member_day.rename(columns={'index': 'Frequency'})
```

Visualisasi Hari

[155]:
```
# 1. Mengubah tipe data kolom 'Hari' berdasarkan urutan hari
day_order = ["Senin", "Selasa", "Rabu", "Kamis", "Jumat", "Sabtu", "Minggu"]
rfm_Non_member_day['Hari'] = pd.Categorical(rfm_Non_member_day['Hari'],␣
 ↪categories=day_order, ordered=True)
rfm_Member_day['Hari'] = pd.Categorical(rfm_Member_day['Hari'],␣
 ↪categories=day_order, ordered=True)
rfm_Non_member_day = rfm_Non_member_day.sort_values('Hari')
rfm_Member_day = rfm_Member_day.sort_values('Hari')

# 2. Visualisasinya
fig, axes = plt.subplots(2, 2, figsize=(14, 10))

# Frequency per Hari (Non-Member)
sns.barplot(x='Hari', y='Frequency', data=rfm_Non_member_day, ax=axes[0, 0],␣
 ↪color='#ADD8E6', order=day_order)
axes[0, 0].set_title('Frequency per Hari (Non-Member)')

# Monetary per Hari (Non-Member)
# Mengurutkan data berdasarkan Monetary (Non_member)
```

```
rfm_Non_member_day_sorted = rfm_Non_member_day.sort_values(by=['Non_member'],␣
↪ascending=False)

# Mengambil 2 batang teratas (top 2 hari) agar mudah kita lihat
top_2_hari_non_member = rfm_Non_member_day_sorted['Hari'][:2]

# sns.barplot dan pewarnaannya
palette_non_member = {hari: '#bc13fe' if hari in top_2_hari_non_member.values␣
↪else '#D3D3D3' for hari in day_order}

sns.barplot(x='Hari', y='Non_member', hue='Hari',␣
↪data=rfm_Non_member_day_sorted, ax=axes[0, 1],
            order=day_order, dodge=False, palette=palette_non_member,␣
↪legend=False)

# Frequency per Hari (Member)
sns.barplot(x='Hari', y='Frequency', data=rfm_Member_day, ax=axes[1, 0],␣
↪color='#ADD8E6', order=day_order)
axes[1, 0].set_title('Frequency per Hari (Member)')

# Monetary per Hari (Member)
# Mengurutkan data berdasarkan Monetary (Member)
rfm_Member_day_sorted = rfm_Member_day.sort_values(by=['Member'],␣
↪ascending=False)

# Sama seperti di atas cuma ini menggunakan 3 top tier
top_4_hari_member = rfm_Member_day_sorted['Hari'][:4]

# sns.barplot dan jangan lupa hue dan palette nya agar tidak eror
palette_member = {hari: '#bc13fe' if hari in top_4_hari_member.values else␣
↪'#D3D3D3' for hari in day_order}

sns.barplot(x='Hari', y='Member', hue='Hari', data=rfm_Member_day_sorted,␣
↪ax=axes[1, 1],
            order=day_order, dodge=False, palette=palette_member, legend=False)

# Menampilkannya
plt.show()
```

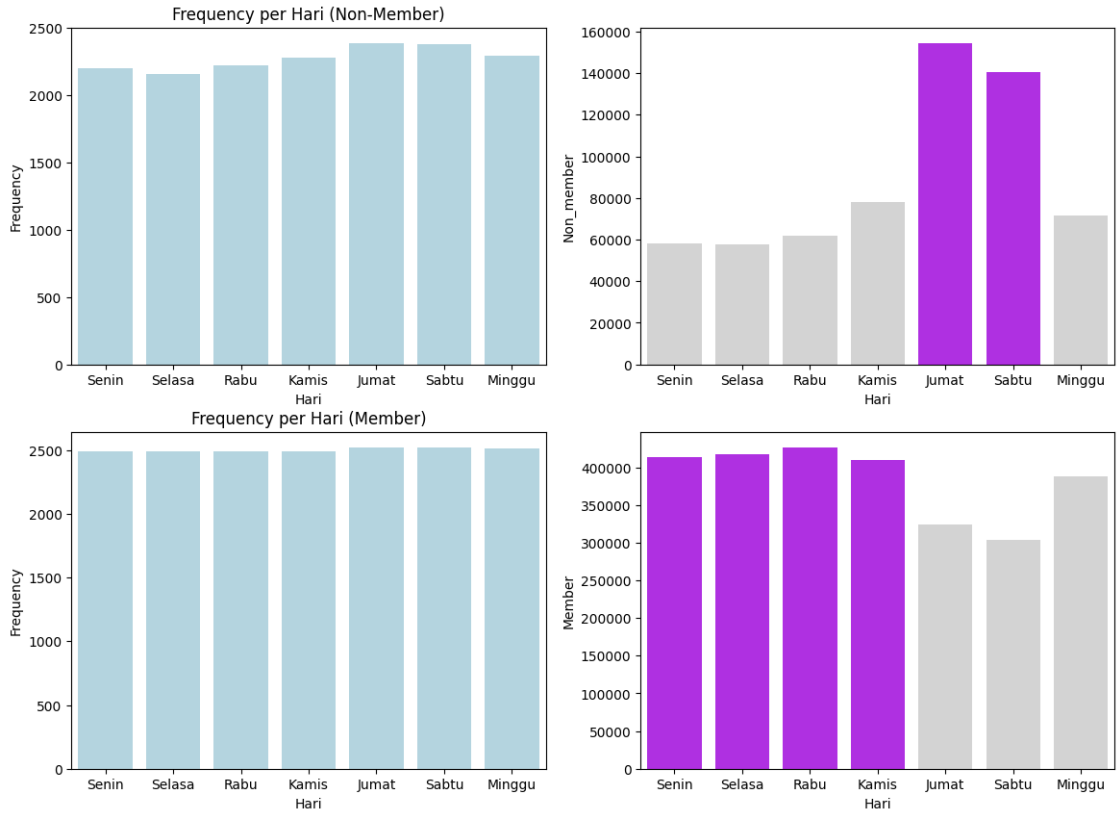

Insight Semakin jelas aku untuk menjawab pertanyaan nomer 5. Jadi dapat di katakan bahwa:

- `Non_member` menggunakan sepeda nya antara menjelang `akhir pekan` sampai `akhir pekan`, bisa kita lihat `Non-Member` pada hari `Jum'at` sangat lah melonjak dan banyak, sampai dengan hari `Sabtu` dan kemungkinan hari `Minggu` itu di jadikan hari beristirahat atau menikmati pemandangan.
- `Member` ini kuat banget sih di katakan bahwa `Member` lebih cenderung memakai sepeda untuk jadi transportasi yang fungsionalitas, dan terbukti kan disini, `Senin` Sampai `Kamis` adalah top tiernya, yang membuktikan bahwa `Member` menggunakan sepeda nya untuk berangkat dan pergi kerja, serta sekolah juga. Sebenarnya minggu juga melonjak sih itu menandakan `Member` manusia yang normal karena ingin liburan

---

`Berdasarkan Jam`

[156]:
```
# RFM berdasarkan Jam untuk pelanggan Non_member
rfm_Non_member_hour = Non_member_df.groupby('Jam').agg({
    'Tanggal': lambda x: (Non_member_df['Tanggal'].max() - x.max()).days,  #␣
 ↪Recency
    'index': 'count',  # Frequency
    'Non_member': 'sum'  # Monetary
```

```
}).reset_index()
rfm_Non_member_hour = rfm_Non_member_hour.rename(columns={'index': 'Frequency'})

# RFM berdasarkan Jam untuk Member
rfm_Member_hour = Member_df.groupby('Jam').agg({
    'Tanggal': lambda x: (Member_df['Tanggal'].max() - x.max()).days,  # Recency
    'index': 'count',  # Frequency
    'Member': 'sum'  # Monetary
}).reset_index()
rfm_Member_hour = rfm_Member_hour.rename(columns={'index': 'Frequency'})
```

Visualisasi Berdasarkan Jam

[157]:
```
fig, axes = plt.subplots(2, 2, figsize=(14, 10))

# Barplot Frequency per Jam untuk Non-Member
sns.barplot(x='Jam', y='Frequency', data=rfm_Non_member_hour, ax=axes[0, 0],␣
 ↪color='#ADD8E6')
axes[0, 0].set_title('Frequency per Jam (Non-Member)')
plt.sca(axes[0, 0])
plt.xticks(rfm_Non_member_hour['Jam'])

# Barplot Monetary per Jam (Non-Member)
# Mengurutkan data berdasarkan Monetary (Non_member) dari yang gede ke kecil
rfm_Non_member_hour_sorted = rfm_Non_member_hour.sort_values(by=['Non_member'],␣
 ↪ascending=False)

# Mengambil 4 batang teratas (jam dengan monetary tertinggi)
top_4_jam_non_member = rfm_Non_member_hour_sorted['Jam'][:4]
top_4_monetary_non_member = rfm_Non_member_hour_sorted['Non_member'][:4]

# Mewarnai agar cantik 4 batang teratas dengan warna ungu neon biar cetar
axes[0, 1].bar(top_4_jam_non_member, top_4_monetary_non_member, color='#bc13fe')

# Batang lainnya warna abu-abu muda aja biar kalem
axes[0, 1].bar(rfm_Non_member_hour_sorted['Jam'][4:],␣
 ↪rfm_Non_member_hour_sorted['Non_member'][4:], color='#D3D3D3')

axes[0, 1].set_title('Monetary per Jam (Non-Member)')
plt.sca(axes[0, 1])
plt.xticks(rfm_Non_member_hour_sorted['Jam'])

# Barplot Frequency per Jam untuk Member
sns.barplot(x='Jam', y='Frequency', data=rfm_Member_hour, ax=axes[1, 0],␣
 ↪color='#ADD8E6')
axes[1, 0].set_title('Frequency per Jam (Member)')
plt.sca(axes[1, 0])
```

```
plt.xticks(rfm_Member_hour['Jam'])

# Barplot Monetary per Jam (Member)
# Mengurutkan data berdasarkan Monetary (Member) dari yang paling cuan
rfm_Member_hour_sorted = rfm_Member_hour.sort_values(by=['Member'],␣
 ↪ascending=False)

# Mengambil 3 batang teratas (jam dengan monetary terokeh)
top_3_jam_member = rfm_Member_hour_sorted['Jam'][:3]
top_3_monetary_member = rfm_Member_hour_sorted['Member'][:3]

# Mewarnai 3 batang teratas dengan warna ungu neon biar stand out
axes[1, 1].bar(top_3_jam_member, top_3_monetary_member, color='#bc13fe')

# Batang lainnya warna abu-abu muda aja biar gak norak
axes[1, 1].bar(rfm_Member_hour_sorted['Jam'][3:],␣
 ↪rfm_Member_hour_sorted['Member'][3:], color='#D3D3D3')

axes[1, 1].set_title('Monetary per Jam (Member)')
plt.sca(axes[1, 1])
plt.xticks(rfm_Member_hour_sorted['Jam'])


plt.tight_layout() # Biar plotnya rapi dan gak tumpang tindih
plt.show()
```

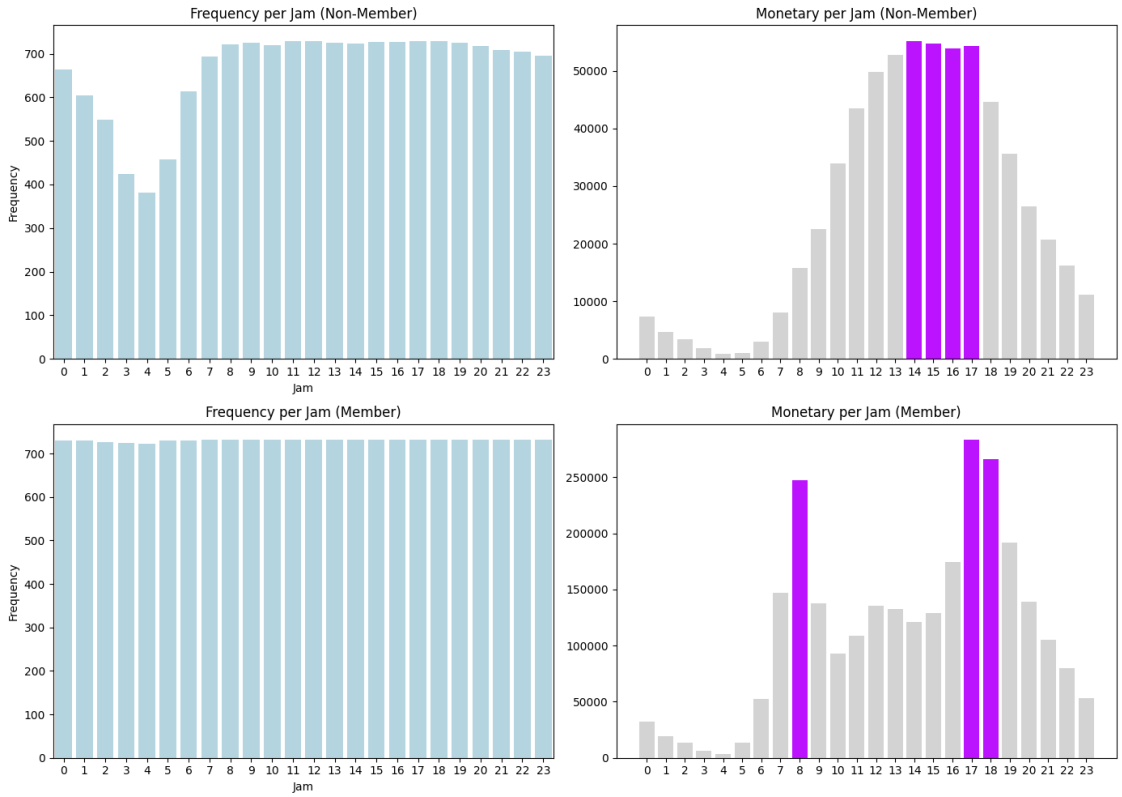

Insight Kalau di dalam per `Jam` aku menemukan:

- `Non-Member`tidak ada lonjakan yang cukup signifikan, pada `Jam 6` merupakan `Jam` untuk memulai aktivitas manusia sehari hari. Lonjakan terjadi pada sore hari. Ini pun normal karena jam jam sibuk, banyak yang pulang kerja, banyak yang rekreasi dan liburan juga.
- Untuk `Member` aku menemukan lonjakan yang cukup signifikan di `Jam 8` Mengapa?
- `Jam 8` adalah Jam berangkat kerja, sekolah, ibu ke pasar, orang orang beraktivitas, dan juga berangkat nya mahasiswa. Bisa di pastikan orang yang `Member` ini sangat memanfaatkan fasilitasnya.
- `Jam 17 - 18` ini adalah jam pulang kerja.

1.12 Kesimpulan

Jika aku jealsakan satu persatu pertanyaan itu sangat amat membutuhkan waktu yang sangat lama.

Jadi, `secara keseluruhan`, bisa disimpulkan bahwa di `Tahun 2012`, masyarakat di `Washington, D.C.` mulai lebih serius menggunakan sepeda sebagai alat transportasi utama mereka, bukan hanya

untuk sekadar bersantai. `Cuaca`, `Musim`, dan `strategi ekspansi` yang dilakukan oleh `Capital Bike Share` berkontribusi besar terhadap meningkatnya `jumlah peminjaman`. Selain itu, pola penggunaan antara pelanggan `Member` dan `Non-Member` semakin memperjelas bahwa sepeda bukan hanya alat `rekreasi`, tapi juga sudah menjadi bagian dari `gaya hidup` masyarakat perkotaan.

---

[157]:

```
```